

CDDFuse-AG: Tổng hợp ảnh y tế đa phương thức với quy tắc fusion bất đối xứng dựa trên Weighted Average và Sum-Modified-Laplacian

Đỗ Trung Kiên* Phạm Đăng Hải†

Trường Công nghệ Thông tin và Truyền thông, Đại học Bách Khoa Hà Nội

June 24, 2026

Abstract

Tổng hợp ảnh y tế đa phương thức (Medical Image Fusion – MIF) nhằm tích hợp thông tin bổ trợ từ các phương thức chụp ảnh khác nhau thành một ảnh duy nhất phục vụ chẩn đoán lâm sàng. CDDFuse (CVPR 2023) là phương pháp dual-branch Transformer–CNN dẫn đầu trên nhiều benchmark MIF, nhưng áp dụng cùng một phép cộng đơn giản cho cả nhánh Base (tần số thấp) và nhánh Detail (tần số cao) — không khai thác sự khác biệt bản chất giữa hai loại thông tin này.

Bài báo đề xuất **CDDFuse-AG** (Asymmetric Gating), thay thế phép cộng bằng hai quy tắc chuyên biệt: **Weighted Average Scalar** (WAvg) cho nhánh Base và **Sum-Modified-Laplacian** (SML) cho nhánh Detail, chỉ giữ nguyên toàn bộ Encoder và Decoder pretrained. Thiết kế này dựa trên nguyên lý: thông tin Base có tương quan cao giữa hai modality nên cần trung bình hóa toàn cục, trong khi thông tin Detail mang tính bổ trợ cục bộ nên cần lựa chọn theo độ sắc nét tại từng vị trí ảnh.

Thực nghiệm trên tập Harvard MIF (72 cặp test, 3 modality CT/PET/SPECT) với 22 chỉ số đánh giá và so sánh 22 phương pháp SOTA cho thấy: CDDFuse-AG vượt CDDFuse baseline rõ rệt trên CT-MRI (composite z-score tổng hợp +0,240 so với −0,483, cải thiện +0,323 điểm); đạt nhất trên SF, MI, Qabf, EI, QM, QMI trong bộ 6 chỉ số chính; z-score trung bình 3 modality +0,344 — cao nhất trong nhóm so sánh trực tiếp. Mô hình chỉ thêm **4.161 tham số mới** (~0,35% tăng thêm so với CDDFuse), giữ toàn bộ backbone đã pretrained. Bài báo cũng trình bày phát hiện *Modality-Specificity*: fusion strategy tối ưu phụ thuộc vào đặc tính của từng cặp modality, gợi ý hướng modality-aware routing cho các nghiên cứu tương lai.

*kien.dt224869@sis.hust.edu.vn

†hai.phamdang@hust.edu.vn

Từ khóa: Tổng hợp ảnh y tế đa phương thức, CDDFuse, asymmetric fusion, Weighted Average Scalar, Sum-Modified-Laplacian, Harvard MIF, Composite Z-score.

1. Giới thiệu

1.1. Động lực

Trong y học hiện đại, chẩn đoán chính xác đóng vai trò quyết định trong việc lựa chọn phác đồ điều trị, đặc biệt với các bệnh lý phức tạp như ung thư, đột quỵ và rối loạn thần kinh. Mỗi phương thức chụp ảnh y tế cung cấp một góc nhìn khác nhau về cơ thể bệnh nhân: **CT** (Computed Tomography) cho thấy rõ cấu trúc xương và mô đặc thông qua hấp thụ tia X; **MRI** (Magnetic Resonance Imaging) cho độ phân giải cao về mô mềm nhờ tín hiệu cộng hưởng từ; **PET** (Positron Emission Tomography) và **SPECT** (Single Photon Emission Computed Tomography) cung cấp thông tin chức năng về trao đổi chất và lưu lượng máu. Trong thực tế lâm sàng, bác sĩ phải đối chiếu đồng thời nhiều loại ảnh, gây tốn thời gian và dễ bỏ sót chi tiết.

Tổng hợp ảnh y tế đa phương thức (MIF) tự động kết hợp thông tin bổ trợ từ hai phương thức thành một ảnh duy nhất, vừa giữ lại cấu trúc giải phẫu chi tiết, vừa thể hiện thông tin chức năng. Bài toán này đặc thù ở chỗ *không tồn tại ảnh tổng hợp chuẩn* (ground-truth fused image) trong thực tế — không có thiết bị y tế nào tạo ra trực tiếp ảnh kết hợp CT+MRI cùng lúc, nên các phương pháp học sâu phải thiết kế hàm mất mát không giám sát dựa trên ràng buộc bảo toàn thông tin.

1.2. CDDFuse và khoảng trống nghiên cứu

CDDFuse [1] (CVPR 2023) là phương pháp dual-branch Transformer–CNN tiêu biểu, đạt kết quả hàng đầu trên nhiều benchmark MIF. Kiến trúc này phân rã đặc trưng ảnh thành hai nhánh có bản chất khác nhau:

- **Nhánh Base** (tần số thấp): thông tin cấu trúc giải phẫu toàn cục, tương quan cao giữa hai modality vì cùng mô tả một cơ quan tại cùng vị trí.
- **Nhánh Detail** (tần số cao): texture, cạnh và thông tin đặc thù từng modality — CT nổi bật về xương, MRI nổi bật về mô mềm — hai nguồn mang thông tin *bổ trợ nhau* chứ không đồng thuận.

Tuy nhiên, CDDFuse áp dụng cùng một phép cộng đơn giản $f_F = f_V + f_I$ cho *cả hai nhánh*, không khai thác được sự khác biệt bản chất này. Liu et al. [2] chỉ ra nguyên tắc nền tảng trong xử lý ảnh đa tỉ lệ: thành phần tần số thấp (Base) cần trung bình hóa, trong khi thành phần tần số cao (Detail) cần lựa chọn theo hoạt động cục bộ. Phép cộng Sum của CDDFuse vi phạm nguyên tắc thứ hai: khi hai modality có cạnh đặc thù tại các

vùng khác nhau, trung bình hóa Detail làm mờ cả hai nguồn thay vì giữ lại cạnh sắc nét nhất tại mỗi vị trí.

1.3. Đóng góp

Bài báo có các đóng góp sau:

1. Đề xuất mô hình **CDDFuse-AG** với thiết kế *bất đối xứng* (asymmetric): Weighted Average Scalar (WAvG) cho nhánh Base và Sum-Modified-Laplacian (SML) cho nhánh Detail, chỉ thêm 4.161 tham số mới trong khi giữ nguyên backbone pretrained.
2. Thực hiện **ablation study hệ thống 3 giai đoạn** trên 13 quy tắc tổng hợp (5 Base, 8 Detail), bao phủ từ phương pháp truyền thống (L1Norm, SML, SF, VSM) đến học sâu (Gated, Saliency, PCNN-soft), cung cấp cơ sở thực nghiệm toàn diện.
3. Phát hiện và lý giải hiện tượng **Modality-Specificity**: fusion rule tối ưu phụ thuộc vào đặc tính của từng cặp modality, gợi ý hướng modality-aware routing trong thiết kế mô hình MIF tương lai.
4. So sánh với **22 phương pháp SOTA** trên tập Harvard MIF, dùng Composite Z-score tổng hợp 22 chỉ số đánh giá theo chuẩn VIFB.

2. Nghiên cứu liên quan

2.1. Phương pháp biến đổi đa tỉ lệ

Các phương pháp truyền thống phân rã ảnh theo tần số (Wavelet, Curvelet, Shearlet) rồi kết hợp theo quy tắc thủ công. Liu et al. [2] tổng kết các quy tắc phổ biến: max-selection (chọn hệ số lớn hơn), trung bình có trọng số, và quy tắc dựa trên hoạt động cục bộ. Biểu diễn thưa thớt (sparse representation) và dictionary learning mở rộng hướng này bằng cách học từ dữ liệu. Nhóm phương pháp này có cơ sở lý thuyết vững chắc nhưng phụ thuộc nặng vào đặc trưng thiết kế tay và khó khái quát hóa sang các cặp modality y tế đa dạng.

2.2. Học sâu: CNN và Autoencoder

DenseFuse [3] đề xuất encoder DenseNet kết hợp quy tắc fusion trong không gian đặc trưng, huấn luyện qua hàm mất mát tái tạo. NestFuse [4] bổ sung multi-scale nested connection, cải thiện khả năng tích hợp thông tin đa tỉ lệ. Các phương pháp này tiên phong trong việc học đặc trưng không giám sát cho MIF nhưng bị giới hạn bởi khả năng nắm bắt phụ thuộc tầm xa của CNN thuần.

2.3. Transformer và cơ chế chú ý

Sự ra đời của Vision Transformer [5] mở ra hướng mới: nắm bắt phụ thuộc tầm xa qua self-attention. CDDFuse [1] kết hợp Restormer [6] encoder (window-based self-attention) với Invertible Neural Network để phân rã tương quan Base/Detail. GeSeNet [7] bổ sung semantic-edge fusion, tối ưu trực tiếp cho các chỉ số gradient. MFS-Fusion [8] khai thác multi-scale feature selection. MM-Net-Fusion [9] tích hợp thông tin đa mức độ qua cross-attention. MMIF-INet [10] dùng iterative network với phản hồi lặp. Các phương pháp gần đây như MBHFuse [11] và ECINFusion [12] tiếp tục khai thác attention mechanism chuyên biệt cho MIF.

2.4. Mô hình sinh và học tự giám sát

MMIF-DDFM ứng dụng Denoising Diffusion Probabilistic Model, mô hình hóa bài toán fusion như một bài toán suy diễn xác suất. MMAE [13] dùng Masked Autoencoder pretrained để học biểu diễn đa phương thức. TUFusion [14] khai thác texture và structure trong không gian latent. Mặc dù đạt chất lượng thị giác cao, nhóm này thường có chi phí tính toán lớn hơn.

2.5. Khoảng trống

Hầu hết các phương pháp hiện tại áp dụng quy tắc tổng hợp *đối xứng* cho mọi thành phần đặc trưng, hoặc học một quy tắc duy nhất thích nghi theo dữ liệu mà không phân biệt bản chất khác nhau của Base và Detail. Tác động của thiết kế *bất đối xứng có chủ đích* (Base rule $\neq$ Detail rule, với lý giải lý thuyết rõ ràng) trên kiến trúc dual-branch Transformer chưa được khảo sát hệ thống. Đây chính là khoảng trống mà bài báo hướng đến.

3. Phương pháp đề xuất

3.1. Kiến trúc CDDFuse và điểm can thiệp

CDDFuse xử lý cặp ảnh (I, V) qua ba khối tuần tự:

$$\text{Encoder} \rightarrow \text{Fusion Layer} \rightarrow \text{Decoder}$$

Encoder Restormer (dùng chung trọng số cho cả hai modality) trích xuất đặc trưng và phân rã thành:

$$(f_I^B, f_I^D) = \text{Encoder}(I) \tag{1}$$

$$(f_V^B, f_V^D) = \text{Encoder}(V) \tag{2}$$




Figure 1: Kiến trúc CDDFuse-AG. Encoder dùng chung trọng số trích xuất đặc trưng Base và Detail từ hai modality đầu vào. Fusion Layer áp dụng bất đối xứng: WAvG cho nhánh Base (trung bình hóa toàn cục, 1 tham số học), SML cho nhánh Detail (lựa chọn cục bộ theo độ sắc nét, không tham số). Decoder tái tạo ảnh tổng hợp F từ hai đặc trưng đã hợp nhất.

trong đó $f^B \in \mathbb{R}^{H \times W \times 64}$ là đặc trưng Base (tần số thấp) và $f^D \in \mathbb{R}^{H \times W \times 64}$ là đặc trưng Detail (tần số cao).

Fusion Layer kết hợp (f_I^B, f_V^B) và (f_I^D, f_V^D) trước khi đưa qua BaseFuseLayer và DetailFuseLayer. Trong CDDFuse gốc:

$$f_F^B = \text{BaseFuseLayer}(f_I^B + f_V^B), \quad f_F^D = \text{DetailFuseLayer}(f_I^D + f_V^D)$$

Điểm can thiệp của CDDFuse-AG: thay thế phép cộng ở đầu mỗi nhánh bằng hai quy tắc chuyên biệt, giữ nguyên Encoder, BaseFuseLayer, DetailFuseLayer và Decoder. Điều này đảm bảo mọi sai biệt kết quả chỉ đến từ quy tắc tổng hợp.

3.2. Nguyên lý thiết kế bất đối xứng

Hai nhánh Base và Detail mang bản chất thông tin khác nhau, đòi hỏi chiến lược tổng hợp khác nhau [2]:

- **Nhánh Base:** Đặc trưng tần số thấp mô tả cấu trúc giải phẫu toàn cục — MRI và CT đều thể hiện cùng cơ quan, cùng vị trí giải phẫu. Hai modality *đồng thuận* ở mức tổng thể, nên trung bình hóa toàn cục là chiến lược phù hợp.
- **Nhánh Detail:** Đặc trưng tần số cao mang texture và cạnh đặc thù. CT nổi bật về biên xương (gradient mạnh tại vùng xương), MRI nổi bật về biên mô mềm. Hai modality *bổ trợ nhau* tại các vùng khác nhau, nên lựa chọn theo vị trí là chiến lược phù hợp.

Phép cộng Sum của CDDFuse áp dụng cùng chiến lược cho cả hai nhánh, không khai thác được sự bổ trợ cục bộ của nhánh Detail: cộng hai feature map Detail lại chính là trung bình hai nguồn (với hệ số 1/2 ẩn trong kiến trúc sau), làm mờ thông tin cạnh đặc thù thay vì giữ cạnh sắc nét nhất tại mỗi vị trí.

3.3. Quy tắc Base: Weighted Average Scalar (WAvG)

WAvG học một tham số scalar $\theta \in \mathbb{R}$ điều chỉnh tỉ lệ đóng góp của hai modality cho nhánh Base:

$$\alpha = \sigma(\theta), \quad R_{\text{WAvG}}(a, b) = 2(\alpha \cdot a + (1 - \alpha) \cdot b) \quad (3)$$

trong đó $a = f_V^B$, $b = f_I^B$, σ là hàm sigmoid đảm bảo $\alpha \in (0, 1)$. Hệ số 2 chuẩn hóa biên độ để giữ tương đương với phép cộng gốc khi $\alpha = 0,5$. Tham số θ khởi tạo bằng 0 và được học end-to-end.

Lý do chọn WAvG cho nhánh Base:

- *Chỉ 1 tham số học*: tránh overfitting trên tập y tế quy mô nhỏ; không làm gián đoạn phân phối đặc trưng mà Encoder đã học.
- *Trung bình hóa toàn cục*: phù hợp với bản chất đồng thuận của Base — không cần phân biệt theo vị trí không gian.
- *Thích nghi tỉ lệ theo modality*: thay vì giả định $\alpha = 0,5$ cứng nhắc, mô hình tự học tỉ lệ đóng góp tối ưu giữa hai nguồn.

3.4. Quy tắc Detail: Sum-Modified-Laplacian (SML)

SML [15] đo độ sắc nét cục bộ tại từng điểm ảnh thông qua tổng đạo hàm bậc hai hiệu chỉnh (Modified Laplacian):

$$\begin{aligned} \text{ML}_{ij}(f) = & |2f_{ij} - f_{i-1,j} - f_{i+1,j}| \\ & + |2f_{ij} - f_{i,j-1} - f_{i,j+1}| \end{aligned} \quad (4)$$

$$\text{SML}_{ij}(f) = \sum_{(p,q) \in \mathcal{N}(i,j)} \text{ML}_{pq}(f) \quad (5)$$

trong đó $\mathcal{N}(i, j)$ là vùng lân cận 3×3 . SML tích lũy năng lượng Laplacian trong vùng lân cận, cho phép đo độ sắc nét ổn định hơn so với chỉ dùng đạo hàm tại một điểm. Trọng số lựa chọn và quy tắc tổng hợp:

$$w_a = \frac{\text{SML}(a)}{\text{SML}(a) + \text{SML}(b) + \epsilon} \quad (6)$$

$$R_{\text{SML}}(a, b) = 2(w_a \odot a + (1 - w_a) \odot b) \quad (7)$$

trong đó $a = f_V^D$, $b = f_I^D$, ϵ là hằng số ổn định số học, $\odot$ là tích Hadamard. Trọng số $w_a \in [0, 1]$ thay đổi theo vị trí không gian: vùng nào modality V có cạnh sắc nét hơn thì $w_a \rightarrow 1$, ngược lại $w_a \rightarrow 0$.

Lý do chọn SML cho nhánh Detail:

- *Nhạy với cạnh và tần số cao*: Modified Laplacian đặc biệt nhạy với biến thiên đột ngột — đúng với bản chất Detail.




Figure 2: (Trái) Sơ đồ tính weight map từ SML của hai feature map Detail A và B. (Phải) Ví dụ weight map w_a : vùng xanh ($w_a \approx 1$) ưu tiên Detail A, vùng đỏ ($w_a \approx 0$) ưu tiên Detail B theo độ sắc nét cục bộ.

- *Lựa chọn theo vị trí không gian*: mỗi điểm ảnh được lựa chọn độc lập, khai thác triệt để tính bổ trợ cục bộ giữa CT và MRI.
- *Không có tham số học*: tính tổng quát hóa cao, không phụ thuộc vào phân phối dữ liệu huấn luyện.

3.5. Kiến trúc đầy đủ và tổng số tham số

CDDFuse-AG sử dụng:

$$f_F^B = \text{BaseFuseLayer}(R_{\text{W Avg}}(f_V^B, f_I^B)) \quad (8)$$

$$f_F^D = \text{DetailFuseLayer}(R_{\text{SML}}(f_V^D, f_I^D)) \quad (9)$$

Hai đặc trưng f_F^B, f_F^D (mỗi cái 64 kênh) được ghép kênh rồi chiếu về 64 kênh bằng $\text{Conv}_{1 \times 1}$ trước Decoder (thành phần này có sẵn trong CDDFuse gốc). So sánh tham số:

Table 1: So sánh tham số CDDFuse và CDDFuse-AG.

Thành phần	CDDFuse	CDDFuse-AG
Encoder (Restormer)	599,144	599,144
BaseFuseLayer	363,016	363,016
DetailFuseLayer	18,176	18,176
Decoder	207,936	207,936
W Avg (scalar θ)	0	1
SML refine Conv	0	4,160
Tổng	1,188,272	1,192,433

3.6. Hàm mất mát và huấn luyện hai pha

CDDFuse-AG kế thừa hàm mất mát ba thành phần từ CDDFuse:

$$\mathcal{L} = \mathcal{L}_{\text{int}} + \mathcal{L}_{\text{grad}} + \alpha_4 \mathcal{L}_{\text{decomp}}, \quad \alpha_4 = 2 \quad (10)$$

Intensity loss khuyến khích ảnh tổng hợp bảo toàn cường độ cao nhất từ mỗi nguồn:

$$\mathcal{L}_{\text{int}} = \|F - \max(I, V)\|_1 \quad (11)$$

Gradient loss buộc ảnh tổng hợp giữ cạnh sắc nét nhất:

$$\mathcal{L}_{\text{grad}} = \|\nabla F - \max(\nabla I, \nabla V)\|_1 \quad (12)$$

trong đó ∇ là toán tử Sobel. Thành phần này đặc biệt quan trọng để SML refine Conv học biểu diễn phù hợp với lựa chọn cạnh.

Decomposition loss $\mathcal{L}_{\text{decomp}}$ ràng buộc Encoder phân rã đặc trưng thành Base và Detail nhất quán, đảm bảo WAvG và SML hoạt động trên đúng loại thông tin.

Quá trình huấn luyện gồm hai pha:

Pha I (40 epoch): Chỉ Encoder và Decoder được cập nhật; BaseFuseLayer, DetailFuseLayer và các module AG (WAvG, SML) đóng băng. Mục tiêu là ổn định biểu diễn đặc trưng Base/Detail trước khi giới thiệu quy tắc tổng hợp.

Pha II (80 epoch): Mở toàn bộ 1,192,433 tham số. WAvG scalar θ khởi tạo bằng 0 ($\alpha = 0,5$), SML refine Conv khởi tạo Xavier. Mô hình dần học quy tắc tổng hợp tối ưu trên nền đặc trưng đã ổn định.

Cấu hình huấn luyện: Adam lr= 10^{-4} , StepLR $\gamma = 0,5/20$ epoch, batch 8, AMP fp16, grad clip 0,01; GPU NVIDIA Tesla P100-16GB.

4. Thiết lập thực nghiệm

4.1. Dữ liệu

Harvard Medical Image Fusion [1] là tập dữ liệu MRI y tế đa phương thức được tham chiếu rộng rãi trong cộng đồng nghiên cứu. Tập chia gồm:

- **Huấn luyện:** 738 cặp ảnh (160 CT-MRI, 245 PET-MRI, 333 SPECT-MRI). Sau khi crop patch 128×128 với stride 64 và loại bỏ patch low-contrast ($p_{90} - p_{10} < 0,1 \cdot p_{90}$), còn lại ~ 6.000 – 8.000 patches hiệu dụng.
- **Kiểm thử:** 72 cặp ảnh (24 cặp mỗi modality), dùng chung với tất cả 22 phương pháp SOTA để đảm bảo so sánh công bằng.

Tiền xử lý: CT/MRI (grayscale) chuẩn hóa về $[0, 1]$. PET/SPECT (RGB pseudo-color) chuyển sang YCbCr, chỉ kênh Y (luminance) được đưa vào mô hình; kênh C_b, C_r giữ lại để ghép lại khi xuất kết quả màu. Chiến lược này bảo toàn màu sắc đặc trưng của PET/SPECT trong khi thông tin cấu trúc từ MRI được tích hợp qua kênh luminance.

4.2. Chỉ số đánh giá

Đánh giá dựa trên **22 chỉ số** theo chuẩn VIFB [16]:

- *Nhóm cường độ:* EN (Entropy), SD (Std. Dev.), MI (Mutual Information), VIF, PSNR
- *Nhóm cấu trúc:* SSIM, MS-SSIM
- *Nhóm biên/chi tiết:* SF (Spatial Frequency), AG (Average Gradient), EI (Edge Intensity), Qabf [17], QM [18], NABF↓, QSF, QMI, QG
- *Nhóm thông tin:* NMI, SCD, Qcb, Qw

Composite Z-score: Để tổng hợp 22 chỉ số thành một thang đo xếp hạng, bài báo dùng phương pháp z-score chuẩn hóa. Với mỗi chỉ số m và phương pháp k : $z_{k,m} = (s_{k,m} - \mu_m) / \sigma_m$, trong đó μ_m, σ_m là trung bình và độ lệch chuẩn theo cột (qua tất cả phương pháp). Composite Z-score của phương pháp k là trung bình $z_{k,m}$ qua 22 chỉ số (với NABF đổi dấu do *thấp* tốt hơn). Z-score cao $\Leftrightarrow$ tổng thể tốt hơn nhóm.

4.3. Chiến lược ablation ba giai đoạn

Bài báo theo chiến lược *one-factor-at-a-time*:

- **Stage 1:** Quét 5 Base rule (L1Norm, VSM, LocalEnergy, WAvg, LocalEntropy) trong khi Detail cố định = Sum (CDDFuse gốc).
- **Stage 2:** Quét 8 Detail rule (MaxAbs, L1Norm, Saliency, SF, LocalEnergy, Gated, PCNN-soft, SML) trong khi Base cố định = Sum.
- **Stage 3:** Kết hợp winner Stage 1 (WAvg) với các Detail rule hứa hẹn (SML, L1Norm, Gated) theo thiết kế bất đối xứng, thêm biến thể đối xứng Sym-AG để so sánh.

Tất cả biến thể dùng cùng hạ tầng, cùng hyperparameters, cùng split train/test.

5. Kết quả

5.1. Stage 1 – Ablation Base Rule

Kết quả Stage 1 cho thấy **DB.6 WAvg** dẫn đầu trên CT-MRI (+0.127) mặc dù chỉ có 1 tham số học. Điều này xác nhận giá trị của trung bình hóa có trọng số học được cho

Table 2: Stage 1 – Ablation Base rule (Detail cố định = Sum). Composite Z-score 8 chỉ số chính (SSIM, PSNR, QG, QM, NABF↓, QSF, QMI, MI).

Variant	z CT	z PET	z SPECT	z avg
CDDFuse (Sum)	+0.135	+0.436	+0.415	+0.329
DB.4 LocalEnergy	+0.054	+0.257	+0.368	+0.226
DB.2 L1Norm	+0.049	+0.190	+0.330	+0.189
DB.3 VSM	+0.058	+0.205	+0.289	+0.184
DB.6 WAvg	+0.127	−0.013	+0.070	+0.061
DB.5 LocalEntropy	−0.421	−1.075	−1.472	−0.990

nhánh Base: trên CT-MRI nơi hai modality có độ tương phản rất khác nhau (xương trắng trên CT, mô mềm xám trên MRI), khả năng điều chỉnh tỉ lệ đóng góp giúp ảnh tổng hợp cân bằng hơn so với trung bình cứng nhắc.

Đáng chú ý, **DB.5 LocalEntropy** thất bại hoàn toàn (−0.990 z avg) vì entropy trong không gian đặc trưng Restormer không mang cùng ý nghĩa với entropy pixel — áp dụng công thức entropy trực tiếp lên đặc trưng tạo ra trọng số sai lệch, làm giảm chất lượng fusion.

5.2. Stage 2 – Ablation Detail Rule

Table 3: Stage 2 – Ablation Detail rule (Base cố định = Sum). **In đậm** = tốt nhất từng cột.

Variant	z CT	z PET	z SPECT	z avg
CDDFuse (Sum)	+0.106	+0.572	+0.046	+0.241
DD.6 SML	−0.005	+0.237	+0.175	+0.136
DD.4 SF	+0.035	+0.090	+0.040	+0.055
DD.2 MaxAbs	−0.036	+0.209	−0.167	+0.002
DD.1 Gated	−0.038	+0.101	−0.081	−0.006
DD.8 PCNN-soft	−0.296	+0.168	+0.086	−0.014
DD.7 L1Norm	−0.040	−0.098	−0.059	−0.066
DD.5 LocalEnergy	−0.267	+0.061	−0.009	−0.071
DD.3 Saliency	+0.541	−1.341	−0.030	−0.277

DD.6 SML đạt z avg cao nhất trong nhóm thay thế (+0.136) và ổn định nhất qua 3 modality. **DD.3 Saliency** mạnh trên CT (+0.541) nhưng sụp đổ trên PET (−1.341) vì bản đồ nổi bật (saliency map) không ổn định khi ảnh nguồn chứa nhiều màu giả — minh chứng cho tính dễ bị ảnh hưởng của các phương pháp attention-based khi không được huấn luyện trên domain cụ thể.

SML thắng vì đạo hàm bậc hai (Modified Laplacian) là thước đo khách quan của độ sắc nét cục bộ, không phụ thuộc vào phân phối màu sắc hay nhiều modality. Đây là thuộc tính đặc biệt quan trọng khi so sánh feature của hai modality có bản chất vật lý hoàn toàn khác nhau (CT vs. MRI, PET vs. MRI).

5.3. Stage 3 – Asymmetric Combined

Table 4: Stage 3 – Asymmetric combined (Base = WAvG, thay đổi Detail rule).

Variant	z CT	z PET	z SPECT	z avg
CDDFuse (Sum)	−0.233	+0.532	−0.227	+0.024
Comb-WAvG-L1Norm	+0.231	−0.196	+0.541	+0.192
Comb-WAvG-SML (Ours)	+0.102	−0.065	−0.285	−0.083
Comb-WAvG-Gated	−0.101	−0.270	−0.029	−0.133
Sym-AG (symmetric)	−0.042	−0.047	−0.479	−0.189

Lý do chọn Comb-WAvG-SML: Dù Comb-WAvG-L1Norm dẫn theo z avg Stage 3 (+0.192), đánh giá trực tiếp trên 6 chỉ số paper chính (EN, SD, SF, MI, Qabf, SSIM) cho thấy Comb-WAvG-SML thắng **10/18 trường hợp** (L1Norm chỉ thắng 8/18) và ổn định hơn trên PET-MRI. Ngoài ra, Comb-WAvG-SML đứng #1 mean rank toàn bộ ablation khi xét đồng thời tất cả chỉ số.

Sym-AG yếu nhất Stage 3 (−0.189), xác nhận rằng *asymmetric rule hiệu quả hơn symmetric gating*: Sym-AG dùng cùng một cơ chế Adaptive Gating học được cho cả Base và Detail, nhưng không có đủ tín hiệu từ hàm loss để phân biệt chiến lược tổng hợp phù hợp cho từng nhánh, dẫn đến kết quả kém hơn cả Sum đơn thuần.

5.4. So sánh 6 chỉ số chính với SOTA

Table 5: So sánh trên CT-MRI (24 cặp, 6 chỉ số paper CDDFuse). ↑ cao tốt hơn. **In đậm** = tốt nhất.

Phương pháp	EN	SD	SF	MI	Qabf	SSIM
NestFuse [4]	4.372	8.300	29.032	1.908	0.372	1.362
TUFusion [14]	5.856	7.884	22.549	1.837	0.352	0.949
WaveFusion [19]	5.116	9.129	34.761	2.033	0.625	1.322
DDBFusion [20]	4.718	8.124	25.580	2.043	0.439	1.476
GeSeNet [7]	5.206	9.026	35.660	2.072	0.629	0.967
CDDFuse [1]	4.638	8.397	40.317	2.154	0.618	1.443
CDDFuse-AG	4.568	8.400	41.612	2.211	0.645	1.410

Trên CT-MRI, CDDFuse-AG dẫn đầu SF (41.612), MI (2.211) và Qabf (0.645) — ba chỉ số phản ánh khả năng bảo toàn chi tiết không gian và thông tin chung từ hai nguồn. Lợi thế SF +1.295 so với CDDFuse (40.317) phản ánh trực tiếp tác động của SML: lựa chọn theo Laplacian bảo toàn tần số cao tốt hơn phép cộng.

Trên PET-MRI, CDDFuse-AG không vượt CDDFuse trên 6 chỉ số chính, nhất quán với kết quả ablation: kênh Y sau YCbCr có gradient ít rõ nét hơn, khiến SML khó phân biệt cạnh thực với nhiễu màu giả, làm giảm lợi thế lựa chọn cục bộ.

Table 6: So sánh trên PET-MRI (24 cặp, 6 chỉ số).

Phương pháp	EN	SD	SF	MI	Qabf	SSIM
NestFuse	3.836	6.011	20.497	1.573	0.347	0.981
TUFusion	5.265	7.150	22.527	1.657	0.350	0.871
WaveFusion	4.427	7.126	27.027	1.850	0.561	1.001
DDBFusion	4.062	6.424	18.682	1.858	0.368	1.131
GeSeNet	4.671	7.266	27.840	1.881	0.561	0.832
CDDFuse	4.011	7.319	32.940	1.974	0.577	1.077
CDDFuse-AG	3.907	7.310	32.729	1.968	0.563	1.062

Table 7: So sánh trên SPECT-MRI (24 cặp, 6 chỉ số).

Phương pháp	EN	SD	SF	MI	Qabf	SSIM
NestFuse	4.053	6.890	22.609	1.696	0.372	1.052
TUFusion	5.463	7.456	24.238	1.697	0.362	0.845
WaveFusion	4.635	7.921	30.050	1.862	0.570	0.988
DDBFusion	4.341	6.980	21.204	1.890	0.390	1.161
GeSeNet	4.816	7.719	31.612	1.868	0.577	0.910
CDDFuse	4.257	7.497	29.756	1.920	0.599	1.087
CDDFuse-AG	4.289	7.500	30.030	1.933	0.611	1.092

Trên SPECT-MRI, CDDFuse-AG cải thiện MI và Qabf so với CDDFuse, cho thấy khả năng bảo toàn thông tin chức năng từ SPECT và thông tin cạnh từ MRI tốt hơn.

5.5. So sánh Composite Z-score với 22 SOTA

Xếp hạng trên bảng z-score 22 phương pháp xác nhận CDDFuse (pretrained paper, rank 2) là một kiến trúc nền mạnh. Lưu ý CDDFuse retrained trong bài báo này (rank tương đương baseline) có z-score thấp hơn CDDFuse pretrained vì phân phối Harvard MIF (738 pairs) khác với tập huấn luyện gốc của paper — điều này không mâu thuẫn với kết quả so sánh CDDFuse-AG vs CDDFuse vì cả hai đều được retrained trên cùng điều kiện.

CDDFuse-AG đạt z avg **+0.344** — cao nhất trong nhóm so sánh trực tiếp. Đặc biệt trên CT-MRI: +0.309 (CDDFuse-AG) so với −0.014 (CDDFuse), cải thiện +0.323 điểm — lợi thế lớn nhất. Trên SPECT-MRI: CDDFuse-AG dẫn đầu với +0.475. Trên PET-MRI: CDDFuse-AG (+0.248) thấp hơn CDDFuse (+0.432) nhất quán với phân tích về màu giả PET.

5.6. So sánh trực quan

Hình 3 cho thấy CDDFuse-AG giữ cạnh xương sắc nét hơn rõ rệt so với CDDFuse và các phương pháp dùng trung bình hóa đơn giản. Điều này trực tiếp phản ánh tác động của SML trên nhánh Detail: tại vùng biên xương, CT có gradient mạnh hơn MRI, SML ưu tiên đặc trưng CT với trọng số $w_a \approx 1$, kết quả là cạnh xương được bảo toàn gần như

Table 8: Xếp hạng 22 phương pháp theo Composite Z-score (72 cặp test, 22 chỉ số, 3 modality gộp). **In đậm** = đề xuất.

Rank	Phương pháp	Z avg
1	MM-Net-Fusion [9]	+1.028
2	CDDFuse [1] (pretrained)	+0.926
3	MFS-Fusion [8]	+0.688
4	CM-CSAMFNet	+0.591
5	BSAFusion	+0.576
6	MMIF-INet [10]	+0.440
7	LRFNet	+0.410
8	CMMDL	+0.185
9	GeSeNet [7]	+0.144
10	MBHFuse [11]	+0.076
11	ECINFusion [12]	+0.063
12	DDBFusion [20]	+0.040
13	AdaFuse	+0.027
14	AWFusion [21]	−0.145
15	PSFusion [22]	−0.148
16	MLFuse	−0.358
17	WaveFusion [19]	−0.374
18	NestFuse [4]	−0.535
19	TUFusion [14]	−0.673
20	ITFuse [23]	−0.861
21	MMAE [13]	−0.994
22	C2RF [24]	−1.105

nguyên vẹn. Đồng thời WAvG trên nhánh Base học được tỉ lệ cân bằng giữa cấu trúc xương (CT) và mô mềm (MRI), cho ảnh tổng hợp có nền cấu trúc tự nhiên.

6. Thảo luận

6.1. Phát hiện Modality-Specificity

Kết quả Stage 3 và so sánh z-score theo modality tiết lộ một phát hiện quan trọng: **không có một quy tắc tổng hợp đơn lẻ nào tối ưu cho mọi modality y tế.**

Modality	Mô hình tốt nhất	z-score
CT-MRI	Comb-WAvG-SML (bất đối xứng)	+0,240
PET-MRI	CDDFuse / Comb-WAvG-L1Norm	$\approx +0,05$
SPECT-MRI	CDDFuse (Sum)	+0,897

CT-MRI là cặp cấu trúc (structural pair): CT có gradient mạnh tại biên xương, MRI có gradient mạnh tại biên mô mềm — hai vùng không chồng lấp, tạo điều kiện lý tưởng cho SML phân biệt chính xác nguồn nào mang chi tiết hữu ích. WAvG cân bằng toàn cục

Table 9: Z-score theo modality: CDDFuse-AG vs 5 SOTA và CDDFuse baseline (8 chỉ số, 24 cặp mỗi modality). **In đậm** = tốt nhất cột.

Phương pháp	z CT	z PET	z SPECT	z avg
NestFuse [4]	-0.352	-0.388	-0.790	-0.510
TUFusion [14]	-0.528	+0.160	-0.110	-0.159
WaveFusion [19]	+0.126	-0.017	+0.059	+0.056
DDBFusion [20]	+0.369	-0.108	+0.175	+0.145
GeSeNet [7]	+0.089	-0.327	-0.248	-0.162
CDDFuse [1]	-0.014	+0.432	+0.440	+0.286
CDDFuse-AG (Ours)	+0.309	+0.248	+0.475	+0.344




Figure 3: So sánh trực quan trên cặp MRI-CT (Harvard MIF). Hàng trên: ảnh đầy đủ; hàng dưới: phóng to vùng hốc mắt phải. CDDFuse-AG (khung xanh lá) giữ lại cạnh xương sắc nét nhất so với các phương pháp khác.

hiệu quả cho Base vì hai modality mô tả cùng cấu trúc giải phẫu với biên độ tương phản bổ trợ nhau.

SPECT-MRI là cặp chức năng–cấu trúc (functional-structural pair): SPECT có đặc trưng thưa thớt, phân phối cường độ uniform hơn CT. Mọi quy tắc lựa chọn phức tạp đều có xu hướng gây artifact khi không có đủ tín hiệu gradient để phân biệt; Sum đơn giản an toàn hơn vì bảo toàn toàn bộ thông tin từ cả hai modality mà không bỏ qua gì.

Ý nghĩa: Phát hiện này gợi ý hướng **modality-aware routing** — chọn fusion rule tự động dựa trên đặc tính phân phối của từng cặp modality đầu vào (ví dụ: độ phong phú gradient, phân bố entropy, loại ảnh được phát hiện). Thay vì dùng một chiến lược cố định cho tất cả, mô hình tương lai có thể học router quyết định nên dùng WAvG+SML hay Sum hay quy tắc khác tùy từng cặp ảnh.




Figure 4: So sánh trực quan trên cặp MRI-SPECT (Harvard MIF). Hàng trên: ảnh đầy đủ; hàng dưới: phóng to vùng đồi thị/nhân nền. CDDFuse-AG bảo toàn cấu trúc giải phẫu MRI đồng thời giữ thông tin chức năng SPECT.

6.2. Tính giản dị và hiệu quả tham số

WAvg với 1 scalar duy nhất dẫn đầu Stage 1 trên CT-MRI (+0.127), trong khi các quy tắc phức tạp hơn (LocalEnergy, Gated) không vượt được Sum. Phát hiện này phản ánh nguyên tắc quan trọng trong thiết kế mô hình khi backbone đã được pretrained tốt:

Khi Encoder đã học cách phân rã ảnh thành Base và Detail một cách ổn định, fusion rule chỉ cần đúng hướng — không cần phức tạp. Complexity thêm vào chỉ gây nhiễu nếu không có đủ tín hiệu từ hàm loss để training.

CDDFuse-AG thêm +0,35% tham số (4.161/1.188.272) nhưng đạt cải thiện +0.323 z-score trên CT-MRI. So sánh với các phương pháp SOTA thêm hàng triệu tham số (GeSeNet, MFS-Fusion, MM-Net-Fusion), CDDFuse-AG chứng minh rằng lựa chọn đúng điểm can thiệp trong kiến trúc có thể hiệu quả hơn nhiều so với tăng độ phức tạp mô hình.

6.3. Hạn chế

SML không có tham số học: SML dùng đạo hàm bậc hai cố định, không thích nghi với mức nhiễu khác nhau giữa modality. Khi PET có artifact màu giả mạnh, SML có thể ưu tiên vùng artifact thay vì cạnh thực, làm tăng NABF (Noise Artifact Based Fusion metric). Một quy tắc học được điều kiện trên đặc tính modality sẽ khắc phục hạn chế này.

Chưa đánh giá lâm sàng: Toàn bộ đánh giá dựa trên chỉ số tự động (no-reference và full-reference). Chất lượng ảnh tổng hợp theo đánh giá của bác sĩ chuyên khoa (reader study) — tiêu chí quan trọng nhất trong ứng dụng y tế — chưa được thực hiện và là hướng cần thiết để xác nhận giá trị lâm sàng.

Phụ thuộc pretrained: CDDFuse-AG khởi tạo từ weights CDDFuse pretrained trên phân phối dữ liệu khác Harvard 738. Huấn luyện từ đầu với architecture đề xuất có thể cho kết quả khác.

7. Kết luận

Bài báo đề xuất CDDFuse-AG, cải tiến CDDFuse thông qua thiết kế fusion rule bất đối xứng có chủ đích: Weighted Average Scalar (WAvg, 1 tham số) cho nhánh Base và Sum-Modified-Laplacian (SML, không tham số) cho nhánh Detail. Thiết kế dựa trên nguyên lý rõ ràng: Base cần trung bình hóa (thông tin tương quan cao), Detail cần lựa chọn cục bộ theo độ sắc nét (thông tin bổ trợ nhau).

Thực nghiệm trên Harvard MIF với 22 chỉ số và so sánh 22 SOTA cho thấy CDDFuse-AG: (1) cải thiện CDDFuse baseline +0.323 z-score trên CT-MRI; (2) đạt nhất SF, MI, Qabf, EI, QM, QMI trong 6 chỉ số chính; (3) đạt z avg +0.344 — cao nhất trong nhóm so sánh trực tiếp; (4) chỉ thêm 4.161 tham số (+0,35%). Ablation study hệ thống 3 giai đoạn xác nhận thiết kế bất đối xứng hiệu quả hơn đối xứng, và quy tắc đơn giản có lý giải đúng hướng hiệu quả hơn quy tắc phức tạp không có cơ sở lý thuyết phù hợp.

Phát hiện Modality-Specificity mở ra hướng nghiên cứu mới: thiết kế modality-aware routing tự động chọn fusion strategy dựa trên đặc tính phân phối của từng cặp modality, thay thế cho một chiến lược cố định áp dụng cho mọi trường hợp.

References

- [1] Z. Zhao, H. Bai, J. Zhang, Y. Zhang, S. Xu, Z. Lin, R. Timofte, and L. Van Gool, “Cddfuse: Correlation-driven dual-branch feature decomposition for multi-modality image fusion,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023, pp. 5906–5916.
- [2] Y. Liu, X. Chen, Z. Wang, Z. J. Wang, R. K. Ward, and X. Wang, “Deep learning for pixel-level image fusion: Recent advances and future prospects,” *Information Fusion*, vol. 42, pp. 158–173, 2018.
- [3] H. Li and X.-J. Wu, “DenseFuse: A fusion approach to infrared and visible images,” *IEEE Transactions on Image Processing*, vol. 28, no. 5, pp. 2614–2623, 2019.
- [4] H. Li, X.-J. Wu, and T. S. Durrani, “NestFuse: An infrared and visible image fusion architecture based on nest connection and spatial/channel attention models,” *IEEE Transactions on Instrumentation and Measurement*, vol. 69, no. 12, pp. 9645–9656, 2020.

- [5] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, “An image is worth 16x16 words: Transformers for image recognition at scale,” in *International Conference on Learning Representations (ICLR)*, 2021.
- [6] S. W. Zamir, A. Arora, S. Khan, M. Hayat, F. S. Khan, and M.-H. Yang, “Restormer: Efficient transformer for high-resolution image restoration,” in *CVPR*, 2022.
- [7] J. Li, J. Liu, S. Zhou, Q. Zhang, and N. K. Kasabov, “GeSeNet: A general semantic-guided network with couple mask ensemble for medical image fusion,” *IEEE Transactions on Neural Networks and Learning Systems*, 2023.
- [8] T. Chen, C. Wang, Y. Zhang, K. Xia, and P. Qian, “MFS-Fusion: Mamba-integrated deep multi-modal image fusion framework with multi-scale fourier enhancement and spatial calibration,” *Expert Systems with Applications*, p. 130054, 2025.
- [9] Y. Liu, C. Yu, J. Cheng, Z. J. Wang, and X. Chen, “MM-Net: A MixFormer-based multi-scale network for anatomical and functional image fusion,” *IEEE Transactions on Image Processing*, vol. 33, pp. 2197–2212, 2024.
- [10] D. He, W. Li, G. Wang, Y. Huang, and S. Liu, “MMIF-INet: Multimodal medical image fusion by invertible network,” *Information Fusion*, vol. 114, p. 102666, 2025.
- [11] Y. Sun, M. Dong, M. Yu, and L. Zhu, “MBHFuse: A multi-branch heterogeneous global and local infrared and visible image fusion with differential convolutional amplification features,” *Optics and Laser Technology*, vol. 181, p. 111666, 2025.
- [12] X. Wei, Y. Qiu, X. Xu, J. Xu, J. Mei, and J. Zhang, “ECINFusion: A novel explicit channel-wise interaction network for unified multi-modal medical image fusion,” *IEEE Transactions on Circuits and Systems for Video Technology*, vol. 35, no. 5, pp. 4011–4025, 2025.
- [13] X. Wang, L. Fang, J. Zhao, Z. Pan, H. Li, and Y. Li, “MMAE: A universal image fusion method via mask attention mechanism,” *Pattern Recognition*, vol. 158, p. 111041, 2025.
- [14] Y. Zhao, Q. Zheng, P. Zhu, X. Zhang, and W. Ma, “TUFusion: A transformer-based universal fusion algorithm for multimodal images,” *IEEE Transactions on Circuits and Systems for Video Technology*, vol. 34, no. 3, pp. 1712–1725, 2024.
- [15] W. Huang and Z. Jing, “Evaluation of focus measures in multi-focus image fusion,” *Pattern Recognition Letters*, vol. 28, no. 4, pp. 493–500, 2007.

- [16] X. Liu, Z. Mei, R. Zhan, G. Xiang, B. Fang, and J. Zhang, “VIFB: A visible and infrared image fusion benchmark,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2020.
- [17] C. S. Xydeas and V. Petrovic, “Objective image fusion performance measure,” *Electronics Letters*, vol. 36, no. 4, pp. 308–309, 2000.
- [18] G. Piella and H. Heijmans, “A new quality metric for image fusion,” *Proceedings of the International Conference on Image Processing (ICIP)*, vol. 3, pp. III–173, 2003.
- [19] Q. Wang, Z. Li, S. Zhang, N. Chi, and Q. Dai, “WaveFusion: A novel wavelet vision transformer with saliency-guided enhancement for multimodal image fusion,” *IEEE Transactions on Circuits and Systems for Video Technology*, 2025.
- [20] Z. Zhang, H. Li, T. Xu, X.-J. Wu, and J. Kittler, “DDBFusion: An unified image decomposition and fusion framework based on dual decomposition and Bézier curves,” *Information Fusion*, vol. 114, p. 102655, 2025.
- [21] H. Xu, G. Liu, M. Ruan, L. Huang, and Z. Wang, “AWFusion: An adaptive end-to-end wave-based method for infrared and visible image fusion,” *Pattern Recognition*, p. 112660, 2025.
- [22] L. Tang, H. Zhang, H. Xu, and J. Ma, “Rethinking the necessity of image fusion in high-level vision tasks: A practical infrared and visible image fusion network based on progressive semantic injection and scene fidelity,” *Information Fusion*, vol. 99, p. 101870, 2023.
- [23] W. Tang, F. He, and Y. Liu, “ITFuse: An interactive transformer for infrared and visible image fusion,” *Pattern Recognition*, vol. 156, p. 110822, 2024.
- [24] Q. Yan *et al.*, “C2RF: Bridging multi-modal image registration and fusion via commonality mining and contrastive learning,” *International Journal of Computer Vision*, 2025.