

CDDFuse-AG: Tổng hợp ảnh y tế đa phương thức với quy tắc fusion bất đối xứng

Đỗ Trung Kiên

Trường CNTT&TT, ĐH Bách Khoa Hà Nội
kien.dt224869@sis.hust.edu.vn

Phạm Đăng Hải

Trường CNTT&TT, ĐH Bách Khoa Hà Nội
hai.phamdang@hust.edu.vn

Abstract—Bài báo đề xuất CDDFuse-AG (Asymmetric Gating), cải tiến từ CDDFuse (CVPR 2023) cho bài toán tổng hợp ảnh y tế đa phương thức (MRI–CT, MRI–PET, MRI–SPECT). CDDFuse phân rã đặc trưng thành hai nhánh Base (tần số thấp) và Detail (tần số cao), nhưng áp dụng chung một phép cộng đơn giản cho cả hai nhánh. CDDFuse-AG thay thế bằng hai quy tắc chuyên biệt: Weighted Average Scalar (WAvG) cho nhánh Base và Sum-Modified-Laplacian (SML) cho nhánh Detail. Thiết kế bất đối xứng này tận dụng bản chất khác nhau của hai loại thông tin: Base cân trung bình hóa toàn cục (tương quan cao giữa modality), trong khi Detail cần lựa chọn cục bộ theo vị trí (thông tin bổ trợ nhau). Thử nghiệm trên tập Harvard MIF (72 cặp test) với 22 chỉ số đánh giá và so sánh 22 phương pháp SOTA cho thấy CDDFuse-AG vượt CDDFuse baseline trên CT-MRI với z-score tổng hợp +0,240 so với −0,483, đạt thứ nhất trên 6/6 chỉ số SF, MI, Qabf, QM, QMI, EI trong bộ chỉ số chính của paper CDDFuse. Mô hình chỉ thêm 4.161 tham số mới (~0,35%) so với CDDFuse.

Index Terms—Tổng hợp ảnh y tế đa phương thức, CDDFuse, Transformer, asymmetric fusion, SML, Harvard MIF.

I. GIỚI THIỆU

Tổng hợp ảnh y tế đa phương thức (Medical Image Fusion – MIF) kết hợp thông tin bổ trợ từ hai phương thức chụp ảnh thành một ảnh duy nhất, hỗ trợ chẩn đoán lâm sàng. MRI cung cấp độ phân giải cao về mô mềm, trong khi CT/PET/SPECT cung cấp thông tin cấu trúc xương và chức năng trao đổi chất. Bài toán MIF đặc thù ở chỗ *không tồn tại ảnh tổng hợp chuẩn* (ground-truth), buộc các phương pháp học sâu phải thiết kế hàm mất mát không giám sát dựa trên ràng buộc bảo toàn thông tin.

CDDFuse [1] (CVPR 2023) là phương pháp dual-branch Transformer–CNN tiêu biểu, đạt kết quả hàng đầu trên nhiều benchmark MIF nhờ kiến trúc phân rã đặc trưng theo tương quan (Correlation-Driven Decomposition). Tuy nhiên, CDDFuse áp dụng cùng một phép cộng đơn giản $f_F = f_V + f_I$ cho cả hai nhánh Base và Detail, không khai thác sự khác biệt bản chất giữa thông tin tần số thấp (cấu trúc toàn cục, tương quan cao) và tần số cao (cạnh đặc thù modality, bổ trợ nhau).

Đóng góp của bài báo:

- Đề xuất CDDFuse-AG với thiết kế *bất đối xứng*: WAvG cho Base và SML cho Detail, chỉ thêm 4.161 tham số mới.
- Thực hiện ablation study hệ thống 3 giai đoạn với 13 quy tắc tổng hợp (5 Base, 8 Detail) trên tập Harvard MIF.
- Phát hiện *Modality-Specificity*: fusion rule tối ưu phụ thuộc vào đặc tính của từng cặp modality – kết quả gợi

ý hướng modality-aware routing trong thiết kế mô hình MIF.

II. NGHIÊN CỨU LIÊN QUAN

Phương pháp truyền thống. Các kỹ thuật biến đổi đa tỷ lệ (Wavelet, Curvelet) và biểu diễn thưa thớt [2] phân rã ảnh theo tần số và kết hợp bằng quy tắc thủ công (max-pooling, trung bình), có cơ sở lý thuyết vững nhưng khó khái quát hóa.

Học sâu. DenseFuse [3] và NestFuse [4] ứng dụng Encoder–Decoder dựa trên DenseNet, huấn luyện qua hàm mất mát tái tạo. Transformer mở rộng khả năng nắm bắt phụ thuộc tầm xa: CDDFuse [1] kết hợp Restormer Encoder với Invertible Neural Network để phân rã đặc trưng. GeSeNet [5], MFS-Fusion [6], MM-Net-Fusion [7] là các phương pháp SOTA gần đây trên Harvard MIF.

Khoảng trống. Hầu hết các phương pháp áp dụng quy tắc tổng hợp đối xứng cho mọi thành phần đặc trưng. Tác động của thiết kế *bất đối xứng* (Base rule $\neq$ Detail rule) chưa được khảo sát hệ thống, đặc biệt trong ngữ cảnh dual-branch Transformer.

III. PHƯƠNG PHÁP ĐỀ XUẤT

A. Kiến trúc CDDFuse và điểm can thiệp

CDDFuse phân rã ảnh đầu vào thành hai nhánh thông qua Encoder Restormer: nhánh **Base** f^B (tần số thấp, đặc trưng cấu trúc toàn cục) và nhánh **Detail** f^D (tần số cao, texture và cạnh đặc thù modality). Fusion Layer kết hợp hai cặp đặc trưng (f_I^B, f_V^B) và (f_I^D, f_V^D) bằng phép cộng $f_I + f_V$, rồi đưa qua BaseFuseLayer / DetailFuseLayer trước Decoder.

Điểm can thiệp: thay thế phép cộng đầu mỗi nhánh bằng hai quy tắc chuyên biệt, giữ nguyên Encoder và Decoder.

B. Quy tắc Base: Weighted Average Scalar (WAvG)

Nhánh Base mang thông tin tương quan cao giữa hai modality — nên trung bình hóa thay vì lựa chọn. WAvG học một scalar $\theta \in \mathbb{R}$:

$$\alpha = \sigma(\theta), \quad R_{\text{WAvG}}(a, b) = 2(\alpha a + (1 - \alpha)b) \quad (1)$$

với σ là sigmoid, $a = f_V^B$, $b = f_I^B$. Hệ số 2 duy trì biên độ so với phép cộng gốc. θ khởi tạo bằng 0 ($\alpha = 0,5$) và được học end-to-end. **WAvG chỉ có 1 tham số**, tránh overfitting và không phá vỡ phân phối đặc trưng của Encoder pretrained.




Figure 1: Kiến trúc CDDFuse-AG: Encoder dùng chung trọng số trích xuất đặc trưng Base/Detail; Fusion Layer áp dụng bất đối xứng (WAvG cho Base, SML cho Detail); Decoder tái tạo ảnh tổng hợp F .

C. Quy tắc Detail: Sum-Modified-Laplacian (SML)

Nhánh Detail mang thông tin bổ trợ nhau — tại mỗi vị trí, nên ưu tiên modality có cạnh sắc nét hơn. SML [8] đo độ sắc nét cục bộ:

$$ML_{ij}(f) = |2f_{ij} - f_{i-1,j} - f_{i+1,j}| + |2f_{ij} - f_{i,j-1} - f_{i,j+1}| \quad (2)$$

$$SML_{ij}(f) = \sum_{(p,q) \in \mathcal{N}(i,j)} ML_{pq}(f) \quad (3)$$

Trọng số lựa chọn và quy tắc tổng hợp:

$$w_a = \frac{SML(a)}{SML(a) + SML(b) + \epsilon}, \quad R_{SML}(a, b) = 2(w_a \odot a + (1 - w_a) \odot b) \quad (4)$$

SML không có tham số học, đảm bảo tính tổng quát hóa cao qua nhiều modality.

D. Tổng số tham số

Table I: So sánh tham số CDDFuse và CDDFuse-AG.

Thành phần	CDDFuse	CDDFuse-AG
Encoder	599,144	599,144
BaseFuseLayer	363,016	363,016
DetailFuseLayer	18,176	18,176
Decoder	207,936	207,936
WAvG (θ)	0	1
SML refine Conv	0	4,160
Tổng	1,188,272	1,192,433

E. Hàm mất mát và huấn luyện hai pha

Hàm mất mát kế thừa từ CDDFuse:

$$\mathcal{L} = \mathcal{L}_{\text{int}} + \mathcal{L}_{\text{grad}} + \alpha_4 \mathcal{L}_{\text{decomp}} \quad (5)$$

với $\mathcal{L}_{\text{int}} = \|F - \max(I, V)\|_1$, $\mathcal{L}_{\text{grad}} = \|\nabla F - \max(\nabla I, \nabla V)\|_1$, $\alpha_4 = 2$.

Pha I (40 epoch): chỉ cập nhật Encoder và Decoder; WAvG/SML đóng băng. **Pha II** (80 epoch): mở toàn bộ tham số, huấn luyện end-to-end. Cấu hình: Adam lr = 10^{-4} , StepLR $\gamma = 0,5/20$ epoch, batch 8, AMP fp16, grad clip 0,01, GPU Tesla P100-16GB.

IV. THỰC NGHIỆM

A. Dữ liệu và thiết lập đánh giá

Tập dữ liệu **Harvard Medical Image Fusion** [1]: 738 cặp huấn luyện (160 CT-MRI, 245 PET-MRI, 333 SPECT-MRI) và 72 cặp test (24 mỗi modality). Ảnh PET/SPECT được chuyển sang YCbCr, chỉ dùng kênh Y để mô hình xử lý ảnh grayscale; hai kênh C_b, C_r được ghép lại khi xuất kết quả màu.

Đánh giá dựa trên **22 chỉ số** theo chuẩn VIFB [9] gồm: nhóm cường độ (EN, SD, MI, VIF), nhóm cấu trúc (SSIM, PSNR), nhóm biên/chi tiết (SF, AG, EI, Qabf, QM, NABF, QSF, QMI), nhóm gradient (QG). Xếp hạng tổng hợp bằng **Composite Z-score**: z-score chuẩn hóa theo từng chỉ số, lấy trung bình, z cao = tốt hơn.

Baseline: CDDFuse được tái huấn luyện trên cùng tập Harvard MIF với cùng hyperparameters và split, đảm bảo so sánh công bằng.

B. Chiến lược ablation ba giai đoạn

Đồ án theo chiến lược *one-factor-at-a-time*:

- **Stage 1**: Quét 5 Base rule (giữ Detail = Sum).
- **Stage 2**: Quét 8 Detail rule (giữ Base = Sum).
- **Stage 3**: Kết hợp winner Stage 1 và 2 theo thiết kế bất đối xứng.

V. KẾT QUẢ

A. Ablation Study

Table II: Stage 1 – Ablation Base rule (Detail cố định = Sum). Z-score tổng hợp 8 chỉ số. $\uparrow$ cao hơn tốt hơn.

Variant	z CT	z PET	z SPECT	z avg
CDDFuse (Sum)	+0.135	+0.436	+0.415	+0.329
DB.4 LocalEnergy	+0.054	+0.257	+0.368	+0.226
DB.2 L1Norm	+0.049	+0.190	+0.330	+0.189
DB.3 VSM	+0.058	+0.205	+0.289	+0.184
DB.6 WAvG	+0.127	-0.013	+0.070	+0.061
DB.5 LocalEntropy	-0.421	-1.075	-1.472	-0.990

WAvG dẫn đầu trên CT-MRI (+0.127), xác nhận giá trị của trung bình hóa có trọng số học được cho nhánh Base. Trên PET/SPECT, Sum thắng vì phân phối ảnh đồng đều hơn không đòi hỏi điều chỉnh trọng số.

Table III: Stage 2 – Ablation Detail rule (Base cố định = Sum).

Variant	z CT	z PET	z SPECT	z avg
CDDFuse (Sum)	+0.106	+0.572	+0.046	+0.241
DD.6 SML	-0.005	+0.237	+0.175	+0.136
DD.4 SF	+0.035	+0.090	+0.040	+0.055
DD.2 MaxAbs	-0.036	+0.209	-0.167	+0.002
DD.1 Gated	-0.038	+0.101	-0.081	-0.006
DD.8 PCNN-soft	-0.296	+0.168	+0.086	-0.014
DD.7 L1Norm	-0.040	-0.098	-0.059	-0.066
DD.5 LocalEnergy	-0.267	+0.061	-0.009	-0.071
DD.3 Saliency	+0.541	-1.341	-0.030	-0.277

SML ổn định nhất qua 3 modality (z avg = +0.136). Saliency mạnh trên CT nhưng sụp đổ trên PET vì nhiễu màu giả làm bản đồ nổi bật không tin cậy.

Table IV: Stage 3 – Asymmetric combined variants (Base = WAvG).

Variant	z CT	z PET	z SPECT	z avg
CDDFuse (Sum)	−0.233	+0.532	−0.227	+0.024
Comb-WAvG-L1Norm	+0.231	−0.196	+0.541	+0.192
Comb-WAvG-SML (Ours)	+0.102	−0.065	−0.285	−0.083
Comb-WAvG-Gated	−0.101	−0.270	−0.029	−0.133
Sym-AG (symmetric)	−0.042	−0.047	−0.479	−0.189

Lựa chọn Comb-WAvG-SML. Dù Comb-WAvG-L1Norm dẫn theo z avg Stage 3, đánh giá trực tiếp trên 6 chỉ số chính (EN, SD, SF, MI, Qabf, SSIM) cho thấy Comb-WAvG-SML thắng **10/18 trường hợp** (vs. 8/18 của L1Norm) và ổn định hơn trên PET-MRI. Sym-AG (đối xứng) yếu nhất ($z = -0.189$), xác nhận thiết kế **bất đối xứng** hiệu quả hơn đối xứng.

B. So sánh 6 chỉ số chính với SOTA

Table V: So sánh trên CT-MRI (24 cặp, 6 chỉ số paper CDDFuse). ↑ cao hơn tốt hơn. **In đậm** = tốt nhất.

Phương pháp	EN	SD	SF	MI	Qabf	SSIM
NestFuse [4]	4.372	8.300	29.032	1.908	0.372	1.362
TUFusion [10]	5.856	7.884	22.549	1.837	0.352	0.949
WaveFusion [11]	5.116	9.129	34.761	2.033	0.625	1.322
DDBFusion [12]	4.718	8.124	25.580	2.043	0.439	1.476
GeSeNet [5]	5.206	9.026	35.660	2.072	0.629	0.967
CDDFuse [1]	4.638	8.397	40.317	2.154	0.618	1.443
CDDFuse-AG	4.568	8.400	41.612	2.211	0.645	1.410

Table VI: So sánh trên PET-MRI (24 cặp).

Phương pháp	EN	SD	SF	MI	Qabf	SSIM
NestFuse	3.836	6.011	20.497	1.573	0.347	0.981
TUFusion	5.265	7.150	22.527	1.657	0.350	0.871
WaveFusion	4.427	7.126	27.027	1.850	0.561	1.001
DDBFusion	4.062	6.424	18.682	1.858	0.368	1.131
GeSeNet	4.671	7.266	27.840	1.881	0.561	0.832
CDDFuse	4.011	7.319	32.940	1.974	0.577	1.077
CDDFuse-AG	3.907	7.310	32.729	1.968	0.563	1.062

Table VII: So sánh trên SPECT-MRI (24 cặp).

Phương pháp	EN	SD	SF	MI	Qabf	SSIM
NestFuse	4.053	6.890	22.609	1.696	0.372	1.052
TUFusion	5.463	7.456	24.238	1.697	0.362	0.845
WaveFusion	4.635	7.921	30.050	1.862	0.570	0.988
DDBFusion	4.341	6.980	21.204	1.890	0.390	1.161
GeSeNet	4.816	7.719	31.612	1.868	0.577	0.910
CDDFuse	4.257	7.497	29.756	1.920	0.599	1.087
CDDFuse-AG	4.289	7.500	30.030	1.933	0.611	1.092

C. So sánh Z-score tổng hợp với 22 phương pháp SOTA

CDDFuse-AG đạt z avg +0.344, cao nhất trong nhóm so sánh. Lợi thế đặc biệt rõ trên CT-MRI: +0.309 (CDDFuse-AG) so với −0.014 (CDDFuse), tương đương cải thiện +0.323 điểm z.

Table VIII: Z-score theo modality so với 5 SOTA đại diện (8 chỉ số, 24 cặp mỗi modality).

Phương pháp	z CT	z PET	z SPECT	z avg
NestFuse	−0.352	−0.388	−0.790	−0.510
TUFusion	−0.528	+0.160	−0.110	−0.159
WaveFusion	+0.126	−0.017	+0.059	+0.056
DDBFusion	+0.369	−0.108	+0.175	+0.145
GeSeNet	+0.089	−0.327	−0.248	−0.162
CDDFuse	−0.014	+0.432	+0.440	+0.286
CDDFuse-AG	+0.309	+0.248	+0.475	+0.344




Figure 2: So sánh trực quan MRI-CT. Hàng trên: ảnh đầy đủ; hàng dưới: phóng to vùng hốc mắt phải. CDDFuse-AG (khung xanh) giữ cạnh xương sắc nét nhất.

VI. THẢO LUẬN

A. Phát hiện Modality-Specificity

Kết quả Stage 3 cho thấy không có quy tắc tổng hợp đơn lẻ nào tối ưu cho mọi modality: CDDFuse-AG tốt nhất trên CT-MRI, CDDFuse (Sum) dẫn trên SPECT-MRI. Lý giải:

- **CT-MRI:** Cạnh xương (CT) và mô mềm (MRI) không chồng lấp, SML phân biệt chính xác vùng nào ưu tiên modality nào, WAvG cân bằng toàn cục hiệu quả cho Base.
- **SPECT-MRI:** SPECT có đặc trưng thừa thớt, ít thông tin chi tiết – mọi quy tắc lựa chọn phức tạp đều có xu hướng tạo artifact; Sum đơn giản an toàn hơn.

Kết quả gợi ý **modality-aware routing**: chọn fusion rule tự động dựa trên đặc tính phân phối của từng cặp modality đầu vào, thay vì dùng một chiến lược cố định.

B. Tính giản dị và hiệu quả tham số

WAvG với 1 scalar duy nhất dẫn đầu Stage 1 trên CT-MRI. Đây là minh chứng cho nguyên tắc: khi Encoder đã pretrained tốt và phân rõ đặc trưng ổn định, fusion rule chỉ cần đúng hướng — không cần phức tạp. LocalEntropy (−0.990 z avg) thất bại vì entropy của feature-space không mang cùng ý nghĩa với entropy pixel-space.

C. Hạn chế

SML không thích nghi với mức nhiễu khác nhau giữa modality, có thể ưu tiên nguồn nhiễu cao thay vì nguồn có cạnh thực sự. Ngoài ra, toàn bộ đánh giá dựa trên chỉ số tự động; nghiên cứu đọc ảnh lâm sàng (reader study) chưa được thực hiện.

VII. KẾT LUẬN

Bài báo đề xuất CDDFuse-AG, cải tiến CDDFuse thông qua thiết kế bất đối xứng: WAvg cho nhánh Base và SML cho nhánh Detail. Chỉ với 4.161 tham số mỗi, mô hình vượt CDDFuse trên CT-MRI (+0.323 z-score) và đạt z avg +0.344 — cao nhất trong nhóm 6 phương pháp so sánh trực tiếp. Phát hiện Modality-Specificity gợi ý rằng fusion strategy nên được điều chỉnh theo đặc tính từng cặp modality, mở hướng cho modality-aware routing và adaptive fusion trong tương lai.

REFERENCES

- [1] Z. Zhao, H. Bai, J. Zhang, Y. Zhang, S. Xu, Z. Lin, R. Timofte, and L. Van Gool, “Cddfuse: Correlation-driven dual-branch feature decomposition for multi-modality image fusion,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023, pp. 5906–5916.
- [2] Y. Liu, X. Chen, Z. Wang, Z. J. Wang, R. K. Ward, and X. Wang, “Deep learning for pixel-level image fusion: Recent advances and future prospects,” *Information Fusion*, vol. 42, pp. 158–173, 2018.
- [3] H. Li and X.-J. Wu, “DenseFuse: A fusion approach to infrared and visible images,” *IEEE Transactions on Image Processing*, vol. 28, no. 5, pp. 2614–2623, 2019.
- [4] H. Li, X.-J. Wu, and T. S. Durrani, “NestFuse: An infrared and visible image fusion architecture based on nest connection and spatial/channel attention models,” *IEEE Transactions on Instrumentation and Measurement*, vol. 69, no. 12, pp. 9645–9656, 2020.
- [5] J. Li, J. Liu, S. Zhou, Q. Zhang, and N. K. Kasabov, “GeSeNet: A general semantic-guided network with couple mask ensemble for medical image fusion,” *IEEE Transactions on Neural Networks and Learning Systems*, 2023.
- [6] T. Chen, C. Wang, Y. Zhang, K. Xia, and P. Qian, “MFS-Fusion: Mamba-integrated deep multi-modal image fusion framework with multi-scale fourier enhancement and spatial calibration,” *Expert Systems with Applications*, p. 130054, 2025.
- [7] Y. Liu, C. Yu, J. Cheng, Z. J. Wang, and X. Chen, “MM-Net: A MixFormer-based multi-scale network for anatomical and functional image fusion,” *IEEE Transactions on Image Processing*, vol. 33, pp. 2197–2212, 2024.
- [8] W. Huang and Z. Jing, “Evaluation of focus measures in multi-focus image fusion,” *Pattern Recognition Letters*, vol. 28, no. 4, pp. 493–500, 2007.
- [9] X. Liu, Z. Mei, R. Zhan, G. Xiang, B. Fang, and J. Zhang, “VIFB: A visible and infrared image fusion benchmark,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2020.
- [10] Y. Zhao, Q. Zheng, P. Zhu, X. Zhang, and W. Ma, “TUFusion: A transformer-based universal fusion algorithm for multimodal images,” *IEEE Transactions on Circuits and Systems for Video Technology*, vol. 34, no. 3, pp. 1712–1725, 2024.
- [11] Q. Wang, Z. Li, S. Zhang, N. Chi, and Q. Dai, “WaveFusion: A novel wavelet vision transformer with saliency-guided enhancement for multimodal image fusion,” *IEEE Transactions on Circuits and Systems for Video Technology*, 2025.
- [12] Z. Zhang, H. Li, T. Xu, X.-J. Wu, and J. Kittler, “DDBFusion: An unified image decomposition and fusion framework based on dual decomposition and Bézier curves,” *Information Fusion*, vol. 114, p. 102655, 2025.