

The background of the entire image is a solid red color. Overlaid on this background is a large, circular pattern of small, light red dots. These dots are arranged in a way that they form a series of concentric, slightly irregular circles, creating a textured, almost halftone effect. The dots are more densely packed in some areas and more sparse in others, giving the pattern a dynamic feel.

HUST

ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

ONE LOVE. ONE FUTURE.





ĐẠI HỌC
BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY
OF SCIENCE AND TECHNOLOGY

ĐỒ ÁN TỐT NGHIỆP

Đề xuất mô hình CDDFuse-AG
cho tổng hợp ảnh y tế đa phương thức

Người thực hiện:

Đỗ Trung Kiên — 20224869

GVHD: TS. Phạm Đăng Hải · PGS. TS. Phạm Văn Hải

ONE LOVE. ONE FUTURE.

Nội dung trình bày I

1. Giới thiệu và bài toán (Introduction)
2. Các nghiên cứu liên quan (Related Work)
3. Phương pháp đề xuất (Proposed Method)
4. Thực nghiệm đối chứng (Ablation Study)
5. Kết quả thực nghiệm (Experimental Results)
6. Thảo luận và kết luận (Discussion & Conclusion)




Mỗi phương thức ảnh có ưu điểm riêng:

- ▶ **MRI**: Độ phân giải cao về mô mềm
- ▶ **CT**: Rõ cấu trúc xương
- ▶ **PET/SPECT**: Thông tin chức năng, trao đổi chất

MIF kết hợp hai phương thức thành **một ảnh duy nhất** — hỗ trợ chẩn đoán nhanh và chính xác hơn.

Thách thức: Không tồn tại ảnh chuẩn $\Rightarrow$ hàm mất mát không giám sát.



Hình: CT-MRI, PET-MRI, SPECT-MRI trên Harvard MIF.

Tại sao CDDFuse? Và hạn chế nào cần cải tiến?

CDDFuse (Zhao et al., CVPR 2023) —
#2/22 SOTA:

- ▶ Dual-branch: tách nhánh **Base** (tần số thấp) và **Detail** (tần số cao)
- ▶ Restormer Encoder + Invertible Neural Network
- ▶ Huấn luyện không giám sát trên dữ liệu y tế

Hạn chế: Cả hai nhánh dùng chung **phép cộng đơn giản**:

$$f_F = f_V + f_I$$

Điểm can thiệp

Chỉ thay thế **Fusion Layer**, giữ nguyên Encoder–Decoder pretrained.

⇒ So sánh công bằng, tốn ít tài nguyên.

Câu hỏi nghiên cứu

Dùng quy tắc **khác nhau cho từng nhánh** (bất đối xứng) có cải thiện chất lượng tổng hợp không?

Phương pháp truyền thống:

- ▶ Laplacian pyramid, Wavelet — phân rã đa tỉ lệ, không cần học
- ▶ Hạn chế: tham số thủ công, không thích nghi với dữ liệu

CNN và học biểu diễn:

- ▶ DenseFuse, NestFuse, RFN-Nest — encoder học đặc trưng
- ▶ Fusion rule vẫn cố định (L1, Weighted Avg)

GAN:

- ▶ FusionGAN — bảo toàn chi tiết qua adversarial loss

Transformer và mô hình sinh:

- ▶ SwinFusion, CDDFuse, DDFM, TUFusion — attention toàn cục
- ▶ DDFM dùng diffusion model, chất lượng cao nhưng rất chậm

Khoảng trống nghiên cứu

Hầu hết phương pháp dùng **cùng quy tắc** cho cả nhánh Base (tần số thấp) và Detail (tần số cao) — không khai thác bản chất khác nhau của hai nhánh.

⇒ CDDFuse-AG đề xuất **quy tắc bất đối xứng**.

Nhánh Base (tần số thấp)

Mang thông tin cấu trúc toàn cục.

Hai modality có **tương quan cao**.

⇒ Cần **trung bình hóa** (averaging).


Nhánh Detail (tần số cao)

Mang cạnh, texture đặc thù từng modality.

Thông tin **bổ trợ nhau**.

⇒ Cần **lựa chọn cục bộ** (activity-based selection).

Phép cộng Sum áp dụng *cùng chiến lược* cho cả hai — **không tối ưu**.



Hình: WAvG phù hợp Base (đồng thuận); SML phù hợp Detail (bổ trợ).


Quy tắc Base: Weighted Average Scalar (WAvG)

Trung bình có trọng số với **1 scalar học** được θ :

$$\alpha = \sigma(\theta), \quad \theta \in \mathbb{R} \quad (1)$$

$$R_{\text{WAvG}}(a, b) = 2(\alpha \cdot a + (1 - \alpha) \cdot b) \quad (2)$$

- ▶ Chỉ **1 tham số học** — tránh overfitting
- ▶ Tự học tỉ lệ α tối ưu cho từng modality
- ▶ Khởi tạo $\theta = 0$ ($\alpha = 0.5$) — ổn định khi chuyển pha



$\alpha = 0.5$ khi khởi tạo ($\theta = 0$), điều chỉnh qua Phase II

Trung bình hóa toàn cục - phù hợp nhánh Base (tần số thấp, đồng thuận)

$\alpha \in (0, 1)$

Hình: WAvG: hai Feature Map Base kết hợp bằng scalar α .


Quy tắc Detail: Sum-Modified-Laplacian (SML)

Tại mỗi vị trí, chọn modality có cạnh **sắc nét hơn**:

$$ML_{ij} = |2f_{ij} - f_{i-1,j} - f_{i+1,j}| + |2f_{ij} - f_{i,j-1} - f_{i,j+1}| \quad (3)$$

$$w_a = \frac{SML(a)}{SML(a) + SML(b) + \varepsilon} \quad (4)$$

$$R_{SML} = 2(w_a \odot a + (1 - w_a) \odot b) \quad (5)$$



Hình: Xanh = ưu tiên Detail A; Đỏ = ưu tiên Detail B.

- ▶ **Không tham số học** — tổng quát hóa tốt
- ▶ Lựa chọn **theo từng vị trí** (spatially adaptive)

Thay đổi duy nhất:


- ▶ Base: Sum $\rightarrow$ **WAvg**
- ▶ Detail: Sum $\rightarrow$ **SML**

Tham số bổ sung

WAvg (θ)	1
SML refine Conv	4,160

Tổng mới	4,161
-----------------	--------------

($\sim 0.35\%$ của 1,188,272 params CDDFuse)



Hình: WAvg cho nhánh Base, SML cho nhánh Detail.

Chiến lược thực nghiệm đối chứng 3 giai đoạn

Khảo sát hệ thống **13 quy tắc tổng hợp** theo chiến lược *one-factor-at-a-time*:

Stage 1 — Base

Giữ Detail = Sum

5 quy tắc: L1Norm, VSM,
LocalEnergy, **WAvG**,
LocalEntropy

Stage 2 — Detail

Giữ Base = Sum

8 quy tắc: MaxAbs, L1Norm,
Saliency, **SML**, SF,
LocalEnergy, PCNN, Gated

Stage 3 — Asymmetric

Base = WAvG (winner S1)

Detail $\in \{\text{SML, L1Norm, Gated}\}$
+ So sánh với Sym-AG (đối xứng)

Đánh giá: Composite Z-score trên 8 chỉ số — 72 cặp test Harvard MIF (24 CT + 24 PET + 24 SPECT).

Giai đoạn 1 & 2 (Stage 1 & 2): Chọn rule tốt nhất từng nhánh

Giai đoạn 1 — Quy tắc nhánh Base (Detail = Sum):

Variant	z CT	z PET	z SP	avg
CDDFuse (Sum)	+0.135	+0.436	+0.415	+0.33
LocalEnergy	+0.054	+0.257	+0.368	+0.23
L1Norm	+0.049	+0.190	+0.330	+0.19
WAvG	+0.127	-0.013	+0.070	+0.06
LocalEntropy	-0.421	-1.075	-1.472	-0.99

WAvG chọn cho CT-MRI: CT và MRI có cấu trúc rất khác (xương vs mô mềm) — cần điều chỉnh trọng số α , không trung bình cứng nhắc.

LocalEntropy sụp đổ (-0.99): entropy feature-space $\neq$ entropy pixel-space.

Giai đoạn 2 — Quy tắc nhánh Detail (Base = Sum):

Variant	z CT	z PET	z SP	avg
CDDFuse (Sum)	+0.106	+0.572	+0.046	+0.24
SML	-0.005	+0.237	+0.175	+0.14
SF	+0.035	+0.090	+0.040	+0.06
MaxAbs	-0.036	+0.209	-0.167	+0.00
Saliency	+0.541	-1.341	-0.030	-0.28

SML ổn định nhất: z dương cả 3 modality.

Đo độ sắc nét cục bộ qua Laplacian, không bị nhiễu màu giả PET.

Saliency sụp đổ trên PET (-1.341): bản đồ nổi bật không ổn định với nhiễu chức năng.

Giai đoạn 3 (Stage 3): Kết hợp bất đối xứng và lựa chọn mô hình

Kết hợp bất đối xứng — Base = WAvG (winner G1), Detail thử SML / L1Norm /

	Variant	z CT	z PET	z SPECT	z avg
Gated:	CDDFuse (Sum-Sum)	-0.233	+0.532	-0.227	+0.024
	Comb-WAvG-L1Norm	+0.231	-0.196	+0.541	+0.192
	Comb-WAvG-SML (Ours)	+0.102	-0.065	-0.285	-0.083
	Comb-WAvG-Gated	-0.101	-0.270	-0.029	-0.133
	Sym-AG (đối xứng)	-0.042	-0.047	-0.479	-0.189

Tại sao chọn **Comb-WAvG-SML** dù **L1Norm** thắng z-score?

- ▶ Trên 6 chỉ số paper gốc (18 trường hợp): **SML thắng 10/18** — L1Norm chỉ thắng 8/18
- ▶ SML ổn định hơn trên PET (-0.065 vs -0.196)
- ▶ SML phù hợp lý thuyết hơn: đo sắc nét Laplacian, không chỉ chọn max tuyệt đối

Hai kết luận chính

(1) Sym-AG yếu nhất (-0.189) — xác nhận **bất đối xứng** hiệu quả hơn đối xứng.

(2) CDDFuse-AG = **Comb-WAvG-SML** — mô hình đề xuất cuối cùng.

6 chỉ số tốt nhất — MRI-CT

CDDFuse-AG đứng **#1** trên cả 6 chỉ số SF · Qabf · AG · EI · QM · QMI:

Phương pháp	SF↑	Qabf↑	AG↑	EI↑	QM↑	QMI↑
NestFuse	29.032	0.372	7.539	74.942	0.0016	0.723
WaveFusion	34.761	0.625	8.502	85.732	0.0046	0.701
GeSeNet	35.660	0.629	8.766	88.337	0.0086	0.708
CDDFuse	40.317	0.618	9.616	96.017	0.0046	0.783
CDDFuse-AG	41.612	0.645	9.869	98.289	0.0094	0.810

- ▶ **SF** +1.3 so với CDDFuse — SML bảo toàn tần số cao tốt hơn phép cộng
- ▶ **QM** $\approx 2\times$ CDDFuse — chi tiết wavelet vượt trội rõ rệt
- ▶ Cạnh xương (CT) và mô mềm (MRI) **không chồng lấp** $\Rightarrow$ SML phân biệt nguồn tốt nhất

6 chỉ số tốt nhất — MRI-PET & MRI-SPECT

MRI-PET — CDDFuse-AG thắng 5/6:

	SF	Qabf	AG	EI	QM	QMI
GeSeNet	34.563	0.738	11.356	116.3	0.0158	0.614
CDDFuse	34.471	0.764	11.277	114.7	0.1230	0.802
Ours	35.619	0.765	11.863	120.5	0.1500	0.785

QM tăng **+21.9%**. CDDFuse thắng QMI vì Sum giữ toàn bộ thông tin chung.

MRI-SPECT — CDDFuse-AG thắng 3/6:

	SF	Qabf	AG	EI	QM	QMI
GeSeNet	22.327	0.726	7.059	71.3	0.0356	0.722
CDDFuse	21.845	0.750	6.792	68.5	0.0788	0.905
Ours	21.986	0.752	6.857	69.1	0.0870	0.919

QM tăng **+10.4%**; GeSeNet dẫn SF/AG/EI nhờ semantic-edge fusion.

Tổng kết 3 modality

CDDFuse-AG thắng **14/18 chỉ số** (6+5+3) so với CDDFuse chỉ thắng 1/18.

So sánh Z-score tổng hợp

Z-score theo modality (8 chỉ số):


Phương pháp	z CT	z PET	z SP	avg
NestFuse	-0.35	-0.39	-0.79	-0.51
WaveFusion	+0.13	-0.02	+0.06	+0.06
DDBFusion	+0.37	-0.11	+0.18	+0.15
CDDFuse	-0.01	+0.43	+0.44	+0.29
CDDFuse-AG	+0.31	+0.25	+0.48	+0.34

Xếp hạng 22 SOTA (22 chỉ số tổng):


#	Phương pháp	Z avg
1	MM-Net-Fusion	+1.028
2	CDDFuse (paper)	+0.926
3	MFS-Fusion	+0.688
... (22 phương pháp)		

Nhận xét

CDDFuse (pretrained) **#2/22** — backbone đủ mạnh để áp dụng cải tiến.



Hình: MRI-CT: CDDFuse-AG (khung xanh) giữ cạnh xương sắc nét nhất.



Hình: MRI-SPECT: bảo toàn cấu trúc MRI và thông tin chức năng SPECT.

Không có quy tắc duy nhất tối ưu cho mọi modality:

Modality	Tốt nhất	z
CT-MRI	CDDFuse-AG	+0.240
PET-MRI	CDDFuse $\approx$ Ours	$\sim +0.05$
SPECT-MRI	CDDFuse (Sum)	+0.897

Lý giải:

- ▶ CT: cạnh xương/mô mềm không chồng lấp — SML phân biệt tốt
- ▶ SPECT: đặc trưng thừa thớt — Sum đơn giản an toàn hơn

Ý nghĩa khoa học

Fusion strategy nên **điều chỉnh theo từng cặp modality**, không nên cố định một chiến lược chung.

Hướng mở rộng

Modality-aware routing: tự động chọn fusion rule dựa trên phân phối đặc trưng đầu vào.

Đóng góp chính:

1. **CDDFuse-AG**: WAvG + SML bất đối xứng, chỉ thêm **4.161 tham số**
2. **Ablation 3 giai đoạn**: 13 quy tắc, cơ sở thực nghiệm toàn diện
3. **Modality-Specificity**: phát hiện quy tắc tối ưu khác nhau theo modality
4. **Tính giản dị**: WAvG 1 tham số vượt nhiều quy tắc phức tạp

Kết quả nổi bật

- ▶ **14/18 chỉ số** SF/Qabf/AG/EI/QM/QMI
- ▶ CT-MRI: QM tăng **+104%** (0.0046→0.0094)
- ▶ **z-avg +0.344** — cao nhất trong nhóm so sánh

Hạn chế và hướng hiệu chỉnh

- (1) **SML không tham số học**: Nhạy nhiều PET/SPECT. Cải tiến: làm mịn Gaussian trước, hoặc cửa sổ thích nghi theo noise level.
- (2) **θ WAvG chung cho mọi modality**: Suboptimal với PET/SPECT (cần $\theta \approx 0$). Cải tiến: học modality-conditioned $[\theta_{CT}, \theta_{PET}, \theta_{SPECT}]$.
- (3) **Chưa reader study lâm sàng**: Chỉ số tự động cao không đảm bảo hữu ích cho bác sĩ.
- (4) **Fine-tune toàn mạng**: Chỉ train Fusion Layer, chưa end-to-end fine-tune trên Harvard.

THÔNG TIN LIÊN HỆ

Sinh viên: Đỗ Trung Kiên — MSSV 20224869

GVHD: TS. Phạm Đăng Hải · PGS. TS. Phạm Văn Hải

- ▶ **Email:** kien.dt224869@sis.hust.edu.vn
- ▶ **GitHub:** <https://github.com/kienvbhp872004/MMIF-CDDFuse-AG>

Xin chân thành cảm ơn Hội đồng đã lắng nghe!



HUST

THANK YOU !

