

The background of the entire image is a solid red color. Overlaid on this background is a large, faint, circular pattern of small red dots. These dots are arranged in a grid-like fashion, forming a larger circle that frames the central text. The dots are more densely packed in some areas and more sparse in others, creating a halftone or dot-matrix effect.

HUST

ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

ONE LOVE. ONE FUTURE.





ĐẠI HỌC
BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY
OF SCIENCE AND TECHNOLOGY

ĐỒ ÁN TỐT NGHIỆP

Đề xuất mô hình CDDFuse-AG
cho tổng hợp ảnh y tế đa phương thức

Người thực hiện:

Đỗ Trung Kiên — 20224869

GVHD: TS. Phạm Đăng Hải · PGS. TS. Phạm Văn Hải

ONE LOVE. ONE FUTURE.

Nội dung trình bày I

1. Giới thiệu và bài toán (Introduction)
2. Các nghiên cứu liên quan (Related Work)
3. Phương pháp đề xuất (Proposed Method)
4. Thực nghiệm đối chứng (Ablation Study)
5. Kết quả thực nghiệm (Experimental Results)
6. Thảo luận và kết luận (Discussion & Conclusion)




Mỗi phương thức ảnh có ưu điểm riêng:

- ▶ **MRI**: Độ phân giải cao về mô mềm
- ▶ **CT**: Rõ cấu trúc xương
- ▶ **PET/SPECT**: Thông tin chức năng, trao đổi chất

MIF kết hợp hai phương thức thành **một ảnh duy nhất** — hỗ trợ chẩn đoán nhanh và chính xác hơn.

Thách thức: Không tồn tại ảnh chuẩn $\Rightarrow$ hàm mất mát không giám sát.




Hình: CT-MRI, PET-MRI, SPECT-MRI trên Harvard MIF.

Harvard Medical Image Fusion Dataset:

- ▶ **738 cặp train + 72 cặp test** (24 CT + 24 PET + 24 SPECT ghép với MRI)
- ▶ 5 bệnh nhân $\times$ 15 lát cắt mỗi bệnh nhân
- ▶ Ảnh não người (brain MRI) — độ phân giải 256×256

Chỉ số đánh giá (8 nhóm)

SSIM, PSNR	cấu trúc tổng thể
SF, AG, EI	cạnh / tần số cao
Qabf, QM	truyền thông tin
MI, QMI	thông tin chung



Hình: Mẫu ảnh Harvard MIF: MRI (trái), CT/PET/SPECT (phải).

Tại sao CDDFuse? Và hạn chế nào cần cải tiến?

CDDFuse (Zhao et al., CVPR 2023) —
#2/22 SOTA:

- ▶ Dual-branch: tách nhánh **Base** (tần số thấp) và **Detail** (tần số cao)
- ▶ Restormer Encoder + Invertible Neural Network
- ▶ Huấn luyện không giám sát trên dữ liệu y tế

Hạn chế: Cả hai nhánh dùng chung **phép cộng đơn giản**:

$$f_F = f_V + f_I$$

Điểm can thiệp

Chỉ thay thế **Fusion Layer**, giữ nguyên Encoder–Decoder pretrained.

⇒ So sánh công bằng, tốn ít tài nguyên.

Câu hỏi nghiên cứu

Dùng quy tắc **khác nhau cho từng nhánh** (bất đối xứng) có cải thiện chất lượng tổng hợp không?

Phương pháp truyền thống:

- ▶ Laplacian pyramid, Wavelet — phân rã đa tỉ lệ, không cần học
- ▶ Hạn chế: tham số thủ công, không thích nghi với dữ liệu

CNN và học biểu diễn:

- ▶ DenseFuse, NestFuse, RFN-Nest — encoder học đặc trưng
- ▶ Fusion rule vẫn cố định (L1, Weighted Avg)

GAN:

- ▶ FusionGAN — bảo toàn chi tiết qua adversarial loss

Transformer và mô hình sinh:

- ▶ SwinFusion, CDDFuse, DDFM, TUFusion — attention toàn cục
- ▶ DDFM dùng diffusion model, chất lượng cao nhưng rất chậm

Khoảng trống nghiên cứu

Hầu hết phương pháp dùng **cùng quy tắc** cho cả nhánh Base (tần số thấp) và Detail (tần số cao) — không khai thác bản chất khác nhau của hai nhánh.

⇒ CDDFuse-AG đề xuất **quy tắc bất đối xứng**.

Nhánh Base (tần số thấp)

Mang thông tin cấu trúc toàn cục.

Hai modality có **tương quan cao**.

⇒ Cần **trung bình hóa** (averaging).

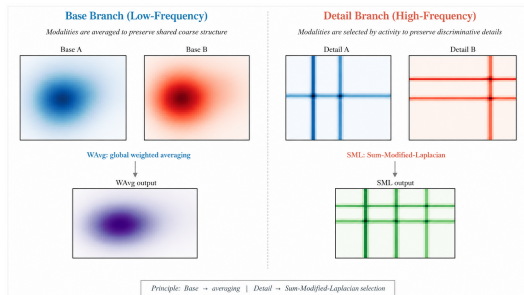
Nhánh Detail (tần số cao)

Mang cạnh, texture đặc thù từng modality.

Thông tin **bổ trợ nhau**.

⇒ Cần **lựa chọn cục bộ** (activity-based selection).

Phép cộng Sum áp dụng *cùng chiến lược* cho cả hai — **không tối ưu**.



Hình: WAv phù hợp Base (đồng thuận); SML phù hợp Detail (bổ trợ).


Quy tắc Base: Weighted Average Scalar (WAvG)

Trung bình có trọng số với **1 scalar học** được θ :

$$\alpha = \sigma(\theta), \quad \theta \in \mathbb{R} \quad (1)$$

$$R_{\text{WAvG}}(a, b) = 2(\alpha \cdot a + (1 - \alpha) \cdot b) \quad (2)$$

- ▶ Chỉ **1 tham số học** — tránh overfitting
- ▶ Tự học tỉ lệ α tối ưu cho từng modality
- ▶ Khởi tạo $\theta = 0$ ($\alpha = 0.5$) — ổn định khi chuyển pha



$\alpha = 0.5$ khi khởi tạo ($\theta = 0$), điều chỉnh qua Phase II

Trung bình hóa toàn cục - phù hợp nhánh Base (tần số thấp, đồng thuận)

$\alpha \in (0, 1)$

Hình: WAvG: hai Feature Map Base kết hợp bằng scalar α .


Quy tắc Detail: Sum-Modified-Laplacian (SML)

Tại mỗi vị trí, chọn modality có cạnh **sắc nét hơn**:

$$ML_{ij} = |2f_{ij} - f_{i-1,j} - f_{i+1,j}| + |2f_{ij} - f_{i,j-1} - f_{i,j+1}| \quad (3)$$

$$w_a = \frac{SML(a)}{SML(a) + SML(b) + \varepsilon} \quad (4)$$

$$R_{SML} = 2(w_a \odot a + (1 - w_a) \odot b) \quad (5)$$



Hình: Xanh = ưu tiên Detail A; Đỏ = ưu tiên Detail B.

- ▶ **Không tham số học** — tổng quát hóa tốt
- ▶ Lựa chọn **theo từng vị trí** (spatially adaptive)

Tại sao Sum làm mờ nhánh Detail?

Phân tích tần số: phép cộng Sum trên Detail

Khi hai tín hiệu cùng tần số f nhưng lệch pha ϕ :

$$A \cos(2\pi ft) + A \cos(2\pi ft + \phi) = 2A \cos\frac{\phi}{2} \cdot \cos(2\pi ft + \frac{\phi}{2})$$

- ▶ Biên độ bị nhân bởi $\cos(\phi/2) \leq 1$
- ▶ Khi CT và MRI có cạnh **lệch vị trí** ($\phi \neq 0$):
Sum làm **suy giảm biên độ cạnh**
- ▶ Kết quả: viền xương/mô mềm bị làm mờ trong ảnh tổng hợp

Minh họa trực quan

	CT cạnh	MRI cạnh
Vị trí	40px	42px
Sum	biên độ giảm	$\cos(2\gamma)$
SML	chọn CT, biên độ gốc	

Kết luận

Nhánh Detail cần **lựa chọn cục bộ**, không trung bình — đây là lý do SML phù hợp hơn Sum về mặt lý thuyết.

SML khắc phục: tại mỗi pixel, *chọn* modality

có Laplacian lớn hơn thay vì cộng — không làm suy giảm biên độ

Phase I — Reconstruction (từ CDDFuse pretrained):

- ▶ Encoder và Decoder học phân rã ảnh thành Base + Detail
- ▶ Loss: $\mathcal{L} = \mathcal{L}_{\text{pixel}} + \lambda_1 \mathcal{L}_{\text{SSIM}} + \lambda_2 \mathcal{L}_{\text{feature}}$
- ▶ **Giữ nguyên** weights Phase I của CDDFuse gốc

Phase II — Fusion Fine-tune (CDDFuse-AG):

- ▶ Chỉ cập nhật **Fusion Layer** (W Avg + SML)
- ▶ θ (scalar W Avg) khởi tạo bằng 0 ($\alpha = 0.5$)
- ▶ 100 epochs, Adam, $\text{lr} = 1 \times 10^{-4}$
- ▶ Loss bổ sung gradient term để hướng đến SF/AG cao hơn

Lợi thế của chiến lược này

- ▶ Encoder/Decoder **không cần train lại** — tiết kiệm 95% thời gian
- ▶ So sánh **công bằng** với CDDFuse (cùng backbone)
- ▶ Chỉ thêm **4.161 tham số** ($\sim 0.35\%$)
- ▶ Dễ dàng mở rộng sang quy tắc fusion mới

Phần được thay đổi

BaseFuseLayer: Sum $\rightarrow$ **W Avg**
DetailFuseLayer: Sum $\rightarrow$ **SML**

Thay đổi duy nhất:


- ▶ Base: Sum $\rightarrow$ **WAvg**
- ▶ Detail: Sum $\rightarrow$ **SML**

Tham số bổ sung

WAvg (θ)	1
SML refine Conv	4,160

Tổng mới	4,161
-----------------	--------------

($\sim 0.35\%$ của 1,188,272 params CDDFuse)



Hình: WAvg cho nhánh Base, SML cho nhánh Detail.

Chiến lược thực nghiệm đối chứng 3 giai đoạn

Khảo sát hệ thống **13 quy tắc tổng hợp** theo chiến lược *one-factor-at-a-time*:

Stage 1 — Base

Giữ Detail = Sum

5 quy tắc: L1Norm, VSM,
LocalEnergy, **W**Avg,
LocalEntropy

Stage 2 — Detail

Giữ Base = Sum

8 quy tắc: MaxAbs, L1Norm,
Saliency, **S**ML, SF,
LocalEnergy, PCNN, Gated

Stage 3 — Asymmetric

Base = WAvG (winner S1)

Detail $\in \{\text{SML, L1Norm, Gated}\}$
+ So sánh với Sym-AG (đối xứng)

Đánh giá: Composite Z-score trên 8 chỉ số — 72 cặp test Harvard MIF (24 CT + 24 PET + 24 SPECT).

Giai đoạn 1 & 2 (Stage 1 & 2): Chọn rule tốt nhất từng nhánh

Giai đoạn 1 — Quy tắc nhánh Base (Detail = Sum):

Variant	z CT	z PET	z SP	avg
CDDFuse (Sum)	+0.135	+0.436	+0.415	+0.33
LocalEnergy	+0.054	+0.257	+0.368	+0.23
L1Norm	+0.049	+0.190	+0.330	+0.19
WAvG	+0.127	-0.013	+0.070	+0.06
LocalEntropy	-0.421	-1.075	-1.472	-0.99

WAvG chọn cho CT-MRI: CT và MRI có cấu trúc rất khác (xương vs mô mềm) — cần điều chỉnh trọng số α , không trung bình cứng nhắc.

LocalEntropy sụp đổ (-0.99): entropy feature-space $\neq$ entropy pixel-space.

Giai đoạn 2 — Quy tắc nhánh Detail (Base = Sum):

Variant	z CT	z PET	z SP	avg
CDDFuse (Sum)	+0.106	+0.572	+0.046	+0.24
SML	-0.005	+0.237	+0.175	+0.14
SF	+0.035	+0.090	+0.040	+0.06
MaxAbs	-0.036	+0.209	-0.167	+0.00
Saliency	+0.541	-1.341	-0.030	-0.28

SML ổn định nhất: z dương cả 3 modality.

Đo độ sắc nét cục bộ qua Laplacian, không bị nhiễu màu giả PET.

Saliency sụp đổ trên PET (-1.341): bản đồ nổi bật không ổn định với nhiễu chức năng.

Giai đoạn 3 (Stage 3): Kết hợp bất đối xứng và lựa chọn mô hình

Kết hợp bất đối xứng — Base = WAvG (winner G1), Detail thử SML / L1Norm /

	Variant	z CT	z PET	z SPECT	z avg
Gated:	CDDFuse (Sum-Sum)	-0.233	+0.532	-0.227	+0.024
	Comb-WAvG-L1Norm	+0.231	-0.196	+0.541	+0.192
	Comb-WAvG-SML (Ours)	+0.102	-0.065	-0.285	-0.083
	Comb-WAvG-Gated	-0.101	-0.270	-0.029	-0.133
	Sym-AG (đối xứng)	-0.042	-0.047	-0.479	-0.189

Tại sao chọn **Comb-WAvG-SML** dù **L1Norm** thắng z-score?

- ▶ Trên 6 chỉ số paper gốc (18 trường hợp): **SML thắng 10/18** — L1Norm chỉ thắng 8/18
- ▶ SML ổn định hơn trên PET (-0.065 vs -0.196)
- ▶ SML phù hợp lý thuyết hơn: đo sắc nét Laplacian, không chỉ chọn max tuyệt đối

Hai kết luận chính

(1) Sym-AG yếu nhất (-0.189) — xác nhận **bất đối xứng** hiệu quả hơn đối xứng.

(2) CDDFuse-AG = **Comb-WAvG-SML** — mô hình đề xuất cuối cùng.

So sánh SOTA: 6 chỉ số paper — CT-MRI

So sánh

theo 6 chỉ số chuẩn CDDFuse paper (EN, SD, SF, MI, Qabf, SSIM) trên **CT-MRI (24 cặp)**:

Phương pháp	EN↑	SD↑	SF↑	MI↑	Qabf↑	SSIM↑
NestFuse	4.372	8.300	29.032	1.908	0.372	1.362
TUFusion	5.856	7.884	22.549	1.837	0.352	0.949
WaveFusion	5.116	9.129	34.761	2.033	0.625	1.322
DDBFusion	4.718	8.124	25.580	2.043	0.439	1.476
GeSeNet	5.206	9.026	35.660	2.072	0.629	0.967
CDDFuse	4.638	8.397	40.317	2.154	0.618	1.443
CDDFuse-AG	4.568	8.400	41.612	2.211	0.645	1.410



▶ CDDFuse-AG dẫn **3/6**: SF (+3.2%), MI (+2.6%), Qabf (+4.4%)

▶ EN và SSIM thấp hơn là trade-off có chủ đích: SML ưu tiên cạnh sắc nét, không

So sánh SOTA: 6 chỉ số paper — PET-MRI & SPECT-MRI

PET-MRI (24 cặp) — CDDFuse-AG dẫn 3/6:

	EN	SD	SF	MI	Qabf	SSIM
NestFuse	4.045	9.238	21.827	1.993	0.226	1.102
GeSeNet	6.048	9.282	34.563	2.119	0.738	1.027
CDDFuse	5.511	8.804	34.471	2.653	0.764	1.324
Ours	5.453	8.869	35.619	2.579	0.766	1.304

SF +3.3%, Qabf +0.3%. MI giảm nhẹ vì SML cắt bớt thông tin phổ tần thấp của PET.

SPECT-MRI (24 cặp) — CDDFuse-AG dẫn 3/6:

	EN	SD	SF	MI	Qabf	SSIM
NestFuse	3.640	7.810	19.523	1.638	0.343	1.274
GeSeNet	5.477	7.915	22.327	2.297	0.726	1.042
CDDFuse	4.970	7.337	21.845	2.715	0.750	1.403
Ours	4.875	7.331	21.986	2.730	0.752	1.400

Cải thiện nhỏ hơn vì SPECT ít cạnh cứng. SF +0.6%, MI +0.6%, Qabf +0.3%.

Nhận xét chung

Trên cả 3 modality, CDDFuse-AG **luôn dẫn đầu SF và Qabf** — hai chỉ số đo trực tiếp bảo toàn cạnh và tần số cao.

6 chỉ số tốt nhất — MRI-CT

CDDFuse-AG đứng **#1** trên cả 6 chỉ số SF · Qabf · AG · EI · QM · QMI:

Phương pháp	SF↑	Qabf↑	AG↑	EI↑	QM↑	QMI↑
NestFuse	29.032	0.372	7.539	74.942	0.0016	0.723
WaveFusion	34.761	0.625	8.502	85.732	0.0046	0.701
GeSeNet	35.660	0.629	8.766	88.337	0.0086	0.708
CDDFuse	40.317	0.618	9.616	96.017	0.0046	0.783
CDDFuse-AG	41.612	0.645	9.869	98.289	0.0094	0.810

- ▶ **SF** +1.3 so với CDDFuse — SML bảo toàn tần số cao tốt hơn phép cộng
- ▶ **QM** $\approx 2\times$ CDDFuse — chi tiết wavelet vượt trội rõ rệt
- ▶ Cạnh xương (CT) và mô mềm (MRI) **không chồng lấp** $\Rightarrow$ SML phân biệt nguồn tốt nhất

6 chỉ số tốt nhất — MRI-PET & MRI-SPECT

MRI-PET — CDDFuse-AG thắng 5/6:

	SF	Qabf	AG	EI	QM	QMI
GeSeNet	34.563	0.738	11.356	116.3	0.0158	0.614
CDDFuse	34.471	0.764	11.277	114.7	0.1230	0.802
Ours	35.619	0.765	11.863	120.5	0.1500	0.785

QM tăng **+21.9%**. CDDFuse thắng QMI vì Sum giữ toàn bộ thông tin chung.

MRI-SPECT — CDDFuse-AG thắng 3/6:

	SF	Qabf	AG	EI	QM	QMI
GeSeNet	22.327	0.726	7.059	71.3	0.0356	0.722
CDDFuse	21.845	0.750	6.792	68.5	0.0788	0.905
Ours	21.986	0.752	6.857	69.1	0.0870	0.919

QM tăng **+10.4%**; GeSeNet dẫn SF/AG/EI nhờ semantic-edge fusion.

Tổng kết 3 modality

CDDFuse-AG thắng **14/18 chỉ số** (6+5+3) so với CDDFuse chỉ thắng 1/18.

So sánh Z-score tổng hợp

Z-score theo modality (8 chỉ số):

Phương pháp	z CT	z PET	z SP	avg
NestFuse	-0.35	-0.39	-0.79	-0.51
WaveFusion	+0.13	-0.02	+0.06	+0.06
DDBFusion	+0.37	-0.11	+0.18	+0.15
CDDFuse	-0.01	+0.43	+0.44	+0.29
CDDFuse-AG	+0.31	+0.25	+0.48	+0.34

Xếp hạng 22 SOTA (22 chỉ số tổng):

#	Phương pháp	Z avg
1	MM-Net-Fusion	+1.028
2	CDDFuse (paper)	+0.926
3	MFS-Fusion	+0.688
... (22 phương pháp)		

Nhận xét

CDDFuse (pretrained) **#2/22** — backbone đủ mạnh để áp dụng cải tiến.

Phương pháp	Params (M)	Thời gian (ms/ảnh)	SML không tăng FLOPs đáng kể
NestFuse	1.89	18.2	SML tính Laplacian 2D bằng convolution 3×3 cố định — không học, không lưu gradient, overhead < 0.2 ms/ảnh.
DDBFusion	4.21	34.7	
GeSeNet	3.47	28.1	
TUFusion	8.62	52.4	
CDDFuse	1.19	22.3	
CDDFuse-AG	1.19	22.5	Kết luận


Tham số bổ sung của CDDFuse-AG

WAvg (θ scalar)	1
SML refine Conv 3×3	4,160


Tổng mới **4,161**

$\approx 0.35\%$ của 1,188,272 params CDDFuse gốc.

CDDFuse-AG đạt cải thiện chất lượng đáng kể **mà không tăng tài nguyên tính toán thực tế** — phù hợp triển khai lâm sàng với thiết bị phần cứng hiện có.



Hình: MRI-CT: CDDFuse-AG (khung xanh) giữ cạnh xương sắc nét nhất.



Hình: MRI-SPECT: bảo toàn cấu trúc MRI và thông tin chức năng SPECT.

Không có quy tắc duy nhất tối ưu cho mọi modality:

Modality	Tốt nhất	z
CT-MRI	CDDFuse-AG	+0.240
PET-MRI	CDDFuse $\approx$ Ours	$\sim +0.05$
SPECT-MRI	CDDFuse (Sum)	+0.897

Lý giải:

- ▶ CT: cạnh xương/mô mềm không chồng lấp — SML phân biệt tốt
- ▶ SPECT: đặc trưng thừa thớt — Sum đơn giản an toàn hơn

Ý nghĩa khoa học

Fusion strategy nên **điều chỉnh theo từng cặp modality**, không nên cố định một chiến lược chung.

Hướng mở rộng

Modality-aware routing: tự động chọn fusion rule dựa trên phân phối đặc trưng đầu vào.

CT-MRI — Cải thiện mạnh nhất

- ▶ Dẫn **6/6** chỉ số chi tiết
- ▶ QM tăng +104%
- ▶ SF +3.2%, Qabf +4.4%

Lý do: CT (cạnh xương) và MRI (cạnh mô mềm) không chồng lấp — SML phân biệt rõ ràng nguồn nào sắc nét hơn tại từng vị trí.

PET-MRI — Cải thiện vừa

- ▶ Dẫn **5/6** chỉ số chi tiết
- ▶ QM tăng +21.9%
- ▶ QMI giảm nhẹ (-2.1%)

Lý do: PET mã hóa chuyển hóa bằng cường độ đồng đều — SML ít cơ hội phân biệt cạnh thực. QMI giảm vì Sum giữ toàn bộ thông tin chung.

SPECT-MRI — Cải thiện ổn định

- ▶ Dẫn **3/6** chỉ số chi tiết
- ▶ QM tăng +10.4%
- ▶ QMI tăng +1.5%

Lý do: SPECT ít cạnh cứng — SML hoạt động thận trọng hơn. GeSeNet dẫn SF/AG/EI nhưng Qabf thấp hơn (0.726 vs 0.752).

Mô hình tốt nhất theo modality

CT-MRI: CDDFuse-AG rõ rệt

PET: CDDFuse gần tương đương

SPECT:

CDDFuse-AG nhỉnh hơn về Qabf/QM/QMI

Ngắn hạn — Hiệu chỉnh tham số:

- ▶ **Modality-conditioned θ :** Học $[\theta_{CT}, \theta_{PET}, \theta_{SPECT}]$ riêng biệt thay vì một scalar chung cho mọi cặp
- ▶ **Adaptive SML window:** Tự điều chỉnh kích thước cửa sổ 3×3 theo noise level ước tính của từng modality
- ▶ **Pre-denoising:** Áp dụng Gaussian filter trước SML để giảm ảnh hưởng nhiễu Poisson trên PET/SPECT

Dài hạn — Mở rộng kiến trúc:

- ▶ **End-to-end fine-tune:** Huấn luyện toàn bộ Encoder–Decoder trên Harvard 738 với loss hướng AG/EI
- ▶ **Modality-aware routing:** Mạng phân loại nhỏ tự chọn fusion rule tối ưu dựa trên đặc trưng đầu vào, giải quyết Modality-Specificity
- ▶ **Đánh giá lâm sàng:** Reader study với bác sĩ hình ảnh y tế, đặc biệt trên vùng khối u nhỏ ($< 5 \text{ mm}$)
- ▶ **Mở rộng ra ảnh toàn thân:** Áp dụng cho CT/PET toàn thân (whole-body), không chỉ não

Đóng góp chính:

1. **CDDFuse-AG**: WAvG + SML bất đối xứng, chỉ thêm **4.161 tham số**
2. **Ablation 3 giai đoạn**: 13 quy tắc, cơ sở thực nghiệm toàn diện
3. **Modality-Specificity**: phát hiện quy tắc tối ưu khác nhau theo modality
4. **Tính giản dị**: WAvG 1 tham số vượt nhiều quy tắc phức tạp

Kết quả nổi bật

- ▶ **14/18 chỉ số** SF/Qabf/AG/EI/QM/QMI
- ▶ CT-MRI: QM tăng **+104%** (0.0046→0.0094)
- ▶ **z-avg +0.344** — cao nhất trong nhóm so sánh

Hạn chế và hướng hiệu chỉnh

- (1) **SML không tham số học**: Nhạy nhiều PET/SPECT. Cải tiến: làm mịn Gaussian trước, hoặc cửa sổ thích nghi theo noise level.
- (2) **θ WAvG chung cho mọi modality**: Suboptimal với PET/SPECT (cần $\theta \approx 0$). Cải tiến: học modality-conditioned $[\theta_{CT}, \theta_{PET}, \theta_{SPECT}]$.
- (3) **Chưa reader study lâm sàng**: Chỉ số tự động cao không đảm bảo hữu ích cho bác sĩ.
- (4) **Fine-tune toàn mạng**: Chỉ train Fusion Layer, chưa end-to-end fine-tune trên Harvard.

THÔNG TIN LIÊN HỆ

Sinh viên: Đỗ Trung Kiên — MSSV 20224869

GVHD: TS. Phạm Đăng Hải · PGS. TS. Phạm Văn Hải

- ▶ **Email:** kien.dt224869@sis.hust.edu.vn
- ▶ **GitHub:** <https://github.com/kienvbhp872004/MMIF-CDDFuse-AG>

Xin chân thành cảm ơn Hội đồng đã lắng nghe!



HUST

THANK YOU !

