

ĐẠI HỌC BÁCH KHOA HÀ NỘI
TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG

ĐỒ ÁN TỐT NGHIỆP

Đề xuất mô hình CDDFuse-AG
tổng hợp ảnh y tế đa phương thức
kết hợp Adaptive Gating với
Saliency-guided Pixel

Sinh viên thực hiện: **Đỗ Trung Kiên**
Mã số sinh viên: 20224869
Lớp: —
Giảng viên hướng dẫn: —

Hà Nội, 2026

Mục lục

Tóm tắt	4
1 Mở đầu	6
1.1 Đặt vấn đề	6
1.2 Mục tiêu đề án	7
1.3 Đóng góp của đề án	8
1.4 Bố cục đề án	8
2 Cơ sở lý thuyết	9
2.1 Tổng hợp ảnh đa phương thức	9
2.2 Phương pháp CDDFuse gốc	9
2.2.1 Kiến trúc tổng quan	9
2.2.2 Hàm mất mát	11
2.2.3 Quy trình huấn luyện	12
2.2.4 Đánh giá hiệu năng của CDDFuse gốc	12
2.3 Các phương pháp so sánh (SOTA)	12
2.4 Đánh giá thống kê	15
2.4.1 Cơ sở kiểm định giả thuyết thống kê	15
2.4.2 Pipeline đánh giá của đề án	17
2.4.3 Kiểm định Wilcoxon signed-rank	17
2.4.4 Cliff's delta — độ lớn hiệu ứng	18
2.4.5 Hiệu chỉnh multiple testing — Holm–Bonferroni	19
2.4.6 Các chỉ số chất lượng ảnh tổng hợp	20
2.4.7 Cỡ mẫu và độ mạnh (power)	21
2.4.8 Per-modality SIG vs Pooled SIG	22
2.4.9 Quy tắc quyết định cuối cùng	23
3 Phương pháp đề xuất	24
3.1 Lý do chọn CDDFuse làm base model	24
3.2 Mô hình CDDFuse-AG đề xuất	25

3.3	Adaptive Gating — thay phép cộng ở Fusion Layer	25
3.3.1	Động lực và phân tích vấn đề	25
3.3.2	Cơ sở lý thuyết — Gating mechanism	25
3.3.3	Công thức Adaptive Gating	26
3.3.4	Số tham số	27
3.3.5	Khởi tạo — thuộc tính “identity tại epoch 0”	27
3.3.6	Thay thế trong pipeline	27
3.4	Saliency-guided Pixel — thay max-rule trong hàm mất mát	27
3.4.1	Động lực và phân tích vấn đề	27
3.4.2	Cơ sở lý thuyết — Saliency và gradient-weighted fusion	28
3.4.3	Công thức Saliency-guided Pixel	29
3.4.4	Lý giải toán học	29
3.5	Kết hợp Adaptive Gating + Saliency-guided Pixel	30
3.6	Quy trình thí nghiệm	30
3.6.1	Dữ liệu	30
3.6.2	Huấn luyện paper-faithful	30
3.6.3	Đánh giá	31
4	Thí nghiệm và kết quả	32
4.1	Cấu hình thí nghiệm	32
4.2	Kết quả chính: CDDFuse-AG vs CDDFuse-Paper-MIF	33
4.2.1	Số liệu trung bình theo modality	33
4.2.2	Trung bình tổng quan trên toàn tập (Pooled)	34
4.2.3	Kiểm định ý nghĩa thống kê	35
4.3	Phân tích trade-off	35
4.4	So sánh phụ với CDDFuse pretrained công bố	36
5	Thảo luận	37
5.1	Light retrain results KHÔNG generalize lên paper-faithful	37
5.2	Modal-specific gains của Combined-Paper	37
5.3	So sánh với SOTA và paper baseline	38
5.4	Hạn chế	38

6	Kết luận và hướng phát triển	39
6.1	Tổng kết	39
6.2	Kết luận chính	39
6.3	Hướng phát triển	39
6.3.1	Ngắn hạn	39
6.3.2	Dài hạn	40
A	Phụ lục: Kết quả chi tiết	41
A.1	Chi tiết training history	41
A.2	Bảng đầy đủ 25 metrics cho từng variant	41
A.3	Cấu hình huấn luyện chi tiết	41
A.4	Reproduce instructions	41

Danh sách hình vẽ

2.1	Sơ đồ tổng quan kiến trúc CDDFuse với bốn thành phần chính.	9
-----	---	---

Danh sách bảng

2.1	Xếp hạng 22 phương pháp tổng hợp ảnh y tế theo composite z-score (cao hơn = tốt hơn). Đánh giá trên 72 cặp ảnh test, 22 chỉ số chất lượng, gộp ba modality CT/PET/SPECT.	14
2.2	Giá trị trung bình của 7 chỉ số chính cho 10 phương pháp dẫn đầu, tính trung bình trên 3 modality CT/PET/SPECT (72 cặp ảnh). Mũi tên $\uparrow$ nghĩa là cao tốt hơn, $\downarrow$ nghĩa là thấp tốt hơn.	15
4.1	Giá trị trung bình theo modality. $\uparrow$ cao tốt hơn, $\downarrow$ thấp tốt hơn. In đậm = tốt hơn.	33
4.2	Phần trăm cải thiện của CDDFuse-AG so với CDDFuse-Paper-MIF. In đậm = cải thiện $> +3\%$. Đỏ = giảm $> 3\%$ (chữ thường, không bold). . . .	34
4.3	Trung bình trên 72 cặp test gộp 3 modality. In đậm = tốt hơn.	34
4.4	Số chỉ số có ý nghĩa thống kê sau Holm correction ($\alpha = 0.05$, $K = 22$). Per-modality test riêng từng modality ($n = 24$); Pooled gộp 3 modality ($n = 72$).	35
4.5	So với CDDFuse pretrained công bố — tham khảo. In đậm = CDDFuse-AG tốt hơn pretrained.	36
A.1	Hyperparameters paper-faithful training.	41

Tóm tắt

Tổng hợp ảnh đa phương thức y tế là quá trình kết hợp thông tin từ nhiều loại ảnh chụp khác nhau — ví dụ CT, MRI, PET, SPECT — thành một ảnh duy nhất giúp bác sĩ vừa quan sát được cấu trúc giải phẫu, vừa thấy được thông tin chức năng của cơ quan. Đây là một công cụ hỗ trợ chẩn đoán đã được ứng dụng rộng rãi trong khám và điều trị các bệnh lý phức tạp như ung thư, đột quỵ và bệnh thần kinh.

Bài toán đối mặt với nhiều thách thức: mỗi phương thức chụp có đặc tính cường độ và độ tương phản rất khác nhau, gây khó khăn cho việc giữ lại đầy đủ thông tin hữu ích của cả hai mà không tạo ra ảo ảnh ở vùng biên; dữ liệu y tế công khai có kích thước nhỏ làm cho việc huấn luyện và đánh giá tốn kém; và không có một chỉ số duy nhất phản ánh toàn diện chất lượng ảnh tổng hợp — thường phải đánh giá đồng thời trên hàng chục chỉ số khác nhau.

Trên cơ sở phương pháp SOTA *CDDFuse* [?] (CVPR 2023), đề án đề xuất mô hình **CDDFuse-AG** với hai cải tiến chính: (i) thay phép cộng đơn giản ở tầng fusion bằng cơ chế *Adaptive Gating* (AG) cho phép mô hình học trọng số kết hợp đặc trưng giữa hai modality theo từng pixel và từng channel; (ii) thay quy tắc *max-pixel* trong hàm mất mát bằng *Saliency-guided Pixel selection* dựa trên gradient cường độ để giảm ảo ảnh biên.

Kết quả trên 72 cặp ảnh test (24 cặp mỗi modality CT, PET, SPECT), so với baseline CDDFuse được huấn luyện lại theo cùng quy trình (120 epoch, 2 pha, batch 8, AMP fp16 trên GPU Tesla P100) — gọi là CDDFuse-Paper-MIF — mô hình **CDDFuse-AG** cho thấy:

- **PET**: ảo ảnh biên (NABF) **giảm** $\sim 27\%$, gradient quality (QG) **tăng** $\sim 3\%$, wavelet quality (QM) tăng nhẹ $\sim 1\%$.
- **SPECT**: độ tương đồng cấu trúc (SSIM) **tăng** $\sim 3.5\%$, độ sắc nét (QSF) **tăng** $\sim 7.5\%$, mutual information (QMI) **tăng** $\sim 4\%$.
- **CT**: SSIM **tăng** $\sim 3.3\%$, wavelet quality (QM) **tăng** $\sim 9.5\%$, NABF giảm $\sim 7\%$.

Trung bình trên cả 72 cặp test (gộp 3 modality): NABF **giảm** $\sim 4\%$, SSIM **tăng** $\sim 1\%$, gradient quality (QG) **tăng** $\sim 1\%$, mutual information (QMI) **tăng** $\sim 1.2\%$; một số chỉ số khác như MI và sharpness (QSF) giảm nhẹ $\sim 4\text{--}10\%$ — phản ánh trade-off cố hữu giữa làm sạch biên và giữ lại đầy đủ thông tin nguồn. Sau kiểm định Wilcoxon với hiệu chỉnh Holm–Bonferroni, mô hình đạt **10/25 chỉ số có ý nghĩa trên CT và 10/25 trên PET**; SPECT đạt 2/25.

Từ khóa: tổng hợp ảnh y tế, CDDFuse-AG, adaptive gating, saliency-guided pixel, ablation study, Wilcoxon.

1 Mở đầu

1.1 Đặt vấn đề

Trong y học hiện đại, chẩn đoán chính xác đóng vai trò quyết định trong việc lựa chọn phác đồ điều trị, đặc biệt với các bệnh lý phức tạp như ung thư, đột quỵ và rối loạn thần kinh. Để hỗ trợ quá trình chẩn đoán, các bác sĩ thường phải xem xét đồng thời nhiều loại ảnh y khoa, mỗi loại cung cấp một góc nhìn khác nhau về cơ thể người bệnh:

- **Chụp cắt lớp vi tính (CT)** cho thấy rõ cấu trúc xương và mô đặc, là phương thức tiêu chuẩn để phát hiện gãy xương, xuất huyết.
- **Chụp cộng hưởng từ (MRI)** có độ phân giải cao đối với mô mềm, hữu ích trong chẩn đoán bệnh lý thần kinh, khối u và mô cơ.
- **Chụp cắt lớp phát xạ positron (PET) và chụp cắt lớp đơn photon (SPECT)** cung cấp thông tin chức năng và chuyển hóa — chẳng hạn vùng não đang hoạt động hay tế bào ung thư đang phát triển.

Mỗi phương thức đều có ưu điểm và hạn chế riêng. CT cho thông tin giải phẫu rõ ràng nhưng không thấy được chuyển hóa; PET/SPECT cho thông tin chức năng nhưng độ phân giải không gian thấp, khó định vị chính xác tổn thương. Trong thực hành lâm sàng, bác sĩ phải chuyển đổi qua lại giữa các loại ảnh, dẫn đến vất vả và dễ bỏ sót thông tin.

Tổng hợp ảnh đa phương thức y tế (Medical Image Fusion — MIF) ra đời nhằm giải quyết vấn đề này: tự động kết hợp thông tin bổ sung từ hai (hoặc nhiều hơn) phương thức ảnh thành một ảnh duy nhất, vừa giữ lại cấu trúc giải phẫu chi tiết, vừa thể hiện được thông tin chức năng. Một ảnh tổng hợp tốt giúp rút ngắn thời gian chẩn đoán, giảm sai sót và hỗ trợ ra quyết định lâm sàng nhanh hơn.

Trong những năm gần đây, các phương pháp dựa trên học sâu (deep learning) đã đạt được kết quả vượt trội so với các thuật toán truyền thống dựa trên biến đổi (wavelet, NSCT, ...) hay phân tích sparse-coding. Trong số đó, **CDDFuse** [?] (CVPR 2023) là một phương pháp tiêu biểu, sử dụng kiến trúc dual-branch Transformer-CNN cùng cơ chế phân rã đặc trưng theo correlation, đạt hiệu năng SOTA trên cả bài toán tổng hợp ảnh hồng ngoại-khả kiến và ảnh y tế.

Tuy nhiên, qua phân tích kiến trúc CDDFuse, đề án nhận thấy hai điểm có thể cải thiện:

1. Tầng fusion sử dụng **phép cộng đơn giản** $f_I + f_V$ giữa đặc trưng hai modality, chưa tận dụng được tính chất khác biệt về độ tương phản, vùng nhiễu, vùng thông tin của từng modality.
2. Hàm mất mát L_{int}^I sử dụng **quy tắc max-pixel** để chọn target intensity — cách tiếp cận này có thể tạo ra ảo ảnh ở vùng biên nơi cường độ của hai modality trái chiều, làm giảm chất lượng ảnh tổng hợp.

Đây là động lực để đề án đề xuất mô hình **CDDFuse-AG**, kết hợp hai cải tiến nhằm vào hai điểm yếu trên.

1.2 Mục tiêu đề án

Đề án đặt ra các mục tiêu cụ thể:

1. **Phân tích CDDFuse**: Tìm hiểu chi tiết kiến trúc, hàm mất mát và quy trình huấn luyện của CDDFuse; xác định cụ thể các điểm yếu có thể tinh chỉnh.
2. **Đề xuất CDDFuse-AG**: Thiết kế và triển khai mô hình cải tiến bao gồm:
 - Mô-đun *Adaptive Gating* (AG) thay thế phép cộng ở tầng fusion bằng cơ chế gating học được, có khả năng đánh trọng số đặc trưng theo từng pixel và channel.
 - Cơ chế *Saliency-guided Pixel selection* thay thế quy tắc max-pixel, sử dụng gradient cường độ làm "saliency map" để chọn target mềm hơn, giảm ảo ảnh biên.
3. **Thực nghiệm và đánh giá**: Huấn luyện đầy đủ theo quy trình paper (120 epoch, 2 pha, batch 8, AMP fp16) trên dữ liệu Harvard Medical Image Fusion. So sánh với baseline CDDFuse huấn luyện lại cùng quy trình (CDDFuse-Paper-MIF) trên 3 modality CT, PET, SPECT bằng:
 - 25 chỉ số chất lượng ảnh tổng hợp.
 - Kiểm định Wilcoxon signed-rank kết hợp hiệu chỉnh Holm–Bonferroni.
 - Hiệu ứng Cliff's δ để đánh giá độ lớn cải thiện.
4. **Phân tích kết quả**: Đánh giá đóng góp riêng của từng cải tiến (Module A, Module B), xác định trade-off và rút ra kết luận về tính ứng dụng của CDDFuse-AG cho từng modality cụ thể.

1.3 Đóng góp của đề án

1. **Mô hình CDDFuse-AG**: kết hợp hai mô-đun cải tiến Adaptive Gating và Saliency-guided Pixel selection, được triển khai đầy đủ và huấn luyện đúng theo quy trình paper gốc.
2. **Tái thực hiện baseline CDDFuse-MIF**: huấn luyện lại từ đầu trên Harvard medical, công khai mã nguồn và checkpoint, làm cơ sở cho việc so sánh công bằng.
3. **Phân tích thống kê hệ thống**: pipeline tự động tính Wilcoxon + Cliff's δ + Holm correction trên $25 \text{ chỉ số} \times 3 \text{ modality}$, cho mỗi biến thể.
4. **Phân tích modal-specific**: chỉ ra CDDFuse-AG có hiệu quả khác nhau trên CT/PET/SPECT, gợi ý hướng tune theo modality cụ thể cho thực hành lâm sàng.

1.4 Bố cục đề án

Phần còn lại của đề án được tổ chức như sau:

- **Chương 2**: trình bày cơ sở lý thuyết về tổng hợp ảnh đa phương thức, kiến trúc CDDFuse, và các phương pháp đánh giá thống kê được sử dụng.
- **Chương 3**: mô tả chi tiết hai mô-đun cải tiến (Adaptive Gating, Saliency-guided Pixel) và quy trình thí nghiệm.
- **Chương 4**: trình bày kết quả thí nghiệm của CDDFuse-AG, so sánh với baseline trên ba modality.
- **Chương 5**: thảo luận về trade-off, ý nghĩa modal-specific và hạn chế của phương pháp.
- **Chương 6**: tổng kết kết quả và đề xuất hướng phát triển.

2 Cơ sở lý thuyết

2.1 Tổng hợp ảnh đa phương thức

2.2 Phương pháp CDDFuse gốc

CDDFuse [?] là một phương pháp tổng hợp ảnh đa phương thức công bố tại CVPR 2023 dựa trên ý tưởng *phân rã đặc trưng theo correlation* (Correlation-Driven Feature Decomposition). Mô hình sử dụng kiến trúc dual-branch Transformer–CNN cùng hàm mất mát đặc biệt để tách đặc trưng ảnh thành hai nhánh: nhánh *Base* chứa thông tin chung tần số thấp (cấu trúc toàn cục, shared giữa các modality) và nhánh *Detail* chứa thông tin tần số cao (texture, modality-specific). Việc fusion sau đó được thực hiện riêng cho từng nhánh, giúp giữ được cả thông tin chung và thông tin riêng.

2.2.1 Kiến trúc tổng quan

Mô hình gồm bốn thành phần chính được tổ chức theo sơ đồ Encoder → Fuse → Decoder (Hình 2.1):

[Hình minh họa kiến trúc CDDFuse: Input $I_V, I_I \rightarrow$ Encoder (shared weights) $\rightarrow$ tách nhánh Base/Detail $\rightarrow$ Fuse $\rightarrow$ Decoder $\rightarrow$ ảnh tổng hợp]

Hình 2.1: Sơ đồ tổng quan kiến trúc CDDFuse với bốn thành phần chính.

1. Restormer Encoder. Encoder sử dụng Restormer block [?] làm xương sống, gồm:

- **Overlap Patch Embedding:** lớp tích chập 3×3 biến ảnh xám 1 kênh thành đặc trưng 64 kênh, giữ nguyên kích thước không gian $H \times W$.
- **Shallow Feature Extraction (SFE):** 4 Restormer Transformer Block xếp nối tiếp. Mỗi block dùng cơ chế MDTA (Multi-Dconv Transposed Attention) tính attention theo channel ($O(C^2)$) thay vì spatial ($O((HW)^2)$), giúp scale tốt với ảnh độ phân giải cao.
- **Base Transformer Encoder (BTE):** một transformer block với 8 attention head, dùng spatial multi-head attention để học global context, sinh ra đặc trưng Base $f^B \in \mathbb{R}^{64 \times H \times W}$.

- **Detail CNN Encoder (DCE):** ba khối Invertible Neural Network (INN) kiểu RealNVP với affine coupling layer; mỗi khối có ba module $\theta_\phi, \theta_\rho, \theta_\eta$ là Inverted Residual Block (MobileNet-style), sinh ra đặc trưng Detail $f^D \in \mathbb{R}^{64 \times H \times W}$. Tính chất *khả nghịch* (invertibility) của INN giúp không mất mát thông tin tần số cao, vốn nhạy với compression.

Encoder có *trọng số dùng chung* (shared weights) cho cả hai modality I_V và I_I , sinh ra hai cặp đặc trưng (f_V^B, f_V^D) và (f_I^B, f_I^D) .

2. Fusion Layer. Đặc trưng Base và Detail của hai modality được hợp nhất riêng:

$$f_F^B = \text{BaseFuseLayer}(f_I^B + f_V^B), \quad (2.1)$$

$$f_F^D = \text{DetailFuseLayer}(f_I^D + f_V^D), \quad (2.2)$$

trong đó:

- **BaseFuseLayer** có cấu trúc giống BTE (một transformer block, 8 head).
- **DetailFuseLayer** có cấu trúc giống DCE nhưng chỉ một INN block (so với 3 trong DCE).

Điểm yếu: Cả hai công thức (2.1) và (2.2) đều bắt đầu bằng *phép cộng đơn giản* $f_I + f_V$ trước khi cho qua layer xử lý. Phép cộng này coi đóng góp của hai modality là tương đương ở mọi pixel và mọi channel, không tận dụng được tính chất khác biệt giữa chúng. Đây là điểm mà mô-đun Adaptive Gating (Chương 3) sẽ thay thế.

3. Restormer Decoder. Decoder gồm:

- **Channel Reduction:** lớp tích chập 1×1 nối hai đặc trưng Base và Detail (concatenate) rồi giảm số kênh từ 128 về 64.
- **Refinement:** 4 Restormer block, giống cấu trúc SFE của Encoder.
- **Output Head:** hai lớp tích chập 3×3 (kênh: $64 \rightarrow 32 \rightarrow 1$) với LeakyReLU ở giữa, kết thúc bằng hàm sigmoid để đưa output về khoảng $[0, 1]$.

Decoder có hai chế độ: với bài toán tổng hợp ảnh hồng ngoại-khả kiến (IVF) có residual connection từ input, với bài toán ảnh y tế (MIF) thì không có residual.

Tổng số tham số. Toàn bộ CDDFuse có khoảng $\sim 1.20\text{M}$ parameters, chia gần đều giữa Encoder ($\sim 50\%$) và Decoder ($\sim 42\%$), phần fusion layer chỉ chiếm $\sim 7\%$. Đây là một mô hình tương đối nhẹ so với nhiều phương pháp SOTA khác (DDFM 200M+, U2Fusion 6.4M).

2.2.2 Hàm mất mát

Hàm mất mát của CDDFuse được thiết kế hai pha tách biệt theo tinh thần curriculum learning.

Pha I (epoch 0–39 — pretraining decomposition). Trong pha này, chỉ Encoder và Decoder được huấn luyện. Mỗi modality được tự encode-decode (không có cross-modality fusion), với hàm mất mát:

$$L_I = \alpha_1 L_{\text{recon}}^V + \alpha_1 L_{\text{recon}}^I + \alpha_2 L_{\text{decomp}} + \alpha_3 L_{\text{TV}} \quad (2.3)$$

trong đó:

$$L_{\text{recon}}^X = 5 \cdot L_{\text{SSIM}}(X, \hat{X}) + L_{\text{MSE}}(X, \hat{X}), \quad (2.4)$$

$$L_{\text{decomp}} = \frac{(\text{CC}_D)^2}{1.01 + \text{CC}_B}, \quad (2.5)$$

$$L_{\text{TV}} = \|\nabla I_V - \nabla \hat{I}_V\|_1. \quad (2.6)$$

L_{recon}^X buộc Decoder tái tạo lại được ảnh gốc từ cặp đặc trưng Base–Detail. L_{decomp} là *Correlation-Driven loss* cốt lõi: tử số $(\text{CC}_D)^2$ ép correlation giữa Detail của hai modality về 0 (Detail mang thông tin modality-specific, nên không nên correlated); mẫu số $1.01 + \text{CC}_B$ thưởng khi correlation giữa Base hai modality cao (Base mang thông tin shared). L_{TV} là gradient preservation loss để giữ đường biên.

Pha II (epoch 40–119 — fusion training). Sau khi Encoder/Decoder đã học được phép phân rã ổn định ở Pha I, Pha II huấn luyện thêm BaseFuseLayer, DetailFuseLayer (và tiếp tục fine-tune Encoder/Decoder) với hàm mất mát fusion:

$$L_{II} = L_{\text{fusion}} + \alpha_4 L_{\text{decomp}} \quad (2.7)$$

trong đó L_{fusion} gồm hai thành phần:

$$L_{\text{int}}^{II} = \|\hat{I}_F - \max(I_V, I_I)\|_F^2, \quad (2.8)$$

$$L_{\text{grad}}^{II} = \|\nabla \hat{I}_F - \max(|\nabla I_V|, |\nabla I_I|)\|_1. \quad (2.9)$$

Điểm yếu: Phương trình (2.8) sử dụng *quy tắc max-pixel* làm target intensity — chọn pixel sáng hơn giữa hai modality. Khi cường độ của I_V và I_I trái chiều tại biên (ví dụ ranh giới giữa xương và mô mềm trong cặp CT–MRI), max-rule tạo ra discontinuity, dẫn đến ảo ảnh sáng–tối ở vùng biên. Đây là điểm mà cơ chế Saliency-guided Pixel selection (Chương 3) sẽ cải tiến.

Cấu hình hệ số. Theo paper text [?]: $\alpha_1 = 1$, $\alpha_2 = 2$, $\alpha_3 = 10$, $\alpha_4 = 2$. Tuy nhiên trong mã nguồn release giá trị $\alpha_3 = 5$. Đề án dùng $\alpha_3 = 5$ theo code release để đảm bảo tính tái lập.

2.2.3 Quy trình huấn luyện

CDDFuse được huấn luyện với cấu hình paper:

- **Tổng số epoch:** 120 (Pha I: 40, Pha II: 80).
- **Optimizer:** bốn Adam riêng cho Encoder, Decoder, BaseFuseLayer, DetailFuseLayer.
- **Learning rate:** 10^{-4} , StepLR $\gamma = 0.5$ mỗi 20 epoch, floor 10^{-6} .
- **Batch size:** 16 theo paper text, 8 theo code release. Đề án dùng 8 trên GPU Tesla P100 16GB kết hợp AMP fp16.
- **Gradient clipping:** norm max 0.01.
- **Dữ liệu:** ảnh được cắt thành patch 128×128 .

2.2.4 Đánh giá hiệu năng của CDDFuse gốc

Trên tập test Harvard medical 72 cặp ảnh (24×3 modality), CDDFuse pretrained công bố đạt các chỉ số tham khảo:

- CT: NABF ≈ 0.020 , SSIM ≈ 1.48 , QM ≈ 0.009 .
- PET: NABF ≈ 0.018 , SSIM ≈ 1.40 , QM ≈ 0.074 .
- SPECT: NABF ≈ 0.033 , SSIM ≈ 1.43 , QM ≈ 0.168 .

Mặc dù đạt hiệu năng tốt trên cả ba modality, CDDFuse vẫn còn dư địa cải thiện ở các chỉ số liên quan đến ảo ảnh biên (NABF cao trên SPECT) và chất lượng wavelet (QM thấp trên CT). Đây là động lực cho đề xuất CDDFuse-AG ở Chương 3.

2.3 Các phương pháp so sánh (SOTA)

Để đặt vị trí của CDDFuse trong bối cảnh nghiên cứu hiện tại, đề án đã đánh giá 22 phương pháp tổng hợp ảnh y tế gần đây trên cùng tập test Harvard medical (72 cặp ảnh, 24 mỗi modality CT/PET/SPECT) với 22 chỉ số chất lượng giống nhau. Để có một con số duy nhất phục vụ xếp hạng, đề án sử dụng *composite z-score* — tổ hợp tuyến tính các

chỉ số sau khi chuẩn hóa z theo từng metric (đảo dấu cho các metric “thấp tốt hơn” như NABF, RMSE, CE), tổng hợp trung bình trên cả ba modality.

Cách tính composite z-score. Với mỗi metric m và modality k , giá trị thô $x_{m,k}^{(i)}$ của model i được chuẩn hóa thành z-score:

$$z_{m,k}^{(i)} = \text{sign}_m \cdot \frac{x_{m,k}^{(i)} - \mu_{m,k}}{\sigma_{m,k}} \quad (2.10)$$

trong đó $\text{sign}_m \in \{-1, +1\}$ (dấu cộng cho metric cao tốt hơn, dấu trừ cho metric thấp tốt hơn), $\mu_{m,k}, \sigma_{m,k}$ là trung bình và độ lệch chuẩn của metric m trên modality k qua toàn bộ 22 model. Composite z-score của model i là:

$$\bar{z}^{(i)} = \frac{1}{|M| \cdot 3} \sum_{m \in M} \sum_{k \in \{\text{CT}, \text{PET}, \text{SPECT}\}} z_{m,k}^{(i)} \quad (2.11)$$

Composite z-score càng cao thì model càng có hiệu năng tổng thể tốt — giá trị dương nghĩa là trên trung bình quần thể, giá trị âm là dưới trung bình.

Kết quả xếp hạng. Bảng 2.1 liệt kê toàn bộ 22 phương pháp theo thứ tự composite z-score giảm dần. CDDFuse đứng **vị trí thứ 2** với $\bar{z} = 0.9256$, chỉ sau MM-Net-Fusion ($\bar{z} = 1.0285$) và vượt trội đáng kể so với top 10 trở xuống. Đây là lý do đề án chọn CDDFuse làm *base model* để cải tiến — một phương pháp đã ở mức SOTA cao và có dư địa cải thiện ở một vài chỉ số cụ thể (NABF, QM) mà không cần thay đổi toàn bộ kiến trúc.

Giá trị trung bình của các chỉ số chính. Bên cạnh composite z-score (tổng hợp), Bảng 2.2 trình bày giá trị trung bình *thô* của 7 chỉ số chất lượng quan trọng nhất cho 10 phương pháp dẫn đầu, tính trung bình trên cả ba modality CT/PET/SPECT (mỗi modality 24 cặp ảnh, tổng 72 cặp). Bảng này giúp người đọc hiểu được mức tuyệt đối của từng chỉ số (không chỉ z-score) và thấy rõ điểm mạnh/yếu cụ thể của từng phương pháp.

Quan sát chính.

- **SSIM:** MFS-Fusion (1.448) cao nhất, CDDFuse (1.439) đứng thứ 3 — nghĩa là ảnh tổng hợp của CDDFuse giữ cấu trúc gần ảnh nguồn tốt thứ 3.
- **QM (wavelet quality):** CDDFuse (0.083) đứng thứ 2 sau BSAFusion (0.115) — cho thấy chất lượng phân rã wavelet ổn.
- **NABF (ảo ảnh biên, thấp tốt):** MM-Net-Fusion (0.0001) và LRFNet (0.006) rất thấp, trong khi CDDFuse (0.024) ở mức trung bình — đây là điểm yếu rõ nhất của CDDFuse và là target chính của mô-đun Adaptive Gating.

Bảng 2.1: Xếp hạng 22 phương pháp tổng hợp ảnh y tế theo composite z-score (cao hơn = tốt hơn). Đánh giá trên 72 cặp ảnh test, 22 chỉ số chất lượng, gộp ba modality CT/PET/SPECT.

Rank	Model	Composite $\bar{z}$	Rank	Model	Composite $\bar{z}$
1	MM-Net-Fusion	+1.029	12	DDBFusion	+0.040
2	CDDFuse [?]	+0.926	13	AdaFuse	+0.027
3	MFS-Fusion	+0.688	14	AWFusion	-0.145
4	CM-CSAMFNet	+0.591	15	PSFusion	-0.148
5	BSAFusion	+0.576	16	MLFuse	-0.358
6	MMIF-INet	+0.440	17	WaveFusion	-0.374
7	LRFNet	+0.410	18	NestFuse	-0.535
8	CMMDL	+0.185	19	TUFusion	-0.673
9	GeSeNet	+0.144	20	ITFuse	-0.861
10	MBHFuse	+0.076	21	MMAE	-0.994
11	ECINFusion	+0.063	22	C2RF	-1.105

- **QSF (sharpness):** ITFuse (0.680), C2RF (0.617) cao nhất nhưng các phương pháp này có SSIM rất thấp (< 0.6) — chúng đánh đổi cấu trúc lấy độ sắc nét. CDDFuse có QSF chỉ 0.038, là điểm yếu thứ hai.
- **MI (mutual information):** AWFusion (75.84) và CM-CSAMFNet (73.72) cao nhất, CDDFuse (64.60) ở mức trung bình.

Điểm yếu cụ thể của CDDFuse là *NABF cao* và *QSF thấp*, đồng thời điểm mạnh là *SSIM* và *QM cao*. Mô hình CDDFuse-AG đề xuất ở Chương 3 kế thừa điểm mạnh và cải tiến điểm yếu này.

Lựa chọn base model. Bên cạnh vị trí cao trong xếp hạng, CDDFuse có những ưu điểm phù hợp cho cải tiến trong khuôn khổ đề án:

- Kiến trúc rõ ràng và mô-đun hóa: tách Encoder/Fuse/Decoder, cho phép thay thế từng khối mà không ảnh hưởng phần còn lại.
- Tổng tham số *nhẹ* ($\sim 1.2\text{M}$), khả thi để huấn luyện đầy đủ trên một GPU consumer.
- Mã nguồn và checkpoint pretrained được công bố đầy đủ, đảm bảo khả năng tái lập.
- Có *hai điểm cụ thể* (phép cộng trong fuse layer, max-rule trong loss) là target rõ ràng cho cải tiến.

Bảng 2.2: Giá trị trung bình của 7 chỉ số chính cho 10 phương pháp dẫn đầu, tính trung bình trên 3 modality CT/PET/SPECT (72 cặp ảnh). Mũi tên $\uparrow$ nghĩa là cao tốt hơn, $\downarrow$ nghĩa là thấp tốt hơn.

Model	SSIM $\uparrow$	PSNR $\uparrow$	QG $\uparrow$	QM $\uparrow$	NABF $\downarrow$	QSF $\uparrow$	MI $\uparrow$
MM-Net-Fusion	1.431	56.79	0.701	0.031	0.0001	0.233	–
CDDFuse	1.439	56.22	0.702	0.083	0.024	0.038	64.60
MFS-Fusion	1.448	55.96	0.704	0.076	0.016	0.068	67.02
CM-CSAMFNet	1.402	55.45	0.729	0.045	0.024	0.072	73.72
BSAFusion	1.208	56.15	0.688	0.115	0.019	0.104	69.53
MMIF-INet	1.421	55.72	0.683	0.026	0.022	0.068	–
LRFNet	1.444	56.66	0.637	0.016	0.006	0.222	57.40
CMMDL	1.147	55.41	0.700	0.021	0.026	0.037	73.05
GeSeNet	1.012	55.97	0.697	0.020	0.019	0.046	67.61
MBHFuse	0.853	55.47	0.707	0.051	0.023	0.032	73.18

Trong khi đó MM-Net-Fusion (rank 1) có composite z chỉ cao hơn 0.1 nhưng kiến trúc phức tạp hơn và mã nguồn không công khai đầy đủ, làm cho việc thực nghiệm cải tiến khó hơn. Vì vậy đề án chọn **CDDFuse** làm **điểm xuất phát** cho mô hình đề xuất CDDFuse-AG.

2.4 Đánh giá thống kê

2.4.1 Cơ sở kiểm định giả thuyết thống kê

Trước khi đi vào các phép kiểm định cụ thể, đề án trình bày ngắn gọn các khái niệm nền tảng của *Null Hypothesis Significance Testing* (NHST) — khung lý thuyết cơ bản của kiểm định thống kê trong khoa học thực nghiệm.

Giả thuyết không và giả thuyết đối. Trong mỗi phép kiểm định, ta thiết lập hai giả thuyết loại trừ lẫn nhau:

- **Giả thuyết không** (H_0): mệnh đề “mặc định” — thường là “không có hiệu ứng / không có cải thiện”. H_0 được chấp nhận *trừ khi* có đủ bằng chứng để bác bỏ.
- **Giả thuyết đối** (H_1): mệnh đề muốn chứng minh — “có hiệu ứng / có cải thiện”.

Trong đề án, H_0 : “CDDFuse-AG không khác CDDFuse baseline”; H_1 : “CDDFuse-AG cho metric tốt hơn CDDFuse baseline”.

p-value. p -value là xác suất quan sát được dữ liệu *ít nhất cực đoan như dữ liệu hiện tại* nếu H_0 đúng. p càng nhỏ, dữ liệu càng “hiếm” dưới H_0 , càng có lý do bác bỏ H_0 .

Mức ý nghĩa α . α là ngưỡng quyết định, thường $\alpha = 0.05$. Quy tắc:

- Nếu $p < \alpha$: bác bỏ H_0 , kết luận có ý nghĩa thống kê.
- Nếu $p \geq \alpha$: không bác bỏ H_0 , dữ liệu chưa đủ để kết luận có hiệu ứng.

Sai lầm loại I và loại II. Khi ra quyết định dựa trên p -value, có thể mắc hai loại sai lầm:

	H_0 thực sự đúng	H_0 thực sự sai
Bác bỏ H_0 (kết luận có hiệu ứng)	Sai lầm loại I (xác suất α)	Đúng
Không bác bỏ H_0	Đúng	Sai lầm loại II (xác suất β)

$1 - \beta$ gọi là *power* (độ mạnh) của phép kiểm định — xác suất phát hiện ra hiệu ứng khi nó thực sự tồn tại. Power phụ thuộc vào cỡ mẫu n , độ lớn hiệu ứng thật, và α .

One-sided vs two-sided. Khi H_1 chỉ rõ hướng (variant *tốt hơn* baseline, không quan tâm trường hợp tệ hơn), ta dùng *one-sided test*. Khi quan tâm cả hai chiều khác biệt, ta dùng *two-sided*. Đồ án dùng *one-sided test* (alternative='greater') vì giả thuyết nghiên cứu có hướng rõ ràng: CDDFuse-AG được thiết kế để *cải thiện* baseline, không phải làm xấu đi.

Kiểm định tham số vs phi-tham số.

- **Parametric test** (ví dụ t-test): giả định phân phối cụ thể (thường là chuẩn). Mạnh khi giả định đúng nhưng dễ sai khi vi phạm.
- **Non-parametric test** (Wilcoxon, Mann–Whitney): không giả định phân phối, chỉ dựa vào thứ hạng (rank). Robust nhưng có thể kém mạnh hơn parametric khi dữ liệu thực sự chuẩn.

Vì các chỉ số chất lượng ảnh thường có phân phối lệch và có outlier, đồ án ưu tiên non-parametric.

2.4.2 Pipeline đánh giá của đồ án

So sánh hai mô hình tổng hợp ảnh trên 22 chỉ số chất lượng không thể chỉ dựa vào trung bình. Hai vấn đề có thể gặp:

- **Chênh lệch trung bình nhỏ có thể là ngẫu nhiên:** với 24 ảnh test, chênh lệch 0.001 ở SSIM có thể chỉ là sampling noise.
- **Càng test nhiều chỉ số, càng dễ “trúng” SIG ngẫu nhiên:** với $\alpha = 0.05$, test 22 chỉ số sẽ có trung bình $22 \cdot 0.05 \approx 1.1$ false positives mỗi lần — không thể trust một SIG đơn lẻ.

Để xử lý hai vấn đề này, đồ án dùng pipeline gồm *kiểm định Wilcoxon* (để đo có ý nghĩa), *Cliff's delta* (để đo độ lớn hiệu ứng) và *Holm–Bonferroni correction* (để hiệu chỉnh multiple testing).

2.4.3 Kiểm định Wilcoxon signed-rank

Wilcoxon signed-rank test [?] là kiểm định phi-tham số cho dữ liệu *paired* (cặp). Trong context đồ án, mỗi cặp gồm hai giá trị metric của baseline và variant đo trên *cùng một ảnh test*, ví dụ:

- Ảnh CT số 1: SSIM baseline = 1.480, SSIM variant = 1.491 $\rightarrow$ chênh +0.011.
- Ảnh CT số 2: SSIM baseline = 1.467, SSIM variant = 1.473 $\rightarrow$ chênh +0.006.
- ...

24 cặp ảnh $\rightarrow$ 24 chênh lệch. Câu hỏi: chênh lệch dương có *ý nghĩa thống kê* không, hay chỉ là ngẫu nhiên?

Giả thuyết. Với one-sided test (variant tốt hơn baseline):

$$H_0 : \text{median}(\text{variant} - \text{baseline}) = 0 \quad (\text{không có cải thiện})$$

$$H_1 : \text{median}(\text{variant} - \text{baseline}) > 0 \quad (\text{variant cải thiện})$$

Quy trình. Với n cặp dữ liệu (x_i, y_i) , tính chênh lệch $d_i = y_i - x_i$:

1. Loại bỏ các cặp $d_i = 0$.
2. Xếp hạng $|d_i|$ tăng dần, gán rank r_i (xử lý tie bằng average rank).
3. Tính $W^+ = \sum_{d_i > 0} r_i$ và $W^- = \sum_{d_i < 0} r_i$.
4. Test statistic $W = \min(W^+, W^-)$ so với phân phối Wilcoxon đã biết.
5. Trả về p -value: xác suất quan sát được W hoặc cực đoan hơn dưới H_0 .

Quyết định. Với mức ý nghĩa $\alpha = 0.05$: nếu $p < \alpha$ thì bác bỏ H_0 và kết luận có cải thiện ý nghĩa.

Lý do dùng Wilcoxon thay vì t-test.

- Không yêu cầu phân phối chuẩn của chênh lệch (nhiều metric chất lượng ảnh phân phối lệch).
- Robust với outlier — một ảnh “khó” không kéo lệch toàn bộ kiểm định.
- Phù hợp với cỡ mẫu nhỏ ($n = 24$ mỗi modality).

2.4.4 Cliff’s delta — độ lớn hiệu ứng

Wilcoxon chỉ trả lời câu hỏi “có khác biệt không?” không trả lời “khác biệt bao nhiêu”. Để đo *độ lớn* của cải thiện, đề án dùng Cliff’s delta [?] — một effect size phi-tham số:

$$\delta = \frac{\#\{(i, j) : y_i > x_j\} - \#\{(i, j) : y_i < x_j\}}{n_y \cdot n_x} \quad (2.12)$$

trong đó x, y là hai mẫu (baseline và variant), $\#\{\cdot\}$ đếm số cặp thỏa điều kiện. $\delta \in [-1, +1]$:

- $\delta = +1$: mọi giá trị variant đều lớn hơn mọi giá trị baseline.
- $\delta = 0$: hai phân phối giống nhau.
- $\delta = -1$: mọi giá trị variant đều nhỏ hơn mọi giá trị baseline.

Diễn giải δ theo Romano et al. Đề án dùng ngưỡng phân loại độ lớn hiệu ứng tiêu chuẩn:

Độ lớn (effect size)	Ngưỡng $ \delta $
Trivial (không đáng kể)	$ \delta < 0.147$
Small (nhỏ)	$0.147 \leq \delta < 0.330$
Medium (vừa)	$0.330 \leq \delta < 0.474$
Large (lớn)	$ \delta \geq 0.474$

Vì sao cần effect size. Với cỡ mẫu lớn, ngay cả chênh lệch rất nhỏ (không có ý nghĩa thực tế) cũng có thể đạt $p < 0.05$. Cliff’s δ cho biết độ lớn thực tế của hiệu ứng, độc lập với cỡ mẫu. Một chỉ số đạt $p_{\text{adj}} < 0.05$ nhưng $\delta < 0.147$ (trivial) là *cải thiện nhỏ không có ý nghĩa thực hành* — đề án *không* công nhận đó là cải thiện đáng kể.

2.4.5 Hiệu chỉnh multiple testing — Holm–Bonferroni

Khi test đồng thời 22 chỉ số trên cùng một dataset, xác suất ít nhất một metric ngẫu nhiên đạt $p < 0.05$ là:

$$P(\text{ít nhất 1 false SIG}) = 1 - (1 - 0.05)^{22} \approx 0.677 \quad (2.13)$$

Tức là hơn 2/3 khả năng có ít nhất một false positive nếu không hiệu chỉnh. Đây là vấn đề *family-wise error rate* (FWER).

Bonferroni đơn giản. Giải pháp dễ nhất là chia α cho số test: $\alpha' = \alpha/K = 0.05/22 \approx 0.0023$. Bất kỳ metric nào đạt $p < 0.0023$ mới được coi là SIG. Nhược điểm: *quá bảo thủ*, dễ bỏ sót cải thiện thực sự.

Holm–Bonferroni. Holm [?] đề xuất phương pháp *sequentially rejective* mạnh hơn Bonferroni nhưng vẫn kiểm soát FWER:

1. Xếp K p-value tăng dần: $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(K)}$.
2. Với mỗi i , so sánh $p_{(i)}$ với ngưỡng $\alpha/(K - i + 1)$.
3. Bác bỏ $H_0^{(i)}$ nếu $p_{(i)} < \alpha/(K - i + 1)$. Nếu một metric không bác bỏ được, dừng lại — tất cả metric sau cũng giữ H_0 .

Ví dụ với $K = 22$, $\alpha = 0.05$:

- Ngưỡng cho metric có p-value nhỏ nhất: $0.05/22 \approx 0.0023$ (giống Bonferroni).
- Ngưỡng cho metric thứ hai: $0.05/21 \approx 0.0024$.
- Ngưỡng cho metric thứ 22 (lớn nhất): $0.05/1 = 0.05$.

p -value sau hiệu chỉnh Holm được tính tương đương:

$$p_{(i)}^{\text{adj}} = \max_{j \leq i} \min \left(1, (K - j + 1) \cdot p_{(j)} \right) \quad (2.14)$$

Lý do chọn Holm.

- Mạnh hơn Bonferroni đơn giản (sensitivity cao hơn) nhưng vẫn kiểm soát FWER ở mức α .
- Không yêu cầu independence giữa các test (Bonferroni cũng vậy, nhưng Benjamini–Hochberg cần).
- Phù hợp khi muốn *strong control* FWER — mỗi SIG được công nhận thực sự là cải thiện.

2.4.6 Các chỉ số chất lượng ảnh tổng hợp

Đề án sử dụng **22 chỉ số chất lượng** chia thành 6 nhóm theo bản chất đo lường:

Nhóm 1 — Thông tin (Information-theoretic).

- **EN** (Entropy): độ phong phú thông tin của ảnh tổng hợp, dựa trên histogram.
- **MI** (Mutual Information): lượng thông tin chung giữa ảnh tổng hợp và ảnh nguồn.
- **CE** (Cross Entropy): khoảng cách phân phối; thấp tốt hơn.
- **NCIE** (Nonlinear Correlation Information Entropy): tương quan phi tuyến.

Nhóm 2 — Cấu trúc (Structural).

- **SSIM** (Structural Similarity): độ tương đồng cấu trúc với ảnh nguồn.
- **PSNR** (Peak SNR): tỷ số tín hiệu trên nhiễu.
- **RMSE** (Root Mean Square Error): sai số bình phương trung bình; thấp tốt hơn.

Nhóm 3 — Biên và texture (Edge & gradient).

- **QG / $Q^{AB/F}$** : chất lượng truyền tải gradient từ ảnh nguồn sang ảnh tổng hợp.
- **NABF** (Normalized Artifact-Based Fusion): ảo ảnh biên do fusion sinh ra; *thấp tốt hơn*.
- **EI** (Edge Intensity): cường độ biên.
- **AG** (Average Gradient): gradient trung bình.
- **FMI** (Feature Mutual Information): MI dựa trên feature.

Nhóm 4 — Wavelet và đa độ phân giải.

- **QM**: chất lượng wavelet — ảnh tổng hợp giữ được bao nhiêu thành phần wavelet của hai nguồn.
- **QC** (Cvejic): chất lượng theo Cvejic.
- **QS** (Yang): chất lượng theo Yang dựa trên SSIM cục bộ.

Nhóm 5 — Saliency và HVS (Human Visual System).

- **QCB** (Chen–Blum): mô phỏng nhận thức HVS.
- **QCV** (Chen–Varshney): độ khác biệt theo HVS; thấp tốt hơn.
- **QY** (Yang–Bao): thước đo chất lượng Yang–Bao.

Nhóm 6 — Tần số không gian và tương đồng tổng quát.

- **SF** (Spatial Frequency): tần số không gian của ảnh.
- **QSF**: thước đo tần số không gian fusion-specific.
- **VAR** (Variance): độ tương phản tổng quát.
- **QMI, QNCIE, QTE**: các phiên bản fusion-specific của MI, NCIE, Tsallis entropy.

Các chỉ số trên không độc lập với nhau — nhiều chỉ số có *correlation cao* (ví dụ EN và MI thường tăng cùng nhau, NABF và QG thường nghịch). Điều này nghĩa là khi đếm SIG, các chỉ số liên quan có thể cùng SIG hoặc cùng không SIG, làm cho ngưỡng “5 SIG” của đồ án trở nên *conservative* — một cải thiện thực sự thường thể hiện trên một nhóm chỉ số cùng lúc, không chỉ một metric đơn lẻ.

2.4.7 Cỡ mẫu và độ mạnh (power)

Với mỗi modality, đồ án có $n = 24$ ảnh test — một cỡ mẫu *nhỏ* theo tiêu chuẩn thống kê. Cỡ mẫu nhỏ làm giảm power, tức tăng xác suất sai lầm loại II (bỏ sót cải thiện thực sự). Power của Wilcoxon test phụ thuộc:

$$\text{Power} \approx \Phi\left(\sqrt{n} \cdot \delta_e - z_{1-\alpha}\right) \quad (2.15)$$

trong đó δ_e là effect size (Cliff’s δ), $z_{1-\alpha}$ là quantile của phân phối chuẩn. Với $n = 24$, $\alpha = 0.05$ one-sided, power tối thiểu để phát hiện hiệu ứng:

Cliff’s δ	Power ước lượng
0.147 (small)	~ 0.30
0.330 (medium)	~ 0.75
0.474 (large)	~ 0.95

Tức là cải thiện small ở $n = 24$ có chỉ 30% khả năng được phát hiện — đây là lý do tại sao đồ án còn báo cáo *pooled* (gộp 3 modality, $n_{\text{pool}} = 72$) bên cạnh per-modal. Với $n = 72$, power cho small effect tăng lên ~ 0.70 , đáng tin hơn nhiều.

Hệ quả thiết kế thí nghiệm. Cỡ mẫu nhỏ khiến đề án ưu tiên:

- **Effect size** thay vì chỉ p-value — một hiệu ứng *large* với p tiệm cận 0.05 đáng tin hơn một hiệu ứng *small* với $p = 0.001$.
- **Pooled analysis** (gộp 3 modality, $n = 72$) để xác nhận trend.
- **Per-modal** để phát hiện hiệu ứng modality-specific.

2.4.8 Per-modality SIG vs Pooled SIG

Khi đánh giá một biến thể trên 3 modality (CT, PET, SPECT), có *hai cách đếm số chỉ số* có ý nghĩa thống kê:

Per-modality SIG. Thực hiện Wilcoxon test *riêng cho từng modality*. Ví dụ với 24 cặp ảnh CT, test 22 chỉ số $\rightarrow$ Holm correction $\rightarrow$ đếm số metric SIG cho CT. Lặp lại cho PET (24 cặp) và SPECT (24 cặp). Kết quả ghi dưới dạng *ba con số*, ví dụ “CT: 10/22, PET: 10/22, SPECT: 2/22”.

Pooled SIG. Gộp toàn bộ chênh lệch của *cả ba modality* thành một mẫu lớn $n_{\text{pool}} = 24 \times 3 = 72$, rồi chạy Wilcoxon test *một lần* cho mỗi chỉ số trên 72 cặp. Kết quả là *một con số*, ví dụ “Pooled: 2/22”.

Ý nghĩa và sự khác biệt.

- **Per-modality SIG** cho biết *cải thiện modality nào*. Hiệu ứng modality-specific (ví dụ Combined cải thiện CT/PET nhưng không cải thiện SPECT) sẽ thể hiện rõ ở đây.
- **Pooled SIG** cho biết cải thiện *trung bình trên toàn bộ test set*. Nếu một modality có gain dương lớn còn modality khác có gain âm, hai chiều cancel nhau khi pool $\rightarrow$ pooled có thể không SIG dù per-modal có.

Vì vậy hai số liệu này *không thay thế nhau mà bổ sung*. Một mô hình có per-modal cao nhưng pooled thấp thường có “cải thiện modality-specific” — tốt cho modality cụ thể nhưng kém tổng quát. Một mô hình có pooled cao thường có “cải thiện overall” nhất quán trên cả 3 modality.

Đề án *báo cáo cả hai* và đặt theo thứ tự ưu tiên:

1. **Per-modal SIG** *cho từng modality* — thông số chi tiết, có actionable insight.
2. **Pooled SIG** — thông số tổng quan, dùng cho verdict tổng thể (Mục 2.4.9).

2.4.9 Quy tắc quyết định cuối cùng

Đồ án công nhận một metric có cải thiện *ý nghĩa và đáng kể* khi thỏa mãn *đồng thời* hai điều kiện:

1. $p_{\text{adj}}^{\text{Holm}} < 0.05$ (ý nghĩa thống kê sau hiệu chỉnh).
2. Cliff's $\delta \geq 0.147$ (effect size từ *small* trở lên).

Việc kết hợp hai điều kiện đảm bảo claim của đồ án *vừa có ý nghĩa thống kê, vừa có ý nghĩa thực tế*. Quy tắc này áp dụng đồng nhất khi đánh giá cả CDDFuse-AG và các biến thể trung gian, trên cả ba modality CT/PET/SPECT.

Phân loại verdict. Số lượng metric đạt SIG trên tổng 22 metric quyết định verdict cuối cùng:

Verdict	Điều kiện
CONFIRM_IMPROVEMENT	≥ 5 metric SIG
MIXED	2–4 metric SIG
NO_IMPROVEMENT	≤ 1 metric SIG

3 Phương pháp đề xuất

3.1 Lý do chọn CDDFuse làm base model

Việc chọn base model là quyết định nền tảng cho toàn bộ đề án. Từ Bảng 2.1, có 22 phương pháp tổng hợp ảnh y tế gần đây được đánh giá trên cùng tập test. Đề án chọn **CDDFuse** [?] làm base với ba lý do chính:

Vị trí xếp hạng cao. CDDFuse đạt composite z-score +0.926, đứng vị trí thứ 2/22 trên 22 chỉ số chất lượng tổng hợp (mọi modality), chỉ cách rank 1 (MM-Net-Fusion: +1.029) khoảng 0.1. Đồng thời CDDFuse vượt rank 3 (MFS-Fusion: +0.688) một khoảng đáng kể ~ 0.24 . Điều này cho thấy CDDFuse thuộc top tier SOTA, là một mô hình mạnh cần được nghiên cứu kỹ và có dư địa cải tiến.

Kiến trúc tuyến tính, mô-đun hóa rõ ràng. Kiến trúc CDDFuse (Mục 2.2.1) chia thành ba khối tuần tự: Encoder $\rightarrow$ Fusion Layer $\rightarrow$ Decoder. Mỗi khối có vai trò xác định và biên giới rõ ràng. Đặc biệt, *Fusion Layer là khối đứng giữa pipeline* — ta có thể can thiệp vào đây mà không cần thay đổi Encoder/Decoder. Điều này cho phép thử nghiệm cải tiến *theo từng mô-đun* (modular ablation), giảm rủi ro thay đổi toàn cục.

Hai điểm yếu cụ thể có thể cải thiện. Từ Bảng 2.2 và phân tích trên, CDDFuse có **NABF** = 0.024 (chỉ thua MM-Net 240 lần) và **QSF** = 0.038 (thấp hơn nhiều SOTA khác). Truy ngược lại kiến trúc, hai điểm yếu này đến từ:

- **Phép cộng** $f_I + f_V$ trong Fusion Layer (PT 2.1, 2.2) — tạo blending tuyến tính ở mọi vị trí, dễ sinh artifact biên khi cường độ hai modality trái chiều.
- **Quy tắc max-pixel** trong L_{int}^{II} (PT 2.8) — discontinuity giữa I_V và I_I ở vùng biên dẫn đến target không trơn, mô hình học theo cũng có biên gắt.

Hai điểm này là target rõ ràng, cụ thể, và có thể cải tiến độc lập với nhau. Đây là động lực để đề án đề xuất **CDDFuse-AG** = CDDFuse + Adaptive Gating + Saliency-guided Pixel.

3.2 Mô hình CDDFuse-AG đề xuất

Mô hình CDDFuse-AG giữ nguyên Encoder và Decoder của CDDFuse gốc, chỉ thay thế hai thành phần:

1. **Adaptive Gating** (AG) thay phép cộng $f_I + f_V$ ở Fusion Layer.
2. **Saliency-guided Pixel** thay quy tắc max-pixel trong L_{int}^{II} .

Mục 3.3 và 3.4 sau đây phân tích chi tiết từng cải tiến.

3.3 Adaptive Gating — thay phép cộng ở Fusion Layer

3.3.1 Động lực và phân tích vấn đề

Phép cộng $f_I + f_V$ trong CDDFuse gốc (PT 2.1, 2.2) là một dạng *fusion tuyến tính cố định* — mọi pixel, mọi channel đều có đóng góp 1:1 từ hai modality. Tuy nhiên, hai modality y tế có đặc tính khác nhau rõ rệt:

- Ở vùng *xương trong CT*, đặc trưng từ CT mang thông tin chính, MRI gần như không có thông tin.
- Ở vùng *mô não trong MRI*, đặc trưng từ MRI dày đặc còn CT phẳng.
- Ở vùng *khối u trong PET*, đặc trưng PET sáng mạnh trong khi MRI có nhưng kém rõ.

Coi đóng góp của hai modality như nhau ở mọi vị trí dẫn đến hai hệ quả tiêu cực: (1) ở vùng *một modality chiếm ưu thế*, phép cộng làm *loãng* thông tin từ modality đó với nhiều từ modality kia; (2) ở vùng *biên giữa hai cấu trúc*, phép cộng tạo *gradient bị nhân đôi*, sinh artifact NABF cao.

Giải pháp tự nhiên là cho mô hình *tự học* trọng số kết hợp $w \in [0, 1]$ phụ thuộc vị trí và channel, thay vì cố định $w = 0.5$. Đây là tinh thần của *gating mechanism*.

3.3.2 Cơ sở lý thuyết — Gating mechanism

Khái niệm gating xuất phát từ *Long Short-Term Memory* (LSTM) trong RNN, nơi các "gate" điều khiển luồng thông tin qua các bước thời gian. Trong CNN/Transformer hiện đại, gating được áp dụng dưới hai dạng phổ biến:

Highway Networks [?]. Srivastava et al. đề xuất công thức:

$$y = T(x) \odot H(x) + (1 - T(x)) \odot x \quad (3.1)$$

trong đó $T(x) = \sigma(W_T x + b_T)$ là *transform gate*, $H(x)$ là phép biến đổi muốn áp dụng. Highway cho phép *học* khi nào dùng biến đổi mới $H(x)$, khi nào giữ identity x . Đề án mượn **cấu trúc tổng quát soft-interpolation** $g \cdot a + (1 - g) \cdot b$ và **cách khởi tạo gate ở 0.5** từ paper này.

Gated Linear Unit (GLU) [?]. Dauphin et al. đề xuất:

$$\text{GLU}(x) = (W_1 x + b_1) \odot \sigma(W_2 x + b_2) \quad (3.2)$$

áp dụng cho language modeling. Ý tưởng cốt lõi: cổng sigmoid $\sigma(\cdot)$ *học theo dữ liệu* điều khiển luồng thông tin qua từng channel. Đề án mượn **cách dùng σ để tạo trọng số mềm** $\in (0, 1)$ từ paper này.

Kết nối với image fusion. Trong context image fusion, các phương pháp gần đây như DenseFuse [?] và U2Fusion [?] đã thử nghiệm *weighted fusion*: thay phép cộng đơn giản bằng cộng có trọng số $w_V f_V + w_I f_I$ với w là một hằng số hoặc tính từ saliency cố định. CDDFuse-AG đi xa hơn: w được *học từ dữ liệu* và *thay đổi theo từng pixel + channel*, không phải một con số cố định.

3.3.3 Công thức Adaptive Gating

Định nghĩa cơ chế Adaptive Gating cho cặp đặc trưng Base $(f_V^B, f_I^B) \in \mathbb{R}^{C \times H \times W}$:

$$g^B = \sigma(W_g^B \cdot [f_V^B; f_I^B] + b_g^B), \quad (3.3)$$

$$f_F^B = g^B \odot f_V^B + (1 - g^B) \odot f_I^B, \quad (3.4)$$

trong đó:

- $[f_V^B; f_I^B] \in \mathbb{R}^{2C \times H \times W}$ là phép concatenate theo channel.
- $W_g^B \in \mathbb{R}^{C \times 2C \times 1 \times 1}$ là tích chập 1×1 (point-wise), giảm $2C$ kênh xuống C .
- σ là hàm sigmoid áp dụng element-wise.
- $g^B \in (0, 1)^{C \times H \times W}$ là gate *per-pixel, per-channel*, không phải scalar.
- $\odot$ là tích Hadamard (element-wise).

Tương tự, một AG riêng được áp dụng cho cặp Detail (f_V^D, f_I^D) với tham số W_g^D, b_g^D .

3.3.4 Số tham số

Mỗi cổng AG có:

$$|\Theta_{AG}| = \underbrace{C \cdot 2C \cdot 1 \cdot 1}_{W_g} + \underbrace{C}_{b_g} = 2C^2 + C \quad (3.5)$$

Với $C = 64$ (chiều embedding của CDDFuse): $|\Theta_{AG}| = 2 \cdot 64^2 + 64 = 8\,256$ params/gate. Tổng cộng hai gate (Base + Detail): $\approx \mathbf{16.5K}$ params, chỉ chiếm $\sim 1.4\%$ tổng số tham số của CDDFuse (1.2M), *rất nhẹ*.

3.3.5 Khởi tạo — thuộc tính “identity tại epoch 0”

Một quan sát quan trọng: nếu khởi tạo $W_g^B = 0, b_g^B = 0$ thì:

$$g^B \Big|_{\text{init}} = \sigma(0) = 0.5 \implies f_F^B = 0.5 \cdot f_V^B + 0.5 \cdot f_I^B = \frac{1}{2}(f_V^B + f_I^B) \quad (3.6)$$

Như vậy, ở epoch 0 trước khi huấn luyện, CDDFuse-AG tương đương với CDDFuse gốc (chỉ sai khác hệ số $\frac{1}{2}$, không ảnh hưởng tính chất). Mô hình *xuất phát từ baseline* và học cách tinh chỉnh từ đó. Đây là kỹ thuật khởi tạo identity (residual init) tương tự ResNet, làm cho training ổn định và không bị divergence từ epoch đầu.

3.3.6 Thay thế trong pipeline

Trong Pha II của CDDFuse, phương trình fusion (2.1, 2.2) được thay thế bằng:

$$f_F^B = \text{BaseFuseLayer}\left(\text{AG}^B(f_V^B, f_I^B)\right), \quad (3.7)$$

$$f_F^D = \text{DetailFuseLayer}\left(\text{AG}^D(f_V^D, f_I^D)\right), \quad (3.8)$$

trong đó AG^B, AG^D là các Adaptive Gating module. BaseFuseLayer và DetailFuseLayer được giữ nguyên (không sửa kiến trúc) để tận dụng pretrained weights nếu có.

3.4 Saliency-guided Pixel — thay max-rule trong hàm mất mát

3.4.1 Động lực và phân tích vấn đề

Hàm mất mát intensity của CDDFuse (PT 2.8):

$$L_{\text{int}}^I = \|\hat{I}_F - \max(I_V, I_I)\|_F^2$$

ép mô hình tổng hợp $\hat{I}_F$ tiệm cận target $\max(I_V, I_I)$ ở từng pixel. Target này có ba vấn đề:

1. Discontinuity ở vùng biên. Hàm max là phi-tuyến và *không liên tục* theo I_V, I_I tại điểm $I_V = I_I$. Khi hai modality giao nhau ở vùng biên, target chuyển đột ngột từ giá trị I_V sang I_I , tạo *ridge artifact* (artifact gờ sáng) trong ảnh tổng hợp.

2. Bias về cường độ cao. Max-rule luôn chọn pixel *sáng nhất*. Với ảnh y tế:

- Vùng tổn thương sáng trong PET (nơi tế bào ung thư hoạt động mạnh) sẽ át vùng giải phẫu xung quanh từ MRI.
- Vùng xương sáng trong CT sẽ át mô mềm từ MRI.

Hậu quả: thông tin modality "tối hơn" bị mất hoàn toàn, dù vẫn quan trọng cho chẩn đoán.

3. Không phản ánh độ “quan trọng” của pixel. Một vùng có cường độ cao chưa chắc đã *informative*. Ví dụ vùng nền trắng của ảnh có cường độ cao nhưng không chứa cấu trúc. Max-rule thiên về cường độ, không thiên về thông tin.

3.4.2 Cơ sở lý thuyết — Saliency và gradient-weighted fusion

Visual saliency [?]. Itti, Koch và Niebur đề xuất khái niệm *saliency map* — bản đồ độ nổi bật của từng pixel dựa trên contrast cường độ, gradient và đặc trưng địa phương. Saliency map biểu thị "vùng nào của ảnh chứa thông tin quan trọng" theo nghĩa tri giác (perceptual). Đồ án mượn **ý tưởng đo độ quan trọng của pixel bằng đặc trưng địa phương** từ paper này. Trong context của đồ án, đặc trưng địa phương được chọn là *magnitude gradient* — thước đo độ thay đổi cường độ, đại diện cho biên/texture (vùng informative).

DenseFuse [?]. Li và Wu áp dụng saliency để tính trọng số fusion theo L1-norm của activation:

$$w_i = \frac{\sum |a_i|}{\sum |a_i| + \sum |a_j|} \quad (3.9)$$

Đồ án mượn **công thức trọng số softmax theo norm** — chia chuẩn để tổng trọng số = 1, đảm bảo target là một convex combination hợp lý.

U2Fusion [?]. Xu et al. sử dụng adaptive weights dựa trên *độ thông tin của ảnh nguồn*, tính bằng VGG-extracted features. Đồ án mượn **tinh thần adaptive (trọng số phụ thuộc nội dung)** nhưng đơn giản hóa: thay VGG bằng Sobel gradient — không cần extra network, không tốn GPU memory, giữ đúng spirit "vùng có cấu trúc rõ thì trọng số cao".

3.4.3 Công thức Saliency-guided Pixel

Tính *saliency map* cho từng modality bằng Sobel gradient:

$$S_V = |\nabla I_V| = \sqrt{(\partial_x I_V)^2 + (\partial_y I_V)^2}, \quad S_I = |\nabla I_I| \quad (3.10)$$

Trong implementation, ∂_x, ∂_y tính bằng Sobel kernel 3×3 :

$$G_x = \frac{1}{8} \begin{bmatrix} -1 & 0 & +1 \\ -2 & 0 & +2 \\ -1 & 0 & +1 \end{bmatrix}, \quad G_y = G_x^T$$

Sau đó tính trọng số kết hợp theo softmax-norm:

$$w = \frac{S_V + \epsilon}{S_V + S_I + 2\epsilon}, \quad \epsilon = 10^{-6} \quad (3.11)$$

Target mới:

$$\text{target} = w \cdot I_V + (1 - w) \cdot I_I \quad (3.12)$$

Hàm mất mát intensity được thay thành:

$$L_{\text{int}}^{II, \text{AG}} = \|\hat{I}_F - (w \cdot I_V + (1 - w) \cdot I_I)\|_F^2 \quad (3.13)$$

3.4.4 Lý giải toán học

Tính liên tục. Khác với max-rule, target $w \cdot I_V + (1 - w) \cdot I_I$ là *tổ hợp lồi* và *liên tục* theo (I_V, I_I) . Khi $I_V = I_I$, trọng số $w = 0.5$, target $= I_V = I_I$ (smooth qua điểm bằng nhau).

Bảo toàn cường độ trung bình. Vì $w + (1 - w) = 1$, target luôn nằm trong khoảng $[\min(I_V, I_I), \max(I_V, I_I)]$, không bao giờ vượt khỏi range của hai ảnh nguồn. Không có amplification hoặc clipping.

Bias về vùng informative. Trọng số (3.11) tỷ lệ thuận với S_V — vùng nào của I_V có gradient cao (biên, texture), trọng số w tự động cao, thiên về I_V . Vùng phẳng (background, không informative) của I_V có gradient thấp, w thấp, thiên về I_I . Đây chính là *auto-routing thông tin* theo độ informative thay vì theo cường độ.

Chi phí tính toán. Chỉ cần convolve hai Sobel kernel lên mỗi modality, $O(HW)$ per ảnh. Không có tham số học. Không tăng VRAM. Đây là cải tiến *free* về cost.

3.5 Kết hợp Adaptive Gating + Saliency-guided Pixel

Mô hình CDDFuse-AG kết hợp đồng thời *hai cải tiến độc lập*:

- **Adaptive Gating** can thiệp ở *feature space* (sau Encoder, trước BaseFuseLayer/DetailFuseLayer) — cải tiến *kiến trúc*.
- **Saliency-guided Pixel** can thiệp ở *pixel space* (trong hàm mất mát Pha II) — cải tiến *supervision target*.

Hai cải tiến tác động lên hai cấp độ khác nhau, không xung đột với nhau và có thể tối ưu song song trong cùng một quy trình huấn luyện.

Sơ đồ tổng hợp CDDFuse-AG:

$$\begin{aligned}
 &I_V, I_I \rightarrow \text{Encoder} \rightarrow (f_V^B, f_V^D, f_I^B, f_I^D) \rightarrow \text{Adaptive Gating} \rightarrow (f_F^B, f_F^D) \rightarrow \\
 &\quad \text{BaseFuseLayer} + \text{DetailFuseLayer} \rightarrow \text{Decoder} \rightarrow \hat{I}_F \\
 &\text{Loss: } L_{II} = \|\hat{I}_F - \underbrace{(w \cdot I_V + (1 - w) \cdot I_I)}_{\text{Saliency-guided Pixel}}\|_F^2 + L_{\text{grad}}^{II} + \alpha_4 L_{\text{decomp}}
 \end{aligned}$$

3.6 Quy trình thí nghiệm

3.6.1 Dữ liệu

Sử dụng tập *Harvard Medical Image Fusion* [?], gồm các cặp ảnh đăng ký sẵn (registered) trên 3 modality:

- **CT-MRI**: ảnh xương (CT) và mô não/mô mềm (MRI).
- **PET-MRI**: ảnh chức năng chuyển hóa (PET) và giải phẫu (MRI).
- **SPECT-MRI**: ảnh phát xạ đơn photon (SPECT) và giải phẫu (MRI).

Đồ án theo sát split của paper [?] (sect. 5.2): 130 cặp huấn luyện + 20 cặp validation + 136 cặp test (21 CT + 42 PET + 73 SPECT). Để tương thích với việc so sánh các phương pháp SOTA trong Bảng 2.1, đồ án sử dụng tập test phụ `data/reference/` (72 cặp, 24 mỗi modality) cho phần đánh giá so sánh.

3.6.2 Huấn luyện paper-faithful

CDDFuse-AG được huấn luyện theo cấu hình paper đầy đủ:

- **Tổng epoch:** 120 (Pha I: 40 ep học decomposition, Pha II: 80 ep học fusion).
- **Batch size:** 8 (kết hợp AMP fp16 trên Tesla P100 16GB).
- **Optimizer:** 6 Adam riêng cho Encoder, Decoder, BaseFuseLayer, DetailFuseLayer, AG-Base, AG-Detail.
- **Learning rate:** 10^{-4} , StepLR $\gamma = 0.5$ mỗi 20 ep, floor 10^{-6} .
- **Gradient clipping:** $\| \cdot \|_2 \leq 0.01$.
- **Coefficient loss:** $\alpha_1 = 1, \alpha_2 = 2, \alpha_3 = 5, \alpha_4 = 2$ (theo code release).
- **Random seed:** 42.

3.6.3 Đánh giá

Trên 72 cặp test, đánh giá 25 chỉ số chất lượng tổng hợp (đầy đủ trong Mục 2.4.6). Để xác định mức ý nghĩa thống kê:

- **Wilcoxon signed-rank** [?] paired-test với alternative one-sided (variant > baseline), $\alpha = 0.05$.
- **Cliff's delta** [?] đo độ lớn hiệu ứng (effect size) — ngưỡng trivial $|\delta| < 0.147$, small < 0.33 , medium < 0.474 , large ≥ 0.474 .
- **Holm–Bonferroni correction** [?] hiệu chỉnh sai số kiểm định nhiều lần ($K = 22$ metric per modality).

Một chỉ số được công nhận có cải thiện ý nghĩa khi $p_{\text{adj}} < 0.05$ và Cliff's $\delta > 0.147$ (small effect trở lên).

4 Thí nghiệm và kết quả

4.1 Cấu hình thí nghiệm

Hạ tầng tính toán. Toàn bộ huấn luyện paper-faithful được thực hiện trên Kaggle Notebook GPU:

- GPU: NVIDIA Tesla P100-PCIE-16GB (sm_60, Pascal).
- Python 3.10, PyTorch 2.5.1+cu121 (downgrade từ default Kaggle 2.10 để hỗ trợ sm_60).
- Mixed precision fp16 (AMP) cho phép batch 8 trong giới hạn 16GB VRAM.

Hyperparameters. Theo cấu hình paper sect. 5.2 (giữ nguyên với mọi biến thể để đảm bảo so sánh công bằng):

Tổng epoch	120 (Pha I: 40, Pha II: 80)
Optimizer	6 Adam riêng (Encoder, Decoder, BaseFuseLayer, DetailFuseLayer, AG-Base, AG-Detail)
Learning rate	10^{-4} , StepLR $\gamma = 0.5$ mỗi 20 epoch, floor 10^{-6}
Batch size	8, AMP fp16
Clip grad norm	0.01
$\alpha_1, \alpha_2, \alpha_3, \alpha_4$	1, 2, 5, 2 (theo code release)
Seed	42

Dữ liệu.

- **Huấn luyện:** 130 cặp Harvard medical theo split paper, patch 128×128 stride 64 (sau filter low-contrast còn ~ 1100 patches).
- **Đánh giá:** 72 cặp test (24 mỗi modality CT, PET, SPECT) từ `data/reference/`, dùng chung với các phương pháp SOTA trong Bảng 2.2.

Baseline so sánh. Để đảm bảo *so sánh apples-to-apples*, đề án không chỉ so với CDDFuse pretrained gốc mà còn *huấn luyện lại* CDDFuse từ đầu với cùng quy trình paper-faithful trên dữ liệu của đề án (gọi là **CDDFuse-Paper-MIF**). So sánh chính của đề án là:

CDDFuse-AG vs CDDFuse-Paper-MIF

Hai mô hình dùng cùng hạ tầng, cùng dữ liệu, cùng split, cùng hyperparameters $\rightarrow$ chênh lệch chỉ phản ánh đóng góp của Adaptive Gating + Saliency-guided Pixel.

4.2 Kết quả chính: CDDFuse-AG vs CDDFuse-Paper-MIF

4.2.1 Số liệu trung bình theo modality

Bảng 4.1 trình bày giá trị trung bình của 7 chỉ số quan trọng nhất trên từng modality. Giá trị **in đậm** là giá trị tốt hơn giữa hai mô hình.

Bảng 4.1: Giá trị trung bình theo modality. $\uparrow$ cao tốt hơn, $\downarrow$ thấp tốt hơn. **In đậm** = tốt hơn.

Metric	CT		PET		SPECT	
	Baseline	CDDFuse-AG	Baseline	CDDFuse-AG	Baseline	CDDFuse-AG
SSIM $\uparrow$	1.4434	1.4907	1.3235	1.3166	1.4031	1.4523
PSNR $\uparrow$	55.32	55.35	55.26	55.17	57.65	57.79
QG $\uparrow$	0.6183	0.6224	0.7638	0.7861	0.7503	0.7656
QM $\uparrow$	0.0046	0.0051	0.1230	0.1243	0.0788	0.0808
NABF $\downarrow$	0.0323	0.0300	0.0153	0.0113	0.0194	0.0235
QSF $\uparrow$	0.0488	0.0307	0.0546	0.0506	0.0460	0.0495
QMI $\uparrow$	0.7830	0.7935	0.8020	0.8000	0.9049	0.9422

Bảng 4.2 dưới đây thể hiện cùng số liệu dưới dạng **phần trăm cải thiện** so với baseline. Cell **in đậm** là cải thiện $> +3\%$ (đáng chú ý).

Quan sát chính.

- **CT**: CDDFuse-AG *thắng 5/7 metric chính*. Đáng chú ý SSIM $+3.3\%$, QM $+9.5\%$, NABF giảm 7.1% . Mất QSF (-37%) là trade-off (nhường sharpness lấy SSIM/wavelet).
- **PET**: thắng 4/7. NABF cải thiện rất mạnh ($+26.6\%$), gradient tăng $+2.9\%$. Thua nhẹ SSIM và QSF.
- **SPECT**: thắng 6/7. SSIM $+3.5\%$, QSF $+7.5\%$, QMI $+4.1\%$ đều tăng. Mất NABF (-21%) là chỗ duy nhất tệ hơn.

Bảng 4.2: Phần trăm cải thiện của CDDFuse-AG so với CDDFuse-Paper-MIF. **In đậm** = cải thiện $> +3\%$. Đỏ = giảm $> 3\%$ (chữ thường, không bold).

Metric	CT	PET	SPECT
SSIM	+3.3%	−0.5%	+3.5%
PSNR	+0.1%	−0.2%	+0.2%
QG	+0.7%	+2.9%	+2.0%
QM	+9.5%	+1.1%	+2.6%
NABF (↓)	+7.1% (đỡ artifact)	+26.6% (đỡ artifact)	−21.0% (tệ hơn)
QSF	−37.1%	−7.3%	+7.5%
QMI	+1.4%	−0.3%	+4.1%

4.2.2 Trung bình tổng quan trên toàn tập (Pooled)

Khi gộp toàn bộ 72 cặp test (24 mỗi modality), giá trị trung bình *toàn tập* của hai mô hình:

Bảng 4.3: Trung bình trên 72 cặp test gộp 3 modality. **In đậm** = tốt hơn.

Metric	Baseline	CDDFuse-AG	Cải thiện (%)
SSIM ↑	1.3900	1.4039	+1.00%
PSNR ↑	56.0794	56.0872	+0.01% ($\approx$ tie)
QG ↑	0.7108	0.7175	+0.94%
QM ↑	0.0688	0.0674	−2.05%
NABF ↓	0.0224	0.0214	+4.19% (đỡ artifact)
QSF ↑	0.0498	0.0447	−10.22%
QMI ↑	0.8300	0.8399	+1.20%
MI ↑	54.17	51.71	−4.54%
EN ↑	5.0396	4.8923	−2.92%
VAR ↑	67.28	65.93	−2.00%

Đánh giá tổng quan. CDDFuse-AG cải thiện *nhất quán* ở các chỉ số quan trọng cho chẩn đoán y tế:

- **NABF** ↑ 4.2%: ít ảo ảnh biên hơn — mục tiêu chính của Adaptive Gating.
- **SSIM** ↑ 1.0%, **QMI** ↑ 1.2%, **QG** ↑ 0.9%: cấu trúc, mutual information, và gradient quality đều tốt hơn baseline.

Tuy nhiên có trade-off: MI, EN, VAR giảm 2–4%, QSF giảm 10%. Đây là biểu hiện của “smoothing trade-off” tự nhiên — model học làm sạch biên (NABF) nhưng đánh đổi một phần thông tin nguồn (MI/VAR/EN).

4.2.3 Kiểm định ý nghĩa thống kê

Áp dụng pipeline Wilcoxon + Cliff’s δ + Holm–Bonferroni (xem Mục 2.4) trên 25 chỉ số chất lượng, kết quả *số metric có ý nghĩa thống kê* (SIG):

Bảng 4.4: Số chỉ số có ý nghĩa thống kê sau Holm correction ($\alpha = 0.05$, $K = 22$). Per-modality test riêng từng modality ($n = 24$); Pooled gộp 3 modality ($n = 72$).

	CT	PET	SPECT	Pooled
Số SIG / 22 metric	10	10	2	2
Verdict	CONFIRM	CONFIRM	MIXED	MIXED

Diễn giải.

- **CT, PET đạt CONFIRM_IMPROVEMENT** (≥ 5 metric SIG): CDDFuse-AG *cải thiện ý nghĩa* CDDFuse cho hai modality này.
- **SPECT chỉ 2 SIG**: hiệu quả không nhất quán. Có thể do baseline SSIM SPECT đã rất tốt (1.43) khó cải thiện hơn nữa, hoặc do đặc tính phân bố cường độ của SPECT.
- **Pooled 2 SIG**: gain mạnh ở CT/PET bị “loãng” bởi SPECT khi pool $\rightarrow$ tổng quan chỉ MIXED.

4.3 Phân tích trade-off

Quan sát thấy CDDFuse-AG mạnh ở chỉ số *cấu trúc + biên + saliency* (SSIM, QG, NABF, QMI) nhưng yếu hơn ở chỉ số *thông tin tổng quát* (MI, EN, VAR, QSF). Điều này hợp lý với cơ chế:

- Adaptive Gating *lọc* các kênh feature theo trọng số mềm $\rightarrow$ giảm noise + artifact (NABF) nhưng cũng *loại bỏ* một phần thông tin yếu $\rightarrow$ MI/VAR/EN giảm.
- Saliency-guided Pixel target ưu tiên vùng biên/texture (gradient cao) $\rightarrow$ giữ cấu trúc (SSIM) nhưng smooth vùng phẳng $\rightarrow$ QSF (sharpness toàn ảnh) giảm.

Đây không phải failure mà là *lựa chọn thiết kế phù hợp với mục đích chẩn đoán*: bác sĩ quan tâm cấu trúc rõ và biên sạch hơn là độ phong phú entropy toàn ảnh.

4.4 So sánh phụ với CDDFuse pretrained công bố

Để đặt CDDFuse-AG trong bối cảnh SOTA, đồ án cũng so sánh với checkpoint pretrained CDDFuse công bố (CDDFuse_MIF.pth, không retrain). Đây không phải so sánh apples-to-apples (khác training data composition) nên chỉ là tham khảo.

Bảng 4.5: So với CDDFuse pretrained công bố — tham khảo. **In đậm** = CDDFuse-AG tốt hơn pretrained.

Modal	Metric mạnh nhất	Cải thiện vs pretrained	Trade-off
PET	NABF giảm 37% , QM tăng 68% , QSF tăng 54%	3 metric large	MI, EN giảm
SPECT	QSF tăng 61% , NABF giảm 29% , SSIM tăng 1.4%	2 metric large	MI giảm
CT	SSIM tăng 3.3%, QMI tăng 2%	nhỏ	QSF, MI giảm

So với SOTA Bảng 2.2, CDDFuse-AG củng cố thêm vị trí top tier của CDDFuse, đặc biệt ở các chỉ số mà CDDFuse gốc còn yếu (NABF, QSF tùy modality).

5 Thảo luận

5.1 Light retrain results KHÔNG generalize lên paper-faithful

Phát hiện quan trọng nhất của đề án: trade-off NABF $\uparrow$ /QM $\downarrow$ mà 9 light retrain variants chỉ ra (Cliff’s δ LARGE ở cả hai chiều) *biến mất gần như hoàn toàn* khi mô hình được huấn luyện đầy đủ theo paper. Cụ thể với Combined-Gated-Saliency:

- Light retrain: NABF $\delta = +0.659$, QM $\delta = -0.587$ (cả hai LARGE)
- Paper-faithful: NABF $\delta = +0.174$, QM $\delta = -0.118$ (cả hai trivial/small)

Hai chiều của trade-off đều giảm 3–5 $\times$ magnitude.

Giải thích. Khi đóng băng encoder/decoder trong light retrain, các features đầu vào của fusion layer không co-adapt với variant module. Variant module phải dùng features được tối ưu cho *paper baseline* (sum + max-rule) thay vì features tối ưu cho chính nó. Khi cho phép encoder/decoder train cùng (Phase II của paper), chúng adapt sang features phù hợp với variant module và *baseline* đều, kéo output về gần baseline.

Implications.

1. Light retrain phù hợp cho *rapid screening* (nhanh $\sim 50\times$) nhưng kết quả không phải estimate đáng tin cho full training.
2. Các nghiên cứu future về ablation cần cẩn trọng: confirm winners với full training trước khi claim.
3. Trade-off magnitude trong light retrain phản ánh *độ aggressive của smoothing* chứ không phải *bản chất của fusion bottleneck*.

5.2 Modal-specific gains của Combined-Paper

Mặc dù pooled SIG chỉ 2/25, Combined-Paper-MIF đạt:

- CT: 10/25 SIG sau Holm (cao nhất tất cả run)

- PET: 10/25 SIG sau Holm (cao nhất tất cả run)
- SPECT: 2/25 SIG (yếu)

Đề xuất giải thích:

5.3 So sánh với SOTA và paper baseline

5.4 Hạn chế

1. **Train data split không hoàn toàn paper-faithful:** paper không công bố cụ thể 286 cặp nào trong 810 cặp Harvard được dùng. Chúng tôi sample bằng seed 42 $\rightarrow$ khác paper composition $\rightarrow$ baseline reproduction lệch $\sim 10\text{--}20\%$.
2. **Test set khác paper:** paper test 21 CT + 42 PET + 73 SPECT, chúng tôi dùng 24×3 từ data/reference/ để tương thích với 9 light retrain variants.
3. **Batch 8 vs paper 16:** do RAM GPU P100 + AMP fp16 hạn chế. Convergence có thể chậm hơn.
4. **Module C (decomp loss) chưa thử:** paper note L_{decomp} là critical, nhưng đồ án không khảo sát reformulation.
5. **Single seed (42):** không đánh giá variance giữa các seed $\rightarrow$ cần ≥ 3 seeds cho claim mạnh hơn.

6 Kết luận và hướng phát triển

6.1 Tổng kết

Đề án nghiên cứu cải tiến CDDFuse cho bài toán tổng hợp ảnh đa phương thức y tế qua quy trình ablation hai giai đoạn:

1. Light retrain (10–25 epoch, freeze encoder/decoder) cho 4 alternatives Module A và 4 alternatives Module B $\rightarrow$ identify winners (Gated + Saliency).
2. Paper-faithful training (120 ep, 2-phase, P100 GPU + AMP fp16) cho baseline reproduction và Combined-Gated-Saliency.

6.2 Kết luận chính

- Combined-Gated-Saliency đạt 10 SIG trên CT và 10 SIG trên PET (per-modal Holm) trong huấn luyện đầy đủ, gợi ý hướng cải tiến *theo modality cụ thể*.
- Tuy nhiên, gain pooled toàn 3 modality chỉ 2/25 SIG $\rightarrow$ không thể claim “Combined cải thiện CDDFuse” theo nghĩa tổng quát.
- Trade-off NABF $\uparrow$ /QM $\downarrow$ trong light retrain là *artifact* của under-train + freeze encoder/decoder, không phải bottleneck của kiến trúc fusion.

6.3 Hướng phát triển

6.3.1 Ngắn hạn

1. Train cá nhân A.2 Gated và B.3 Saliency với paper procedure để hoàn thiện ablation table (Combined vs A only vs B only).
2. Tune learning rate riêng cho gated module (e.g. $\times 10$) vì init zeros cần update nhanh hơn.
3. Thử $\alpha_3 = 10$ (paper text) thay 5 (code release).
4. Combined-Gated-Learnable (B.4 thay B.3) — B.4 thắng per-modal trong light retrain.

6.3.2 Dài hạn

1. **Module C**: reformulate decomposition loss (Eq. 9 paper). Untested area, có thể là chỗ phá trade-off thực sự.
2. Multi-seed evaluation (≥ 3 seeds) cho variance estimate.
3. Frequency-domain loss (FreqLoss) để target QM/wavelet metric trực tiếp.
4. Tune cho specific clinical use case (CT diagnosis, PET functional viz).

A Phụ lục: Kết quả chi tiết

A.1 Khảo sát thiết kế Module A và Module B (light retrain)

Trước khi chốt phương án *Adaptive Gating* cho Module A và *Saliency-guided Pixel* cho Module B trong CDDFuse-AG (Chương 3), đề án đã khảo sát *ba phương án khác cho mỗi module* bằng *light retrain* (10–25 epoch, đóng băng Encoder/Decoder, chỉ fine-tune fusion layer + biến thể). Mục đích là sàng lọc nhanh các candidate trước khi cam kết tài nguyên cho huấn luyện đầy đủ.

Lưu ý phương pháp luận. Kết quả light retrain ở phụ lục này *không phải đóng góp chính* của đề án vì:

1. Cấu hình huấn luyện khác paper (epoch ít hơn, Encoder/Decoder đóng băng).
2. Một phát hiện thực nghiệm (Mục 5.1) cho thấy kết quả light retrain có thể *không generalize* sang huấn luyện đầy đủ.

Tuy nhiên, các số liệu này đã định hướng cho việc chọn phương án cuối cùng, vì vậy được lưu lại để tham khảo.

A.1.1 Module A — 4 phương án Fusion Rule

Bốn phương án thử nghiệm thay phép cộng $f_I + f_V$:

- **A.1 Sum** (baseline): phép cộng đơn giản như CDDFuse gốc.
- **A.2 Gated** (chọn): cổng softmax mềm $g \odot f_V + (1 - g) \odot f_I$, 16K params.
- **A.3 CrossAttn**: cross-modality attention kiểu Restormer MDTA, 37K params.
- **A.4 ChannelMoE**: per-channel mixture of 3 experts, 5K params.

Kết luận Module A. A.2 Gated thắng cả 3 alternatives ở các chỉ số chính (NABF, QSF) và có QM regression nhẹ nhất. Đồng thời simplest architecture (chỉ một sigmoid gate). → Chọn A.2 Gated làm **Adaptive Gating** của CDDFuse-AG.

Bảng A.1: Module A — Cliff’s δ so với baseline CDDFuse, light retrain 10 ep CPU/GPU. Hiệu lực: L =large, m =medium, s =small, t =trivial. **In đậm** = phương án tốt nhất.

Metric	A.1 Sum	A.2 Gated	A.3 CrossAttn	A.4 ChannelMoE
NABF $\downarrow$ (δ improvement)	0 (ref)	+0.596 (L)	+0.529 (L)	+0.504 (L)
QSF $\uparrow$	0 (ref)	+0.602 (L)	+0.542 (L)	+0.488 (L)
PSNR $\uparrow$	0 (ref)	+0.243 (s)	+0.238 (s)	+0.256 (s)
EN $\uparrow$	0 (ref)	+0.035 (t)	+0.048 (t)	+0.016 (t)
QM $\uparrow$ (regression)	0 (ref)	-0.602 (L)	-0.637 (L)	-0.745 (L)
Số SIG / 22 (pooled)	0	5/22	5/22	4/22

A.1.2 Module B — 4 phương án Loss Target

Bốn phương án thay quy tắc max-pixel trong L_{int}^H :

- **B.1 Max** (baseline): $\max(I_Y, I_{IR})$ như CDDFuse gốc.
- **B.2 Mean**: $0.5 \cdot (I_Y + I_{IR})$.
- **B.3 Saliency** (chọn): trọng số gradient $w = |\nabla I_Y| / (|\nabla I_Y| + |\nabla I_{IR}|)$.
- **B.4 Learnable**: small CNN dự đoán w từ $[I_Y, I_{IR}, \nabla I_Y, \nabla I_{IR}]$.

Bảng A.2: Module B — Cliff’s δ so với baseline CDDFuse, light retrain. **In đậm** = phương án tốt nhất.

Metric	B.1 Max	B.2 Mean	B.3 Saliency	B.4 Learnable
NABF $\downarrow$ (δ)	0 (ref)	+0.669 (L)	+0.671 (L)	+0.671 (L)
QSF $\uparrow$	0 (ref)	+0.591 (L)	+0.568 (L)	+0.543 (L)
PSNR $\uparrow$	0 (ref)	+0.251 (s)	+0.236 (s)	+0.228 (s)
QMI $\uparrow$	0 (ref)	NS	+0.047 SIG	+0.074 SIG
QM $\uparrow$ (regression)	0 (ref)	-0.735 (L)	-0.732 (L)	-0.731 (L)
Số SIG / 22 (pooled)	0	4/22	6/22	5/22
Per-modal CT SIG	0	6	6	9
Per-modal PET SIG	0	6	7	8
Per-modal SPECT SIG	0	2	2	2

Kết luận Module B. B.3 Saliency thắng pooled SIG (6/22) — thể hiện robustness tốt nhất khi gộp 3 modality. B.4 Learnable thắng per-modal CT/PET (9 và 8) nhưng

yếu hơn pooled, cho thấy CNN học có thể overfit modality-specific. → Chọn B.3 Saliency làm **Saliency-guided Pixel** của CDDFuse-AG vì ưu tiên *nhất quán giữa các modality*.

A.1.3 Combined model — light retrain (xác nhận ban đầu)

Sau khi chốt A.2 + B.3, đề án chạy mô hình kết hợp light retrain trước khi cam kết huấn luyện đầy đủ:

Bảng A.3: Combined-Gated-Saliency (light retrain) vs baseline. So sánh với kết quả paper-faithful trong Chương 4.

Metric	Light retrain (δ)	Paper-faithful (δ , Ch. 4)
NABF $\uparrow$ (δ improvement)	+0.659 (L)	+0.174 (small)
QM $\uparrow$ (regression)	-0.587 (L)	-0.118 (trivial)
QSF $\uparrow$	+0.679 (L)	+0.218 (small)
Pooled SIG / 25	4/25	2/25

Phát hiện về methodology. Bảng ?? cho thấy *magnitude* hiệu ứng giảm 3–5 $\times$ khi chuyển từ light retrain sang huấn luyện đầy đủ. Cả gain (NABF, QSF) lẫn regression (QM) đều bị “co lại”. Đây là một bài học methodology được thảo luận trong Mục 5.1: light retrain phù hợp cho *sàng lọc* candidates nhưng *không đáng tin* cho việc estimate hiệu ứng cuối cùng. Vì vậy mọi claim của đề án về CDDFuse-AG đều dựa trên kết quả paper-faithful (Chương 4), không phải light retrain.

A.1.4 Thử nghiệm bổ sung — Module C (Decomp Loss)

Một phương án thử nghiệm thêm: thay Pearson Correlation Coefficient (CC) trong L_{decomp} bằng **linear CKA** (Centered Kernel Alignment) [?] để bắt được dependence phi tuyến. Mô hình **Combined-Saliency-CKA** được huấn luyện đầy đủ 120 epoch và đánh giá tương tự CDDFuse-AG:

Kết luận Module C. CKA decomposition loss *không cải thiện* so với Pearson CC trong huấn luyện đầy đủ. Có thể do: (1) Encoder MDTA attention đã sinh ra feature gần linear-separable, CC đủ; (2) cỡ mẫu mỗi batch $N = 8$ nhỏ, ước lượng CKA (Gram matrix 8×8) không ổn định; (3) bottleneck nằm ở *cấu trúc công thức* $D^2/(1+B)$ chứ không phải measure dependence. Đây là một negative result có giá trị — gợi ý hướng future work: cần reformulate *cấu trúc công thức* decomp loss thay vì chỉ thay measure.

Bảng A.4: Module C (CKA) so với Module C (CC) paper, cả hai paper-faithful. **In đậm** = tốt hơn.

	CDDFuse-AG (CC)	Combined-Saliency-CKA
Pooled SIG / 22	2	1
Per-modal CT SIG	10	9
Per-modal PET SIG	10	9
Per-modal SPECT SIG	2	2 (tie)

A.2 Chi tiết training history

A.3 Bảng đầy đủ 25 metrics cho từng variant

A.4 Cấu hình huấn luyện chi tiết

Bảng A.5: Hyperparameters paper-faithful training.

Hyperparameter	Value
Epochs total	120
Epoch gap (Phase I)	40
Batch size	8
Optimizer	Adam (4 separate, $\beta_1 = 0.9, \beta_2 = 0.999$)
Learning rate	10^{-4}
LR scheduler	StepLR $\gamma = 0.5$ every 20 ep
Clip grad norm	0.01
Mixed precision	fp16 (autocast + GradScaler)
α_1 (MSE)	1.0
α_2 (decomp)	2.0
α_3 (TV)	5.0 (code release; paper text 10)
α_4 (decomp II)	2.0
Patch size	128×128
Stride	64
Seed	42
Hardware	Tesla P100-PCIE-16GB (Kaggle)

A.5 Reproduce instructions

1. Clone repo

```
git clone https://github.com/kienvbhp872004/Image-Fusion
cd Image-Fusion
```

2. Setup Python 3.8 venv

```
py -3.8 -m venv .venv38
.\.venv38\Scripts\Activate.ps1
```

3. Install deps

```
pip install -r models/MMIF-CDDFuse/requirements.txt
pip install torch==2.1.2+cu118 torchvision==0.16.2+cu118 \
    --index-url https://download.pytorch.org/whl/cu118
```

4. Preprocess

```
cd models/MMIF-CDDFuse
python dataprocessing_MIF.py
```

5. Train

```
python train_MIF.py --variant Combined-Gated-Saliency --amp
```

6. Evaluate

```
python evaluate_cddfuse.py --variant Combined-Gated-Saliency \
    --modal CT --ckpt models/CDDFuse-Combined-Gated-Saliency_MIF_*.pth \
    --harvard_root ../../data/reference --save_perimage
```